



FACULTÉ DES SCIENCES INFORMATIQUES
Intelligence Artificielle

**Approches de traduction automatique pour les langues à
faibles ressources : application au ruund–français**

*Travail de fin d'études présenté et défendu en vue de l'obtention
du grade de licencié en sciences informatiques.*

Présenté par: MUNUNGA KAYINDA Eliezer

Date (juillet 2026)



FACULTÉ DES SCIENCES INFORMATIQUES
Intelligence Artificielle

Approches de traduction automatique pour les langues à faibles ressources : application au ruund–français

*Travail de fin d'études présenté et défendu en vue de l'obtention
du grade de licencié en sciences informatiques.*

*Présenté par: MUNUNGA KAYINDA Eliezer
Dirigé par: **Prof. Selain K. Kasereka**
Codirigé par : **C.T Godwill W.K. Ilunga***

Date (juillet 2026)

DÉCLARATION SUR L'HONNEUR

Je soussigné, certifie sur l'honneur que le présent mémoire constitue un travail personnel, original et réalisé dans le cadre de mes études.

Je déclare que toutes les sources d'information, les données, les idées ainsi que les citations utilisées dans ce document ont été correctement identifiées et référencées conformément aux normes bibliographiques IEEE.

Je certifie également que :

- ce mémoire est un travail inédit qui n'a jamais été soumis, en tout ou en partie, pour l'obtention d'un autre diplôme ou titre académique ;
- il ne comporte aucun acte de plagiat ni aucune reproduction non autorisée d'une œuvre protégée par les droits d'auteur ;
- toutes les citations, qu'elles soient directes ou indirectes, ont été dûment signalées et référencées.

Fait à Lubumbashi, le May 31, 2026

Signature :

A handwritten signature in black ink, appearing to read 'Mununga', with a stylized flourish underneath.

MUNUNGA KAYINDA Eliezer

RÉSUMÉ

Résumé en français obligatoire.

ABSTRACT

Abstract in English mandatory.

ÉPIGRAPHE

Mon epigraphe

DEDICACE

Dédié à la mémoire de
1960 – 2018

REMERCIEMENT

Remerciement

CONTENTS

Déclaration sur l'honneur	iii
Dédicace	vii
Liste des abréviations et acronymes	xii
0 INTRODUCTION GÉNÉRALE	1
0.1 Contexte de l'étude	1
0.2 Problématique	1
0.3 Objectifs du mémoire	2
0.3.1 Objectif général	2
0.3.2 Objectifs spécifiques	2
0.4 Hypothèses de recherche	3
0.5 Contributions du mémoire	3
0.6 Organisation du mémoire	3
1 REVUE DE LITTÉRATURE	4
1.1 Fondements théoriques	4
1.1.1 Intelligence artificielle	4
1.1.2 Machine Learning	5
1.1.3 Deep Learning	6
1.1.4 Traitement automatique des langues naturelles	7
1.1.5 Traduction automatique	7
1.1.6 Traduction automatique neuronale	9
1.1.7 Architectures Transformer	10
1.1.8 Modèles multilingues de traduction	12
1.1.9 Entraînement et adaptation des modèles neuronaux	14
1.1.10 Tokenisation et représentations linguistiques	15
1.1.11 Corpus parallèles	16
1.2 Domaine linguistique et langues à faibles ressources	18
1.2.1 Langues à faibles ressources	18
1.2.2 Défis du Traitement Automatique des Langues Naturelles (TAL) pour les langues africaines	19
1.2.3 Présentation linguistique du ruund	19
1.2.4 Préservation linguistique et intelligence artificielle	21
1.2.5 Analyse critique des travaux existants	21
1.2.6 Gap scientifique et positionnement du mémoire	24
2 MÉTHODOLOGIE	25
3 RÉSULTATS ET ANALYSE	26
4 CONCLUSION ET PERSPECTIVES	27
A ANNEXE A	32

LIST OF FIGURES

Figure 1.1	L'Encodeur-Décodeur	10
Figure 1.2	Architecture Transformer	11
Figure 1.3	Répartition des langues selon leurs ressources en NLP	18

LIST OF TABLES

Table 1	Comparaison des approches de traduction automatique	9
Table 2	Comparaison des modèles multilingues de traduction automatique . . .	13
Table 3	Synthèse comparative des travaux existants sur la TAN pour les langues à faibles ressources	22

LISTE DES ABRÉVIATIONS ET ACRONYMES

IA	Intelligence Artificielle
TAL	Traitement Automatique des Langues Naturelles
NLP	<i>Natural Language Processing</i>
ML	<i>Machine Learning</i> (Apprentissage automatique)
DL	<i>Deep Learning</i> (Apprentissage profond)
TA	Traduction Automatique
TAB	Traduction Automatique Basée sur des règles
TAS	Traduction Automatique Statistique
TAN	Traduction Automatique Neuronale
NMT	<i>Neural Machine Translation</i>
SMT	<i>Statistical Machine Translation</i>
RBMT	<i>Rule-Based Machine Translation</i>
RNN	<i>Recurrent Neural Network</i>
LSTM	<i>Long Short-Term Memory</i>
GRU	<i>Gated Recurrent Unit</i>
GPU	Processeurs Graphiques
OOV	Out Of Vocabulary
CNN	<i>Convolutional Neural Network</i> (Réseau de neurones convolutif)
RNA	<i>Réseaux de neurones artificiels</i> (Artificial Neural Network)
BLEU	<i>Bilingual Evaluation Understudy</i>
BPE	<i>Byte Pair Encoding</i>
SentencePiece	<i>SentencePiece Tokenizer</i>
mBART	<i>Multilingual Bidirectional and Auto-Regressive Transformer</i>
NLLB	<i>No Language Left Behind</i>
MarianMT	<i>Marian Machine Translation</i>
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
mBERT	<i>Multilingual BERT</i>
GPT	<i>Generative Pre-trained Transformer</i>
XLM	<i>Cross-lingual Language Model</i>
TF-IDF	<i>Term Frequency–Inverse Document Frequency</i>
LFR	Langues à Faibles Ressources

RDC *République Démocratique du Congo*

ACL *Association for Computational Linguistics*

TER *Translation Edit Rate*

chrF *Character n -gram F -score*

PBSMT *Phrase-Based*

MNMT *Multilingual Neural Machine Translation*



INTRODUCTION GÉNÉRALE

Ce chapitre présente le contexte général de l'étude, la problématique, les objectifs du mémoire, les hypothèses de recherche, les contributions du travail ainsi que l'organisation générale du mémoire.

0.1 CONTEXTE DE L'ÉTUDE

La traduction automatique constitue aujourd'hui un domaine majeur du [TAL](#). Les progrès récents de l'intelligence artificielle, notamment ceux liés à l'apprentissage profond et aux architectures Transformer [\[43\]](#), ont permis le développement de systèmes de traduction automatique neuronale capables de produire des traductions de haute qualité pour plusieurs langues disposant d'importantes ressources numériques [\[37\]](#).

Cependant, ces avancées concernent principalement les langues dites à **fortes ressources**, telles que l'anglais, le français ou le chinois, pour lesquelles de très grands volumes de données parallèles sont disponibles. À l'inverse, plusieurs langues africaines demeurent faiblement représentées dans les technologies linguistiques modernes en raison du manque de ressources numériques exploitables [\[2, 37\]](#). Ces langues sont généralement qualifiées de **Langues à Faibles Ressources (LFR)**.

Parmi ces langues figure le **ruund**, une langue bantoue parlée principalement en République Démocratique du Congo ([RDC](#)) et en Angola. Malgré son importance culturelle et sociale, cette langue reste très peu exploitée dans le domaine du traitement automatique des langues. À l'instar d'autres langues à faibles ressources telles que le mizo [\[19\]](#) ou le pendjabi [\[21\]](#), les ressources numériques disponibles pour le ruund sont rares, peu structurées et souvent non numérisées, ce qui limite fortement le développement d'outils intelligents tels que les systèmes de traduction automatique.

Dans ce contexte, les approches modernes basées sur les modèles neuronaux multilingues pré-entraînés offrent de nouvelles perspectives pour le développement de systèmes de traduction adaptés aux langues à faibles ressources [\[26, 36\]](#). Ces modèles permettent de transférer des connaissances acquises sur plusieurs langues afin d'améliorer les performances de traduction même lorsque les données disponibles sont limitées [\[31, 35\]](#).

Le présent mémoire s'inscrit dans cette dynamique et porte sur les **approches de traduction automatique pour les langues à faibles ressources**, avec une application particulière au couple **ruund–français**.

0.2 PROBLÉMATIQUE

Le développement des systèmes modernes de traduction automatique repose principalement sur la disponibilité de grands volumes de données parallèles permettant l'apprentissage des correspondances linguistiques entre les langues source et cible [\[37\]](#). Toutefois, dans le cas des

langues à faibles ressources telles que le ruund, ces données sont extrêmement limitées, ce qui constitue un obstacle majeur à l'entraînement des modèles neuronaux performants [2, 19].

L'absence de datasets parallèles structurés, le manque de ressources linguistiques numériques ainsi que la faible disponibilité des travaux de recherche dédiés au ruund rendent difficile le développement d'un système de traduction automatique fiable [19, 21]. De plus, les spécificités morphologiques et syntaxiques des langues bantoues augmentent davantage la complexité du problème

Face à cette situation, plusieurs interrogations scientifiques se posent :

- Comment construire un dataset parallèle ruund–français exploitable pour l'apprentissage automatique ?
- Quelles techniques de prétraitement et d'alignement peuvent être utilisées pour améliorer la qualité des données ?
- Dans quelle mesure les modèles multilingues pré-entraînés peuvent-ils améliorer les performances de traduction dans un contexte à faibles ressources ?
- Quelles performances peuvent être obtenues avec une quantité limitée de données parallèles ?

La problématique principale de ce mémoire consiste donc à étudier comment développer un système de traduction automatique neuronale capable de produire des traductions exploitables entre le ruund et le français malgré la rareté des ressources linguistiques disponibles.

0.3 OBJECTIFS DU MÉMOIRE

0.3.1 *Objectif général*

L'objectif général de ce mémoire est de concevoir et d'évaluer un système de traduction automatique du ruund vers le français adapté au contexte des langues à faibles ressources.

0.3.2 *Objectifs spécifiques*

Plus spécifiquement, il s'agit de :

- Étudier les approches modernes de traduction automatique adaptées aux langues à faibles ressources ;
- Construire un dataset parallèle ruund–français à partir de ressources textuelles disponibles ;
- Effectuer le prétraitement, le nettoyage et l'alignement des données collectées ;
- Expérimenter différents modèles de traduction automatique neuronale, notamment les modèles multilingues pré-entraînés ;
- Évaluer les performances des modèles entraînés à l'aide de métriques adaptées ;
- Développer une application intégrant le modèle de traduction ainsi qu'un système de collecte de données textuelles et vocales.

0.4 HYPOTHÈSES DE RECHERCHE

Ce travail repose sur les hypothèses suivantes :

- La construction d'un dataset parallèle ruund–français de qualité peut améliorer significativement les performances de traduction automatique ;
- Les modèles multilingues pré-entraînés permettent de compenser partiellement le manque de ressources linguistiques disponibles ;
- L'utilisation des techniques modernes de traduction automatique neuronale peut produire des résultats exploitables même dans un contexte de faible disponibilité des données .

0.5 CONTRIBUTIONS DU MÉMOIRE

Les principales contributions de ce travail sont les suivantes :

- La construction d'un dataset parallèle ruund–français ;
- L'expérimentation des approches modernes de traduction automatique neuronale pour une langue à faibles ressources ;
- L'évaluation des performances de plusieurs modèles de traduction ;
- Le développement d'une application de collecte de données linguistiques intégrant un système de traduction automatique.

0.6 ORGANISATION DU MÉMOIRE

Le présent mémoire est structuré en deux grandes parties.

La première partie est consacrée à la construction du dataset parallèle ruund–français. Elle présente l'état de l'art, les concepts théoriques, les caractéristiques linguistiques du ruund ainsi que les différentes étapes de collecte, de préparation et de prétraitement des données.

La seconde partie porte sur l'entraînement du modèle de traduction automatique neuronale. Elle décrit les approches méthodologiques adoptées, les architectures utilisées, les expérimentations réalisées, les résultats obtenus ainsi que les perspectives d'amélioration du système proposé.

L'**intelligence artificielle** connaît une évolution rapide et transforme profondément plusieurs domaines technologiques, notamment le **traitement automatique des langues naturelles**. Grâce aux avancées du *machine learning* et du *deep learning*, les systèmes informatiques sont désormais capables d'analyser, comprendre et générer du langage humain avec une efficacité croissante.

Le **TAL** constitue aujourd'hui un domaine central de l'intelligence artificielle. Parmi ses principales applications figure la **traduction automatique**, qui a évolué des approches basées sur des règles vers des modèles neuronaux utilisant les architectures **Transformer** [43]. Ces modèles offrent des performances élevées, mais nécessitent généralement de grandes quantités de données linguistiques [37].

Cependant, les **LFR** demeurent insuffisamment représentées dans les technologies numériques modernes [37]. Cette problématique est particulièrement visible dans le contexte africain, où de nombreuses langues locales disposent de peu de corpus numériques et d'outils linguistiques adaptés [2]. Le **ruund** fait partie de ces langues sous-représentées, ce qui limite son intégration dans les systèmes de traduction automatique [19].

Dans ce contexte, ce chapitre présente les fondements théoriques liés à l'intelligence artificielle, au **TAL** et à la **Traduction Automatique Neuronale (TAN)**. Il aborde également les problématiques des **LFR**, le contexte linguistique africain ainsi que les travaux existants afin de justifier l'intérêt scientifique de cette recherche sur la traduction automatique ruund-français.

1.1 FONDEMENTS THÉORIQUES

1.1.1 Intelligence artificielle

Définition et évolution de l'intelligence artificielle

L'**Intelligence Artificielle (IA)** désigne un ensemble de méthodes et de techniques permettant à une machine de reproduire certaines capacités cognitives humaines telles que l'apprentissage, le raisonnement, la résolution de problèmes ou la prise de décision. Ce domaine de recherche vise principalement à concevoir des systèmes capables d'exécuter automatiquement des tâches nécessitant normalement l'intelligence humaine [16].

L'évolution des capacités de calcul, la disponibilité massive des données numériques ainsi que les progrès des réseaux de neurones ont favorisé l'émergence du *machine learning* puis du *deep learning* [16]. Ces approches permettent aux systèmes informatiques d'apprendre automatiquement des représentations complexes à partir des données, améliorant considérablement les performances dans plusieurs domaines tels que la vision par ordinateur, la reconnaissance vocale et le traitement automatique des langues [37].

Domaines d'application de l'IA

L'**intelligence artificielle** est aujourd'hui utilisée dans de nombreux secteurs scientifiques, industriels et sociaux. L'IA joue également un rôle majeur dans les technologies linguistiques modernes. Les avancées récentes des modèles neuronaux ont permis le développement d'applications capables de traiter automatiquement les langues humaines avec un niveau de précision élevé [37, 43].

IA et traitement automatique des langues

Le **traitement automatique des langues naturelles** (*Natural Language Processing (NLP)*) constitue une branche de l'IA consacrée à l'analyse, à la compréhension et à la génération du langage humain par les machines. Ce domaine combine des connaissances issues de l'informatique, de la linguistique et de l'apprentissage automatique [37].

Les applications du TAL sont nombreuses, notamment la **traduction automatique**, la reconnaissance vocale, l'analyse de sentiments, le résumé automatique de textes et les agents conversationnels. Les progrès récents du *deep learning* et des architectures **Transformer** ont considérablement amélioré les performances des systèmes NLP, en particulier dans les tâches de TAN (*Neural Machine Translation (NMT)*) [3, 37, 43].

1.1.2 *Machine Learning*

Définition du Machine Learning

Le **Machine Learning (Apprentissage automatique) (ML)** constitue une branche de l'intelligence artificielle permettant aux systèmes informatiques d'apprendre automatiquement à partir des données sans être explicitement programmés pour chaque tâche [16]. Son objectif principal est de construire des modèles capables d'identifier des relations, des régularités ou des représentations à partir des données afin d'effectuer des prédictions ou des décisions automatiques [16].

Types d'apprentissage

Le ML regroupe principalement trois grandes catégories d'apprentissage : l'apprentissage supervisé, l'apprentissage non supervisé et l'apprentissage par renforcement [16].

L'APPRENTISSAGE SUPERVISÉ : repose sur l'utilisation de données annotées contenant des exemples d'entrée et de sortie. Le modèle apprend alors à établir une relation entre les données d'entrée et les résultats attendus afin de prédire correctement de nouvelles données [16]. Cette approche est largement utilisée dans les tâches de classification, de régression et de traduction automatique [37].

L'APPRENTISSAGE NON SUPERVISÉ : utilise des données non annotées. Dans ce cas, le système cherche automatiquement à identifier des structures, des regroupements ou des relations cachées dans les données [16]. Cette approche est souvent utilisée pour le *clustering*, la réduction de dimension ou l'analyse exploratoire des données.

L'APPRENTISSAGE PAR RENFORCEMENT : repose sur un mécanisme d'interaction entre un agent et son environnement. Le système apprend progressivement en recevant des récompenses ou des pénalités selon les actions réalisées [16]. Cette approche est principalement utilisée dans les systèmes de décision autonome, la robotique et certains domaines d'optimisation.

Apprentissage supervisé dans la traduction automatique

La **traduction automatique neuronale** (TAN) repose principalement sur l'apprentissage supervisé. Dans cette approche, le modèle est entraîné à partir de **corpus parallèles** contenant des phrases dans une langue source et leurs traductions correspondantes dans une langue cible [19, 21, 37].

1.1.3 *Deep Learning*

Réseaux de neurones artificiels

Les **Réseaux de neurones artificiels** (Artificial Neural Network) (RNA) sont des modèles informatiques inspirés du fonctionnement biologique du cerveau humain [16]. Ils sont composés d'unités appelées **neurones artificiels**, organisées en différentes couches interconnectées. Chaque neurone reçoit des données en entrée, effectue des calculs mathématiques puis transmet un résultat à la couche suivante [16].

Réseaux neuronaux profonds

Le **Deep Learning** (*Apprentissage profond*) (DL) correspond à une évolution des réseaux de neurones artificiels utilisant plusieurs couches cachées. Ces architectures profondes permettent d'apprendre des représentations hiérarchiques et complexes des données, améliorant considérablement les performances des modèles d'intelligence artificielle [16].

Les réseaux neuronaux profonds ont connu un développement important grâce à l'augmentation de la puissance de calcul, à la disponibilité des données massives et aux progrès des processeurs graphiques [16]. Ils sont aujourd'hui utilisés dans plusieurs domaines tels que la vision par ordinateur, la reconnaissance vocale et le traitement automatique des langues [37].

Importance du Deep Learning dans le NLP

Le DL a profondément transformé le traitement automatique des langues naturelles. Contrairement aux approches traditionnelles basées sur des règles linguistiques ou des caractéristiques manuellement définies, les modèles profonds apprennent automatiquement les représentations linguistiques à partir des données [16, 37].

Cette évolution a permis l'apparition de modèles neuronaux performants capables de traiter des tâches complexes telles que la **Traduction Automatique** (TA), la génération de texte, les agents conversationnels et l'analyse sémantique [3, 37]. Les architectures modernes comme les **Transformers** ont particulièrement amélioré la qualité des systèmes NLP en facilitant la prise en compte du contexte linguistique [43].

1.1.4 Traitement automatique des langues naturelles

Définition du TAL

Le **traitement automatique des langues naturelles** (*Natural Language Processing*—NLP) est une branche de l'intelligence artificielle consacrée à l'analyse, à la compréhension et à la génération automatique du langage humain par les machines. Ce domaine combine des connaissances issues de l'informatique, de la linguistique et du ML afin de permettre aux systèmes informatiques de manipuler les langues naturelles de manière automatisée [37].

Le TAL vise principalement à faciliter l'interaction entre l'homme et la machine à travers le traitement des données textuelles et vocales. Les avancées récentes du DL ont fortement amélioré les capacités des systèmes NLP dans plusieurs tâches linguistiques complexes [43].

Principales applications du TAL

Le TAL possède de nombreuses applications dans les technologies numériques modernes. Parmi les principales figurent la **traduction automatique**, la reconnaissance vocale, les assistants conversationnels, l'analyse de sentiments ainsi que les systèmes de recherche d'information [37].

TAL et langues africaines

Malgré les progrès importants du TAL, plusieurs langues africaines demeurent faiblement représentées dans les ressources numériques et les systèmes NLP modernes. Cette situation s'explique notamment par le manque de corpus numériques, l'absence de standardisation linguistique et la rareté des outils de traitement adaptés [2].

Les **langues africaines à faibles ressources** rencontrent ainsi des difficultés importantes dans le développement d'applications telles que la **traduction automatique neuronale**. Le manque de données parallèles limite l'entraînement efficace des modèles de DL, ce qui réduit les performances des systèmes développés pour ces langues [32].

1.1.5 Traduction automatique

Définition de la traduction automatique

La **traduction automatique** (TA) désigne l'utilisation de systèmes informatiques capables de traduire automatiquement un texte d'une langue source vers une langue cible sans intervention humaine directe. Elle constitue l'une des principales applications du traitement automatique des langues naturelles [37].

L'objectif de la TA est de produire des traductions grammaticalement correctes et sémantiquement cohérentes tout en conservant le sens du texte original. Les performances des systèmes de traduction ont considérablement évolué grâce aux progrès du ML et du DL [43].

Traduction Automatique Basée sur des règles (TAB)

Les premiers systèmes de traduction automatique reposaient principalement sur des approches basées sur des règles linguistiques (*Rule-Based Machine Translation (RBMT)*). Ces systèmes utilisaient des dictionnaires bilingues ainsi que des règles grammaticales définies manuellement par des experts linguistes [37].

Cette approche nécessitait une importante expertise linguistique et un travail manuel considérable pour chaque paire de langues. Bien qu'elle permette un certain contrôle linguistique, elle présentait des difficultés importantes face aux ambiguïtés lexicales et aux variations contextuelles des langues naturelles [14].

Traduction Automatique Statistique (TAS)

La **TAS** (*Statistical Machine Translation (SMT)*) a ensuite remplacé progressivement les approches basées sur des règles. Cette méthode repose sur l'apprentissage de relations statistiques à partir de grands corpus parallèles contenant des phrases alignées dans plusieurs langues.

Les systèmes statistiques analysent les probabilités de correspondance entre les mots et les segments linguistiques afin de générer des traductions automatiques. Cette approche a permis d'améliorer significativement la qualité des traductions par rapport aux systèmes basés uniquement sur des règles linguistiques [5].

Limites des approches classiques

Malgré leurs contributions importantes, les approches classiques de traduction automatique présentent plusieurs limites. Les systèmes basés sur des règles nécessitent un important travail manuel et restent difficiles à adapter à de nouvelles langues. Les approches statistiques, quant à elles, dépendent fortement de la disponibilité de grands corpus parallèles et rencontrent des difficultés dans la gestion du contexte global des phrases [37].

Ces limitations ont favorisé l'émergence de la **traduction automatique neuronale (TAN)**, capable d'apprendre automatiquement des représentations linguistiques plus complexes et de produire des traductions plus naturelles et plus cohérentes [43].

Table 1: Comparaison des approches de traduction automatique

Critère	RBMT	SMT	NMT
Période	Années 1950–1990	Années 1990–2015	Depuis 2015
Principe	Règles linguistiques et dictionnaires bilingues définis manuellement	Modèles probabilistes appris à partir de corpus parallèles	Réseaux de neurones profonds entraînés sur corpus parallèles
Données requises	Règles et lexiques manuels	Grands corpus parallèles	Grands corpus parallèles
Apprentissage	Non automatique	Automatique (statistique)	Automatique (neural)
Gestion du contexte	Limitée	Partielle (n-grammes)	Globale (mécanisme d’attention)
Qualité des traductions	Contrôlée mais rigide	Meilleure que RBMT	Meilleure qualité globale
Langues à faibles ressources	Difficile (expertise manuelle)	Difficile (manque de corpus)	Difficile (manque de données)
Exemples de systèmes	Systran, Apertium	Moses, Pharaoh	mBART, NLLB...

1.1.6 Traduction automatique neuronale

Principe de la traduction neuronale

La **traduction automatique neuronale** (NMT) constitue une approche moderne de traduction automatique fondée sur les réseaux de neurones profonds. Contrairement aux approches classiques basées sur des règles ou des probabilités statistiques, la traduction neuronale apprend automatiquement les relations linguistiques entre les langues à partir de corpus parallèles [37].

Le modèle reçoit une phrase dans une langue source et génère directement sa traduction dans une langue cible. Cette approche permet de produire des traductions plus fluides, plus cohérentes et mieux adaptées au contexte linguistique [43].

Architectures encodeur-décodeur

Les premiers systèmes de traduction neuronale reposaient principalement sur l’architecture **encodeur-décodeur** (*Encoder–Decoder*). Dans cette architecture, l’encodeur transforme la phrase

source en une représentation numérique appelée **vecteur de contexte**, tandis que le décodeur utilise cette représentation pour générer progressivement la phrase traduite [37].

Cette architecture a permis d'améliorer considérablement les performances de la traduction automatique en facilitant l'apprentissage des relations sémantiques entre les langues [27].




Figure 1.1: L'Encodeur-Décodeur [25]

Mécanisme d'attention

Le **mécanisme d'attention** (*Attention Mechanism*) a été introduit afin de résoudre certaines limites des architectures encodeur-décodeur classiques, notamment les difficultés liées aux longues phrases [43].

L'attention permet au modèle de se concentrer sur les parties les plus pertinentes de la phrase source lors de la génération de chaque mot traduit. Cette approche améliore la prise en compte du contexte linguistique et augmente la qualité des traductions produites [15].

Le mécanisme d'attention constitue également la base des architectures **Transformer** utilisées dans les modèles modernes de traduction automatique neuronale [43].

Avantages des approches neuronales

Les approches neuronales présentent plusieurs avantages par rapport aux méthodes classiques de traduction automatique. Elles permettent de produire des traductions plus naturelles, plus cohérentes et mieux contextualisées. Elles réduisent également la nécessité de définir manuellement des règles linguistiques complexes [37].

Les modèles neuronaux sont capables d'apprendre automatiquement des représentations linguistiques riches et de mieux gérer les relations contextuelles entre les mots. Cependant, leurs performances dépendent fortement de la disponibilité des données d'entraînement et des ressources de calcul, ce qui représente un défi important pour les **langues à faibles ressources** (LFR) telles que le ruund [19].

1.1.7 Architectures Transformer

Origine des Transformers

Les architectures **Transformer** ont été introduites en 2017 afin d'améliorer les performances des modèles de traitement automatique des langues. Contrairement aux réseaux récurrents traditionnels (*Recurrent Neural Network* (RNN)), les Transformers reposent principalement sur le mécanisme d'attention, permettant un traitement parallèle des données textuelles [43].

Cette architecture a marqué une évolution majeure dans le domaine du [NLP](#) en améliorant la qualité des tâches linguistiques telles que la traduction automatique, la génération de texte et la compréhension du langage naturel [\[37\]](#).

Fonctionnement du mécanisme d'attention

Le **mécanisme d'attention** permet au modèle d'identifier les éléments les plus importants d'une phrase lors du traitement linguistique. Pour chaque mot, le système évalue les relations avec les autres mots de la séquence afin de mieux comprendre le contexte global [\[43\]](#).

Cette approche améliore la gestion des dépendances linguistiques longues et réduit certaines limitations des architectures récurrentes classiques. Les Transformers utilisent principalement une variante appelée *Self-Attention*, dans laquelle chaque mot peut interagir directement avec les autres mots de la phrase [\[43\]](#).




Figure 1.2: Architecture Transformer [\[43\]](#)

Représentation contextuelle des mots

Les architectures Transformer permettent de générer des **représentations contextuelles** des mots. Contrairement aux représentations statiques traditionnelles, le sens d'un mot est interprété selon son contexte dans la phrase [\[43\]](#).

Cette capacité améliore considérablement la compréhension sémantique et réduit les ambiguïtés linguistiques. Les modèles modernes peuvent ainsi produire des traductions plus cohérentes et mieux adaptées au contexte du texte source [\[36\]](#).

Transformers et traduction multilingue

Les Transformers constituent aujourd’hui la base des principaux modèles de traduction automatique multilingue tels que **mBART**, **MarianMT** ou **NLLB**. Ces modèles sont capables d’apprendre simultanément plusieurs langues à partir de grands corpus multilingues [36].

Cette approche facilite le transfert de connaissances entre les langues à fortes ressources et les **langues à faibles ressources**. Elle représente ainsi une solution importante pour le développement de systèmes de traduction automatique adaptés aux langues africaines peu représentées numériquement, notamment le ruund [32].

1.1.8 Modèles multilingues de traduction

Modèles pré-entraînés multilingues

Les **modèles pré-entraînés multilingues** sont des modèles neuronaux entraînés sur de grandes quantités de données provenant de plusieurs langues simultanément. Leur objectif est d’apprendre des représentations linguistiques générales capables d’être réutilisées dans différentes tâches de traitement automatique des langues, notamment la traduction automatique [37].

Ces modèles reposent principalement sur les architectures **Transformer** et exploitent le transfert de connaissances entre langues. Cette approche est particulièrement importante pour les **langues à faibles ressources**, car elle permet d’améliorer les performances même lorsque les données disponibles sont limitées [35].

Présentation de Multilingual Bidirectional and Auto-Regressive Transformer (mBART)

mBART-50 est un modèle multilingue de traduction automatique fondé sur l’architecture Transformer. Il repose sur une stratégie de pré-entraînement séquence-à-séquence permettant au modèle d’apprendre des représentations linguistiques à partir de plusieurs langues [36].

Le modèle prend en charge plusieurs dizaines de langues et peut être adapté à des tâches spécifiques grâce au *fine-tuning*. mBART-50 est particulièrement utilisé dans les contextes multilingues et les langues à faibles ressources grâce à sa capacité de transfert linguistique [36].

Présentation de NLLB-200-distilled-600M

NLLB-200-distilled-600M est un modèle développé dans le cadre du projet *No Language Left Behind* (**NLLB**). Son objectif principal est d’améliorer la traduction automatique pour les langues sous-représentées dans les technologies numériques [37].

Ce modèle prend en charge un très grand nombre de langues, notamment plusieurs langues africaines. Grâce à son entraînement multilingue massif, il offre de bonnes capacités de généralisation et de transfert vers les langues à faibles ressources. La version distillée permet également de réduire les besoins en ressources computationnelles tout en conservant des performances importantes [3].

Présentation de Marian Machine Translation (*MarianMT*)

MarianMT est un modèle de traduction automatique neuronale basé sur l'architecture Transformer et développé pour les tâches de traduction multilingue. Il est largement utilisé dans les bibliothèques NLP modernes grâce à sa flexibilité et à sa compatibilité avec plusieurs paires de langues [8].

MarianMT propose des modèles pré-entraînés spécialisés pour différentes combinaisons linguistiques et peut également être adapté à des contextes spécifiques à travers le *fine-tuning* [26].

Comparaison générale des modèles

Les modèles mBART-50, NLLB-200-distilled-600M et MarianMT reposent tous sur les architectures Transformer et utilisent des approches multilingues de traduction automatique neuronale. Le tableau 2 présente une synthèse comparative de ces trois modèles selon plusieurs critères pertinents pour le contexte des langues à faibles ressources [36, 37].

Table 2: Comparaison des modèles multilingues de traduction automatique

Critère	mBART-50	NLLB-200-distilled-600M	MarianMT
Architecture	Transformer seq2seq	Transformer seq2seq	Transformer seq2seq
Nombre de langues	50 langues	200+ langues	Paires spécifiques
Stratégie de pré-entraînement	Débruitage multi-lingue	Entraînement supervisé massif	Entraînement supervisé par paire
Langues africaines	Couverture limitée	Couverture étendue	Très limitée
Adaptation (fine-tuning)	Oui	Oui	Oui
Ressources computationnelles	Modérées	Réduites (version distillée)	Légères
Langues à faibles ressources	Performant après fine-tuning	Orienté LFR	Dépend de la paire
Disponibilité	HuggingFace	HuggingFace	HuggingFace

Le choix du modèle dépend principalement de plusieurs facteurs tels que la disponibilité des données, les ressources computationnelles et les objectifs de la tâche de traduction [37].

1.1.9 Entraînement et adaptation des modèles neuronaux

Pré-entraînement des modèles

Le **pré-entraînement** consiste à entraîner un modèle neuronal sur de très grandes quantités de données textuelles avant son utilisation dans une tâche spécifique. Cette étape permet au modèle d'apprendre des représentations linguistiques générales telles que les relations syntaxiques, sémantiques et contextuelles entre les mots [16, 37].

Fine-tuning des modèles multilingues

Le ***fine-tuning*** correspond à l'adaptation d'un modèle pré-entraîné à une tâche particulière à l'aide d'un corpus spécialisé. Dans le contexte de la traduction automatique, cette étape consiste à réentraîner le modèle sur des données parallèles spécifiques à une paire de langues donnée [36].

Le *fine-tuning* permet d'améliorer les performances du modèle dans un domaine précis tout en exploitant les connaissances acquises lors du pré-entraînement. Cette méthode est particulièrement utilisée pour les **langues à faibles ressources**, car elle réduit les besoins en grandes quantités de données d'entraînement [31].

Transfer learning dans les langues à faibles ressources

Le ***Transfer Learning*** ou **apprentissage par transfert** consiste à réutiliser les connaissances acquises par un modèle sur des langues ou des tâches disposant de grandes quantités de données afin d'améliorer les performances sur des langues moins représentées [26, 35].

Paramètres et poids des modèles

Les modèles neuronaux sont composés de nombreux paramètres appelés **poids** (*weights*), appris automatiquement pendant l'entraînement. Ces paramètres représentent les relations mathématiques apprises par le modèle à partir des données [16].

Les grands modèles multilingues possèdent souvent des millions, voire des milliards de paramètres. L'ajustement de ces poids pendant l'entraînement et le *fine-tuning* permet au système d'améliorer progressivement ses performances de traduction [36].

Cependant, l'augmentation du nombre de paramètres entraîne également des besoins plus importants en mémoire, en puissance de calcul et en données d'entraînement. Cette contrainte représente un défi majeur dans les contextes de **langues à faibles ressources (LFR)** et d'environnements computationnels limités [3].

Hyperparamètres d'entraînement

Les performances des modèles neuronaux dépendent fortement du choix des **hyperparamètres d'entraînement**. Contrairement aux paramètres appris automatiquement par le modèle, les hyperparamètres sont définis avant l'entraînement et influencent directement la qualité de

l'apprentissage [16]. Les principaux hyperparamètres utilisés dans les systèmes de TAN sont les suivants :

- Le *learning rate* détermine la vitesse de mise à jour des poids du modèle pendant l'apprentissage. Une valeur trop élevée peut entraîner une instabilité de l'entraînement, tandis qu'une valeur trop faible peut ralentir la convergence du modèle.
- Le *batch size* correspond au nombre d'exemples traités simultanément lors d'une étape d'entraînement. Une taille de batch élevée améliore généralement la stabilité des calculs, mais nécessite davantage de mémoire.
- Les *epochs* représentent le nombre de passages complets du modèle sur l'ensemble des données d'entraînement. Un nombre insuffisant d'epochs peut produire un sous-apprentissage (*underfitting*), tandis qu'un nombre trop élevé peut provoquer un surapprentissage (*overfitting*).

Le choix approprié de ces hyperparamètres est déterminant pour la convergence et les performances finales du modèle, en particulier dans les contextes à faibles ressources où les données d'entraînement sont limitées [36].

Contraintes computationnelles

L'entraînement des modèles neuronaux de traduction automatique nécessite des ressources computationnelles importantes. Les contraintes computationnelles concernent principalement l'utilisation des **Processeurs Graphiques (GPU)**, la capacité de stockage des données ainsi que le temps nécessaire pour entraîner et ajuster les modèles. Ces contraintes deviennent encore plus importantes dans les contextes de recherche disposant de ressources matérielles limitées [16].

Dans le cadre des **langues à faibles ressources**, les difficultés computationnelles s'ajoutent souvent aux limitations liées aux données linguistiques. Il devient alors nécessaire d'utiliser des approches adaptées telles que le *fine-tuning* de modèles pré-entraînés, les modèles distillés ou les architectures optimisées afin de réduire les coûts computationnels tout en maintenant des performances satisfaisantes [3].

1.1.10 *Tokenisation et représentations linguistiques*

Tokenisation des textes

La **tokenisation** consiste à découper un texte en unités élémentaires appelées **tokens**. Ces unités peuvent correspondre à des mots, des caractères ou des sous-mots selon l'approche utilisée. Cette étape constitue une phase essentielle du prétraitement des données dans les systèmes de TAL [37].

La tokenisation permet de transformer les textes bruts en représentations exploitables par les modèles neuronaux [16].

Segmentation en sous-mots

Les modèles modernes de traduction automatique utilisent généralement une **segmentation en sous-mots** plutôt qu’une simple segmentation par mots entiers. Cette approche consiste à découper les mots en unités linguistiques plus petites afin de mieux gérer les mots rares ou inconnus [41].

Cette stratégie est particulièrement adaptée aux langues morphologiquement riches et agglutinantes, pour lesquelles une tokenisation par mots entiers produirait un vocabulaire très large et peu généralisable [11].

SentencePiece Tokenizer (SentencePiece)

SentencePiece est une méthode de tokenisation largement utilisée dans les modèles Transformer modernes. Contrairement aux approches traditionnelles dépendantes des espaces entre les mots, SentencePiece traite directement le texte brut et apprend automatiquement les unités de segmentation les plus pertinentes [33].

Embeddings multilingues

Les **embeddings multilingues** sont des représentations vectorielles permettant de projeter les mots de plusieurs langues dans un même espace sémantique. Les mots ayant des significations proches possèdent ainsi des représentations vectorielles similaires [7, 33].

Problème des mots hors vocabulaire (OOV)

Les **mots hors vocabulaire** (*Out Of Vocabulary* (OOV)) correspondent aux mots absents du vocabulaire appris par le modèle pendant l’entraînement. Ce problème est fréquent dans les langues à faibles ressources en raison du manque de données disponibles [37, 41].

1.1.11 Corpus parallèles

Définition d’un corpus parallèle

Un **corpus parallèle** est un ensemble de textes alignés dans au moins deux langues différentes. Chaque phrase de la langue source possède une traduction correspondante dans la langue cible. Ces corpus constituent une ressource fondamentale dans les systèmes de traduction automatique neuronale [19, 37].

Importance des corpus dans la traduction automatique

Les modèles de traduction automatique apprennent les relations linguistiques à partir des corpus parallèles. La qualité, la taille et la diversité des données influencent directement les performances des systèmes neuronaux [2, 37].

Méthodes de collecte des données

La collecte des données peut être réalisée à partir de plusieurs sources telles que les documents bilingues, les textes religieux, les contenus éducatifs, les traductions manuelles ou les ressources communautaires [19, 21].

Dans le contexte des **langues africaines à faibles ressources**, la collecte des données nécessite souvent un travail manuel important en raison du manque de ressources numériques disponibles [2, 32].

Nettoyage et normalisation

Le **nettoyage** des données consiste à supprimer les erreurs, les doublons et les phrases mal alignées présentes dans le corpus. La **normalisation** permet quant à elle d'uniformiser les textes afin de faciliter l'apprentissage du modèle [39].

Cette étape peut inclure la conversion en minuscules, la suppression des caractères inutiles ainsi que la correction de certaines incohérences orthographiques [7].

Alignement des phrases

L'**alignement** consiste à associer correctement chaque phrase de la langue source avec sa traduction dans la langue cible. Cette étape est essentielle pour garantir la qualité des données utilisées pendant l'entraînement des modèles neuronaux [7, 19].

Corpus religieux et poétiques dans les langues à faibles ressources

Pour de nombreuses **langues à faibles ressources**, les textes religieux et poétiques constituent les piliers fondamentaux pour la construction des premiers corpus parallèles en raison de leur disponibilité. La **Bible** est une ressource privilégiée car sa structure rigoureuse en chapitres et en versets offre un cadre d'alignement naturel et fiable, essentiel pour des langues comme le mizo [13, 19], l'araméen [30], le twi [2] ou encore une douzaine de langues autochtones de Colombie et du Mexique telles que le mazatèque, le huichol ou le paez [8].

D'autres ressources structurées, comme le corpus **JW300**, sont également utilisées pour fournir des données bilingues à des langues comme le quechua ou des langues agglutinantes [11, 22]. Parallèlement, l'intégration de la **poésie** et de textes littéraires anciens permet d'enrichir la diversité lexicale et de capturer des nuances culturelles uniques, malgré une complexité stylistique accrue. Cette approche a été appliquée avec succès pour le croate [14], le môn [42] et pour la traduction de l'écriture logographique **Dongba** à partir de textes sacrés [31]. Ces ressources jouent un rôle crucial dans l'amorçage des systèmes de traduction automatique (NMT et SMT), permettant de réduire la fracture numérique pour les communautés linguistiquement sous-représentées [37].

1.2 DOMAINE LINGUISTIQUE ET LANGUES À FAIBLES RESSOURCES

1.2.1 Langues à faibles ressources

Définition

Les **langues à faibles ressources (LFR)** sont des langues disposant de peu de données numériques exploitables pour le développement des systèmes de traitement automatique des langues. Cette insuffisance concerne notamment les corpus textuels, les dictionnaires numériques, les ressources parallèles ainsi que les outils linguistiques nécessaires à l'entraînement des modèles d'intelligence artificielle [2, 37].

Ces langues sont généralement sous-représentées dans les technologies numériques modernes, ce qui limite leur intégration dans les applications de traduction automatique, de reconnaissance vocale ou de génération de texte [19, 37].

Causes du faible niveau de ressources numériques

Le faible niveau de ressources numériques s'explique par plusieurs facteurs. Parmi les principales causes figurent le manque de corpus électroniques, l'absence de standardisation orthographique, la faible numérisation des contenus linguistiques ainsi que le manque d'investissements technologiques et scientifiques [2, 21].

Dans plusieurs langues africaines, les ressources disponibles existent souvent sous forme papier ou orale, ce qui complique leur exploitation dans les systèmes de TAL [2, 32].

Inégalités numériques linguistiques

Les **inégalités numériques linguistiques** désignent la différence de représentation entre les langues dans les technologies numériques modernes. Certaines langues largement utilisées à l'échelle internationale disposent de grandes quantités de données et de nombreux outils NLP, tandis que d'autres restent faiblement représentées [3, 37].

Cette situation crée une **exclusion technologique** pour plusieurs communautés linguistiques, notamment africaines, dont les langues ne bénéficient pas pleinement des avancées de l'intelligence artificielle et de la TAN [2, 32].



Figure 1.3: Répartition des langues selon leur nombre de locuteurs et leurs ressources en NLP [29]

1.2.2 Défis du TAL pour les langues africaines

Manque de données linguistiques

Le principal défi du TAL pour les langues africaines réside dans le **manque de données linguistiques numériques** disponibles. La majorité des langues africaines disposent de très peu de corpus textuels, de ressources parallèles ou de bases lexicales exploitables pour l'entraînement des modèles neuronaux [2, 37].

Diversité dialectale

Plusieurs langues africaines présentent une forte **diversité dialectale**. Une même langue peut posséder différentes variantes régionales, phonétiques ou lexicales selon les communautés locutrices [2, 32].

Cette diversité complique la construction des corpus linguistiques et l'entraînement des modèles de TAL, car les variations dialectales peuvent entraîner des incohérences dans les données [19].

Absence de standardisation orthographique

Certaines langues africaines ne disposent pas d'une orthographe totalement standardisée. Les variations d'écriture, les différences de transcription et les pratiques linguistiques locales peuvent produire plusieurs formes écrites pour un même mot [19, 21].

Difficultés de collecte et d'annotation

La collecte et l'annotation des données linguistiques nécessitent souvent un travail manuel important. Dans les **langues à faibles ressources**, les textes numériques sont rares et plusieurs contenus existent principalement sous forme orale ou papier [2, 32].

Ces difficultés rendent la constitution de corpus parallèles de qualité particulièrement laborieuse, et exigent le recours à des méthodes d'augmentation ou d'automatisation partielle de la collecte afin de pallier le manque de données annotées [37, 39].

1.2.3 Présentation linguistique du ruund

Classification linguistique du ruund

Le **ruund**, aussi appelé *ruwund*, *uruund* ou *lunda du Nord* dans certaines classifications linguistiques, est une langue bantoue parlée par plus de 250 000 personnes principalement en République Démocratique du Congo et en Angola. Il appartient à la famille des langues nigéro-congolaises et au groupe des langues bantoues [44].

Cette langue est utilisée par une importante communauté locutrice, notamment dans la région du Katanga, mais demeure faiblement représentée dans les ressources numériques et les technologies linguistiques modernes [44].

Caractéristiques morphologiques

Sur le plan morphologique, le ruund possède une structure fortement **agglutinante** caractéristique des langues bantoues. L'organisation grammaticale de la langue repose principalement sur un système complexe de **classes nominales** dans lequel les substantifs sont regroupés sous forme de classes singulier/pluriel ou de classes uniques. Chaque nom est généralement associé à un **préfixe nominal** jouant un rôle central dans les mécanismes d'accord grammatical [24].

Le système verbal du ruund présente également une morphologie riche et complexe. Le verbe est construit autour d'une **racine verbale** combinée à plusieurs affixes flexionnels indiquant notamment l'accord du sujet, le temps, l'aspect, la négation ou encore la pronominalisation de l'objet. À cette structure s'ajoutent des extensions dérivationnelles telles que l'applicatif, le causatif ou le passif, capables de modifier la structure actancielle et la valeur sémantique du verbe [23, 24].

Par ailleurs, la morphotactique du ruund est soumise à des contraintes d'**harmonie vocalique** entre la racine verbale et certains suffixes grammaticaux [23]. Cette richesse morphologique représente un défi important dans les tâches de traitement automatique des langues, notamment pour la tokenisation, la segmentation morphologique et la traduction automatique neuronale.

Particularités syntaxiques et lexicales

Le fonctionnement syntaxique du ruund repose sur un système de **concordance grammaticale** fortement développé. Les différents éléments associés au substantif — notamment les adjectifs, les démonstratifs, les possessifs ainsi que le verbe — s'accordent systématiquement avec le nom selon la classe nominale, le nombre et parfois la personne grammaticale [24].

L'identification des relations grammaticales telles que le sujet, l'objet direct ou l'objet indirect s'effectue à travers une combinaison de mécanismes incluant l'ordre des mots, la pronominalisation et certains marquages morphosyntaxiques [24].

Le ruund présente également des évolutions syntaxiques particulières, notamment l'apparition de constructions **passives impersonnelles** venant concurrencer certaines formes passives bantoues traditionnelles construites à l'aide de suffixes verbaux. La langue se caractérise aussi par une diversité typologique importante des propositions relatives ainsi que par différents mécanismes de détransitivation [24].

Sur le plan morphosyntaxique, plusieurs études soulignent également l'existence d'un certain **synchrétisme** entre les formes réflexives et réciproques, ainsi qu'une convergence fonctionnelle entre les constructions passives et neutre-passives malgré leurs différences structurelles [23, 24].

Défis du ruund dans le NLP

Le développement des applications **NLP** pour le ruund fait face à plusieurs défis majeurs. La langue dispose de peu de corpus numériques, de ressources parallèles et d'outils linguistiques spécialisés. Les variations orthographiques et la rareté des données annotées compliquent également l'entraînement des modèles neuronaux.

Ces limitations réduisent les performances des systèmes de traduction automatique et justifient la nécessité de développer des approches adaptées aux langues à faibles ressources dans le contexte du ruund.

1.2.4 *Préservation linguistique et intelligence artificielle*

Numérisation des langues africaines

La numérisation des langues africaines constitue une étape essentielle pour leur intégration dans les technologies modernes de traitement automatique des langues. Ce processus consiste à transformer les ressources linguistiques disponibles sous forme orale ou papier en données numériques exploitables par les systèmes informatiques [2, 32].

IA et sauvegarde du patrimoine linguistique

L'intelligence artificielle joue un rôle important dans la préservation du patrimoine linguistique. Les technologies de traitement automatique des langues permettent de documenter, analyser et valoriser les langues peu représentées numériquement [3, 37].

Importance des ressources numériques locales

Le développement de ressources numériques locales représente un enjeu vital pour les langues africaines afin de surmonter la « **pénurie de données** » (*data scarcity*) qui marginalise la majorité des langues mondiales [37]. Pour le **ruund**, cette démarche s'appuie sur les avancées méthodologiques observées pour d'autres langues à faibles ressources telles que le **mizo** [19, 27], le **pendjabi** [21] ou le **twi** [2], qui souffrent également d'un manque initial de présence numérique native. À l'instar du **mon** [42], l'absence de corpus parallèles structurés constitue un frein majeur au développement d'applications performantes, rendant indispensable la création d'outils linguistiques et de données annotées pour renforcer les capacités des modèles neuronaux.

En s'appuyant sur les efforts de documentation menés pour le **quechua** [40] ou l'**araméen** [30], la constitution de ressources pour le ruund s'inscrit dans une quête de **justice numérique** visant à réduire la fracture technologique [2, 37]. Cette production de données locales dépasse le simple cadre du progrès technique : elle est essentielle pour **préserver et valoriser un patrimoine linguistique et culturel** unique face aux défis de la mondialisation. En permettant l'intégration du ruund dans les technologies du langage, ces travaux garantissent que ses locuteurs ne soient pas exclus des services essentiels et puissent participer pleinement à l'écosystème numérique mondial.

1.2.5 *Analyse critique des travaux existants*

Forces des approches actuelles

Les modèles basés sur les **Transformers** et l'apprentissage par transfert permettent d'obtenir des résultats exploitables là où les méthodes traditionnelles échouaient. Cette supériorité

empirique a été démontrée pour plusieurs paires de langues à faibles ressources, notamment le mizo–anglais [27] et le môn–anglais [42].

Limites liées aux données

La TAN est extrêmement gourmande en données ; les performances chutent drastiquement en dessous de 10 000 paires de phrases [37]. Notre corpus de 8 431 paires se situe précisément dans cette zone critique, rendant l’usage du transfert d’apprentissage indispensable [31].

Difficultés liées aux langues bantoues

Le manque de standardisation orthographique et la richesse des affixes verbaux compliquent la tâche de tokenisation. Les modèles généralistes peinent souvent à capturer l’harmonie vocalique et les spécificités tonales sans données massives.

Limites des métriques d’évaluation

Le score *Bilingual Evaluation Understudy* (BLEU), bien que standard, ne corrèle pas toujours parfaitement avec le jugement humain pour les langues à faibles ressources [27, 28]. Notre choix d’inclure une évaluation humaine est donc scientifiquement justifié pour valider l’adéquation sémantique [42].

Synthèse comparative des travaux

Le tableau 3 présente une analyse comparative de seize études représentatives portant sur la traduction automatique pour les langues à faibles ressources. Il synthétise les approches méthodologiques, les performances obtenues, la complexité des systèmes, leur robustesse ainsi que leurs limites principales.

Table 3: Synthèse comparative des travaux existants sur la TAN pour les langues à faibles ressources

Auteur(s)	Approche	Performance	Complexité	Robustesse	Limites principales
Ali, Yadav, and Kumar [7]	<i>Multilingual Neural Machine Translation</i> (MNMT) non supervisée (XLM-R + ACL)	+1.2 BLEU (bilingue)	Élevée	Haute	Qualité médiocre sur phrases longues ; dépendance aux dictionnaires bilingues
Lalrempuii, Soni, and Pakray [27]	Comparaison SMT vs NMT (mizo)	Transformer >> LSTM et SMT	Modérée	Moyenne	Baisse radicale sur phrases longues ; manque de ressources pour le mizo

Rakhimov [36]	Fine-tuning mBART-50	+11.95 BLEU (kazakh-russe)	Moyenne	Haute	Sensibilité à la qualité des données de fine-tuning et aux hyperparamètres
Ahmadnia, Dorr, and Aranovich [4]	Filtrage de données pseudo-parallèles	BLEU > baselines non filtrées	Modérée	Améliorée	Corpus filtré très réduit ; généralisation limitée
Dai et al. [12]	Transfert TFT-TL (niveau token)	19.88 BLEU (Tr-En)	Élevée	Excellente	Instabilité possible à certaines étapes d'apprentissage
Brahma, Maurya, and Desarkar [10]	SELECTNOISE (injection de bruit)	Surpasse les baselines zero-shot	Élevée	Robuste	Efficacité réduite si les scripts des langues sont trop différents
Chen and Fazio [11]	Segmentation morphologique (PRPE)	23.4 BLEU (quechua)	Modérée	Bonne	Nécessite une liste d'affixes préalable (connaissances linguistiques)
Bala Das et al. [9]	MNMT + translittération (Indic-Indic)	+6.74 BLEU (malayalam)	Modérée	Bonne	Interférence négative sur certains groupes linguistiques rares
Tun, Sin, and Soe [42]	Hybride SMT, NMT, BART fine-tuné	BART + SentencePiece = meilleurs résultats	Élevée	Bonne	Complexité morphologique du môt non résolue par le seul transfert
Ahmed et al. [6]	Rétro-translation itérative (mizo)	+3.65 BLEU par itération	Modérée	Moyenne	Inefficace sur phrases très longues
Grönroos, Virpioja, and Kurimo [18]	Multi-task learning programmé	+12.7 BLEU via MNMT + rétro-translation	Élevée	Haute	Rendements décroissants au-delà de 10 000 phrases
Acı, Vuran Sarı, and Acı [1]	Analyse de profondeur (anglais-turc)	47.85 BLEU (Transformer 3 couches)	Élevée	Excellente	Chute de performance si la profondeur dépasse le seuil optimal
Kann et al. [22]	AmericasNLI (langues indigènes)	+24.53% pour le quechua	Haute	Moyenne	Répétition de sous-mots dans les sorties ; sensibilité au domaine
Goyal, Kumar, and Sharma [17]	Translittération unifiée (indo-aryen)	+5 points BLEU en moyenne	Modérée	Bonne	Ambiguïtés à l'inférence entre langues proches

Hong et al. [20]	CANTONMT (rétro-traduction + commutation)	SacreBLEU 16.8	Haute	Moyenne	Corpus très réduit (60k) par rapport à la population cible (80M locuteurs)
Rani, Yadav, and Kumar Singh [38]	Filtrage cross- validation (sanskrit-hindi)	+1.85 BLEU (token-level)	Modérée	Bonne	Corpus filtré final très réduit (300 paires test) ; portée statistique limitée

1.2.6 Gap scientifique et positionnement du mémoire

Absence de travaux sur le ruund

Il n'existe actuellement aucun système de traduction automatique robuste documenté pour le ruund. Ce travail comble un vide numérique pour cette communauté linguistique.

Insuffisance des ressources numériques ruund-français

Les sources disponibles pour le ruund sont fragmentaires et non structurées pour le ML. L'effort de *Data Engineering* (nettoyage, normalisation, alignement de 8 431 paires) réalisé dans ce travail constitue une contribution majeure à la documentation numérique de cette langue [34].

Justification scientifique du mémoire

Ce mémoire se positionne à la pointe de la recherche actuelle en utilisant le *fine-tuning* de modèles étatiques (NLLB-200, mBART-50) pour compenser la rareté des données, selon une démarche validée pour d'autres langues à faibles ressources telles que le môn [42].

Contribution attendue de la recherche

Outre le système de traduction, ce travail propose une méthodologie pour construire des jeux de données exploitables à partir de sources religieuses et poétiques, ouvrant la voie à une future généralisation vers des domaines variés.

L'analyse du contexte des **langues à faibles ressources** a montré que le manque de données linguistiques, l'insuffisance des ressources numériques et les défis de standardisation constituent des obstacles majeurs au développement d'outils NLP performants [2, 37]. Ces contraintes sont particulièrement marquées dans le cas du **ruund**, une langue encore faiblement représentée dans les technologies du langage [19, 21].

Ainsi, la littérature existante souligne la nécessité de développer des approches adaptées aux langues à faibles ressources, notamment par la constitution de **corpus parallèles** et l'adaptation de **modèles multilingues pré-entraînés** [19, 37]. Ces constats justifient la présente recherche consacrée à la traduction automatique ruund-français [35, 36].

RÉSULTATS ET ANALYSE

CONCLUSION ET PERSPECTIVES

BIBLIOGRAPHY

- [1] Mehmet Acı, Nisa Vuran Sarı, and Çiğdem İnan Acı. "Morphological and structural complexity analysis of low-resource English-Turkish language pair using neural machine translation models." In: *PeerJ Computer Science* 11 (2025), e3072. DOI: [10.7717/peerj-cs.3072](https://doi.org/10.7717/peerj-cs.3072).
- [2] Emmanuel Agyei, Xiaoling Zhang, Stephen Bannerman, Ama Bonuah Quaye, Sophyani Banaamwini Yussi, and Victor Kwaku Agbesi. "Low resource Twi-English parallel corpus for machine translation in multiple domains (Twi-2-ENG)." In: *Discover Computing* 27.1 (2024), p. 17.
- [3] Emmanuel Agyei, Xiaoling Zhang, Ama Bonuah Quaye, Victor Adeyi Odeh, and Joseph Roger Arhin. "Dynamic aggregation and augmentation for low-resource machine translation using federated fine-tuning of pretrained transformer models." In: *Applied Sciences* 15.8 (2025), p. 4494.
- [4] Benyamin Ahmadnia, Bonnie J. Dorr, and Raul Aranovich. "Impact of Filtering Generated Pseudo Bilingual Texts in Low-Resource Neural Machine Translation Enhancement: The Case of Persian-Spanish." In: *Procedia Computer Science*. Vol. 189. Elsevier, 2021, pp. 136–141.
- [5] Benyamin Ahmadnia, Parisa Kordjamshidi, and Gholamreza Haffari. "Neural Machine Translation Advised by Statistical Machine Translation: The Case of Farsi-Spanish Bilingually Low-Resource Scenario." In: *Proceedings of the 17th IEEE International Conference on Machine Learning and Applications (ICMLA'18)*. IEEE. 2018, pp. 1209–1213. DOI: [10.1109/ICMLA.2018.00196](https://doi.org/10.1109/ICMLA.2018.00196).
- [6] Mazida Ahmed, Kuwali Talukdar, Parvez Boruah, Shikhar Kumar Sarma, and Kishore Kashyap. "Guit-nlp's submission to shared task: Low resource indic language translation." In: *Proceedings of the Eighth Conference on Machine Translation*. 2023, pp. 935–940.
- [7] Mumtaz Ali, Arun Yadav, and Mohit Kumar. "A Hybrid Word and Sentence Alignment Approach for Unsupervised Multilingual Machine Translation Using Pre-Trained Cross-Lingual Encoder." In: *ACM Transactions on Asian and Low-Resource Language Information Processing* (2026).
- [8] Jason Angel, Abdul Gafar Manuel Meque, Christian Maldonado-Sifuentes, Grigori Sidorov, and Alexander Gelbukh. "Comparing transformer-based machine translation models for low-resource languages of Colombia and Mexico." In: *Mexican International Conference on Artificial Intelligence*. Springer. 2023, pp. 95–105. DOI: [10.1007/978-3-031-47640-2_8](https://doi.org/10.1007/978-3-031-47640-2_8).
- [9] Sudhansu Bala Das, Divyajyoti Panda, Tapas Kumar Mishra, Bidyut Kr. Patra, and Asif Ekbal. "Multilingual neural machine translation for indic to indic languages." In: *ACM Transactions on Asian and Low-Resource Language Information Processing* 23.5 (2024), pp. 1–32.
- [10] Maharaj Brahma, Kaushal Maurya, and Maunendra Desarkar. "SelectNoise: Unsupervised Noise Injection to Enable Zero-Shot Machine Translation for Extremely Low-resource Languages." In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. Singapore: Association for Computational Linguistics, 2023, pp. 1615–1629. URL: <https://aclanthology.org/2023.findings-emnlp.109/>.

- [11] William Chen and Brett Fazio. "Morphologically-Guided Segmentation For Translation of Agglutinative Low-Resource Languages." In: *Proceedings of the 4th Workshop on Technologies for MT of Low Resource Languages (LoResMT2021)*. Virtual: Association for Machine Translation in the Americas, Aug. 2021, pp. 20–31. URL: <https://aclanthology.org/2021.mtsummit-loresmt.3/>.
- [12] Wei Dai, Dongfang Han, Turdi Tohti, Yi Liang, Zicheng Zuo, Yuanyuan Liao, and Qingwen Yang. "TFT-TL: Token-Level Filter Training Transfer Learning for Low-Resource Neural Machine Translation." In: *ACM Transactions on Asian and Low-Resource Language Information Processing* 24.6 (2025). DOI: [10.1145/3732779](https://doi.org/10.1145/3732779).
- [13] Chanambam Svata Devi, Loitongbam Sanayai Meetei, and Bipul Syam Purkayastha. "An empirical study on English-Mizo Statistical Machine Translation with Bible Corpus." In: *International Journal of Electrical and Computer Engineering Systems* 13.9 (Nov. 2022), pp. 759–765. DOI: [10.32985/ijeces.13.9.4](https://doi.org/10.32985/ijeces.13.9.4).
- [14] Ivan Dunđer, Sanja Seljan, and Marko Pavlovski. "Automatic machine translation of poetry and a low-resource language pair." In: *2020 43rd International Convention on Information, Communication and Electronic Technology (MIPRO)*. IEEE. 2020, pp. 1034–1039. DOI: [10.23919/MIPRO48935.2020.9245342](https://doi.org/10.23919/MIPRO48935.2020.9245342).
- [15] Kavita Gangar, Hardik Ruparel, and Shreyas Lele. "Hindi to english: Transformer-based neural machine translation." In: *International Conference on Communication, Computing and Electronics Systems: Proceedings of ICCCES 2020*. Springer. 2021, pp. 337–347.
- [16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [17] Vikrant Goyal, Sourav Kumar, and Dipti Misra Sharma. "Efficient neural machine translation for low-resource languages via exploiting related languages." In: *Proceedings of the 58th annual meeting of the association for computational linguistics: student research workshop*. 2020, pp. 162–168.
- [18] Stig-Arne Grönroos, Sami Virpioja, and Mikko Kurimo. "Transfer learning and subword sampling for asymmetric-resource one-to-many neural translation." In: *Machine Translation* 34 (2020), pp. 251–286. DOI: [10.1007/s10590-020-09253-x](https://doi.org/10.1007/s10590-020-09253-x).
- [19] Thangkhanhau Haulai and Jamal Hussain. "Construction of mizo: English parallel corpus for machine translation." In: *ACM Transactions on Asian and Low-Resource Language Information Processing* 22.8 (2023), pp. 1–12.
- [20] Kung Yin Hong et al. "CANTONMT: Investigating Back-Translation and Model-Switch Mechanisms for Cantonese-English Neural Machine Translation." In: *ACM Transactions on Asian and Low-Resource Language Information Processing* (2024). DOI: [10.1145/3698236](https://doi.org/10.1145/3698236).
- [21] Shishpal Jindal, Vishal Goyal, and Jaskarn Singh Bhullar. "Building English–Punjabi parallel corpus for machine translation." In: *International Journal of Computer Applications* 180.8 (2017), pp. 26–29.
- [22] Katharina Kann, Abteen Ebrahimi, Manuel Mager, Arturo Oncevay, John E Ortega, Annette Rios, Angela Fan, Ximena Gutierrez-Vasques, Luis Chiruzzo, Gustavo A Giménez-Lugo, et al. "AmericasNLI: Machine translation and natural language inference systems for Indigenous languages of the Americas." In: *Frontiers in Artificial Intelligence* 5 (2022), p. 995667. DOI: [10.3389/frai.2022.995667](https://doi.org/10.3389/frai.2022.995667).

- [23] Michaël Kasombo Tshibanda. *Structure segmentale du radical verbal et comportement tonal en ruwund L53*. Tech. rep. Lubumbashi: Université de Lubumbashi, 2016. URL: <https://blogs.helsinki.fi/bantu-6/files/2016/09/Bantu6-Kasombo-Structure-segmentale-du-radical-verbal-et-comportement-tonal-en-ruwund-L53.pdf>.
- [24] Boniface Kaumba Kawasha. “LUNDA GRAMMAR: A MORPHOSYNTACTIC AND SEMANTIC ANALYSIS.” Book. University of Oregon, June 2003. URL: <https://theswissbay.ch/pdf/Books/Linguistics/Mega%20linguistics%20pack/African/Niger-Congo/Bantu/Lunda%20Grammar%20-%20A%20Morphosyntactic%20and%20Semantic%20Analysis%20%28Kawasha%29.pdf>.
- [25] Tom Keldenich. *Encoder Decoder What and Why ? – Simple Explanation*. Inside Machine Learning. Consulté le 29 mai 2026. Oct. 2021. URL: <https://inside-machinelearning.com/en/encoder-decoder-what-and-why-simple-explanation/>.
- [26] Candy Lalrempuii and Badal Soni. “Investigating unsupervised neural machine translation for low-resource language pair english-mizo via lexically enhanced pre-trained language models.” In: *ACM Transactions on Asian and Low-Resource Language Information Processing* 22.8 (2023), pp. 1–18.
- [27] Candy Lalrempuii, Badal Soni, and Partha Pakray. “An improved English-to-Mizo neural machine translation.” In: *Transactions on Asian and Low-Resource Language Information Processing* 20.4 (2021), pp. 1–21.
- [28] Séamus Lankford, Haithem Afli, and Andy Way. “Human Evaluation of English–Irish Transformer-Based NMT.” In: *Information* 13.7 (2022), p. 309. DOI: [10.3390/info13070309](https://doi.org/10.3390/info13070309).
- [29] Felix Laumann. *Challenges in using NLP for low-resource languages and how NeuralSpace solves them*. Medium. Consulté le 29 mai 2026. Jan. 2022. URL: <https://medium.com/neuralspace/challenges-in-using-nlp-for-low-resource-languages-and-how-neuralspace-solves-them-54a01356a71b>.
- [30] Chaya Liebeskind, Shmuel Liebeskind, and Dan Bouhnik. “Machine translation for historical research: A case study of Aramaic–Ancient Hebrew translations.” In: *ACM Journal on Computing and Cultural Heritage* 17.2 (2024), pp. 1–23. DOI: [10.1145/3627168](https://doi.org/10.1145/3627168).
- [31] Xinchun Ma, Man Lan, Wenbo Hu, and Yue Lu. “Dongba machine translation with transfer Learning: leveraging pre-trained ancient Chinese models.” In: *ACM Transactions on Asian and Low-Resource Language Information Processing* 24.5 (2025), pp. 1–17.
- [32] Reagan E. Mandiya, Selain K. Kasereka, Christophe B. Wizamo, Milena Savova-Mratsenkova, Ruffin-Benoît M. Ngoie, Tasho Tashev, and Nathanaël M. Kasoro. “A Transformer-Based Method for Bidirectional French–Lingala Machine Translation in Speech and Text.” In: *Applied Sciences* 16.7 (2026), p. 3399. DOI: [10.3390/app16073399](https://doi.org/10.3390/app16073399).
- [33] Francois Meyer and Jan Buys. “A Systematic Analysis of Subwords and Cross-Lingual Transfer in Multilingual Translation.” In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. 2024. URL: <https://arxiv.org/abs/2403.20157>.
- [34] Eliezer Mununga, Christopher Mwanza, and Egla Mutale. *Ruwund-French Parallel Dataset*. 2026. URL: <https://huggingface.co/datasets/eliezermg/ruund-french-parallel-corpus>.
- [35] Toan Q. Nguyen and David Chiang. “Transfer Learning across Low-Resource, Related Languages for Neural Machine Translation.” In: *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 2: Short Papers)*. Taipei, Taiwan: Asian Federation of Natural Language Processing, Nov. 2017, pp. 296–301. URL: <https://aclanthology.org/I17-2050/>.

- [36] Mirzokhid Rakhimov. "Enhancing Neural Machine Translation with Fine-Tuned mBART50 Pre-Trained Model: An Examination with Low-Resource Translation Pairs." In: *Ingénierie des Systèmes d'Information* 29.3 (2024), pp. 1095–1104. DOI: [10.18280/isi.290304](https://doi.org/10.18280/isi.290304).
- [37] Surangika Ranathunga, En-Shiun Annie Lee, Marjana Prifti Skenduli, Ravi Shekhar, Mehreen Alam, and Rishemjit Kaur. "Neural machine translation for low-resource languages: A survey." In: *ACM Computing Surveys* 55.11 (2023), pp. 1–37. DOI: [10.1145/3567592](https://doi.org/10.1145/3567592).
- [38] Pooja Rani, Kamlesh Yadav, and Anil Kumar Singh. "Filtering and Extended Vocabulary based Translation for Low-resource Language Pair of Sanskrit-Hindi." In: *ACM Transactions on Asian and Low-Resource Language Information Processing* (2023). DOI: [10.1145/3580495](https://doi.org/10.1145/3580495).
- [39] Prawaal Sharma, Navneet Goyal, Poonam Goyal, and Vishnupriyan R. "A fully automated and scalable Parallel Data Augmentation for Low Resource Languages using image and text analytics." In: *Proceedings of the 38th ACM/SIGAPP Symposium on Applied Computing*. 2023, pp. 358–361.
- [40] José Alfredo Sulla Torres, Beatrice Cueva Medina, and Gabriel Fabrizio Tuco Casquino. "Desarrollo de un modelo de traducción automática neuronal optimizado con BERT para la traducción del idioma quechua al español." In: *Sustainable Engineering for a Diverse, Equitable, and Inclusive Future at the Service of Education, Research, and Industry for a Society 5.0*. (LACCEI 2024). Costa Rica, 2024. URL: <https://laccei.org/LACCEI2024-CostaRica/meta/FP1636.html>.
- [41] Cagri Toraman, Eyup Halit Yilmaz, Furkan Şahinuç, and Oguzhan Ozelik. "Impact of Tokenization on Language Models: An Analysis for Turkish." In: *ACM Transactions on Asian and Low-Resource Language Information Processing* 22.4 (2022), pp. 1–21. DOI: [10.1145/3578707](https://doi.org/10.1145/3578707).
- [42] Ei Ni Tar Tun, Yi Mon Shwe Sin, and Khin Mar Soe. "Exploring Bidirectional Mon-English Machine Translation with SMT, NMT and Fine-Tuned BART." In: *IAENG International Journal of Computer Science* 52.11 (2025).
- [43] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. "Attention is all you need." In: *Advances in neural information processing systems* 30 (2017).
- [44] Wikipédia. *Ruund — Wikipédia, l'encyclopédie libre*. [En ligne; Page disponible le 29 Mai 2026]. 2022. URL: <http://fr.wikipedia.org/w/index.php?title=Ruund&oldid=199251041>.

ANNEXE A

Contenu annexe.