



FACULTÉ DES SCIENCES INFORMATIQUES  
Intelligence Artificielle

---

**Approches de traduction automatique pour les langues à  
faibles ressources : application au ruund–français**

---

*Travail de fin d'études présenté et défendu en vue de l'obtention  
du grade de licencié en sciences informatiques.*

*Présenté par : Mununga Kayinda Eliezer*

juillet 2026



FACULTÉ DES SCIENCES INFORMATIQUES  
Intelligence Artificielle

---

## **Approches de traduction automatique pour les langues à faibles ressources : application au ruund–français**

---

*Travail de fin d'études présenté et défendu en vue de l'obtention  
du grade de licencié en sciences informatiques.*

*Présenté par : Mununga Kayinda Eliezer  
Dirigé par : Prof. Dr Selain Kasereka Kabunga  
Encadrant : C.T Godwill Ilunga Wa Kumwita*

juillet 2026

## DÉCLARATION SUR L'HONNEUR

---

Je soussigné, certifie sur l'honneur que le présent mémoire constitue un travail personnel, original et réalisé dans le cadre de mes études.

Je déclare que toutes les sources d'information, les données, les idées ainsi que les citations utilisées dans ce document ont été correctement identifiées et référencées conformément aux normes bibliographiques IEEE.

Je certifie également que :

- ce mémoire est un travail inédit qui n'a jamais été soumis, en tout ou en partie, pour l'obtention d'un autre diplôme ou titre académique ;
- il ne comporte aucun acte de plagiat ni aucune reproduction non autorisée d'une œuvre protégée par les droits d'auteur ;
- toutes les citations, qu'elles soient directes ou indirectes, ont été dûment signalées et référencées.

Fait à Lubumbashi, le 10 juillet 2026

Signature :

A handwritten signature in black ink, appearing to read 'Mununga', with a stylized flourish underneath.

Mununga Kayinda Eliezer

Believe in yourself...



## IN MEMORIAM

---

À la mémoire de mon père **Paul Mununga**,

Parti trop tôt, mais dont les valeurs, les conseils et l'amour continuent de guider chacun de mes pas. Ce travail est le fruit des enseignements et de l'héritage que tu m'as laissés.

Repose en paix.

1972 – 2020

Mununga Kayinda Eliezer

## REMERCIEMENTS

---

Au terme de ce travail, il m'est particulièrement agréable d'exprimer ma profonde gratitude à toutes les personnes qui, par leurs conseils, leur soutien et leurs encouragements, ont contribué à la réalisation de ce mémoire.

Mes sincères remerciements s'adressent en premier lieu au **Prof. Dr Selain Kasereka Kabunga**, Directeur de ce mémoire, pour avoir accepté de diriger ce travail. Sa disponibilité, la pertinence de ses orientations, ses remarques constructives ainsi que sa rigueur scientifique ont été d'une importance capitale tout au long de cette recherche.

J'exprime également ma profonde reconnaissance au **C.T Godwill Ilunga Wa Kumwita**, Co-directeur de ce mémoire, pour son accompagnement constant, sa patience, ses conseils avisés et son soutien tout au long de ce travail. Son encadrement a largement contribué à l'amélioration de la qualité scientifique de cette étude.

Je tiens également à remercier le **Professeur Michel Kasombo**, dont les connaissances en linguistique africaine et les précieux échanges ont permis d'enrichir cette recherche, en particulier sur les aspects linguistiques liés à la langue ruund.

Mes remerciements vont également à l'**Université Nouveaux Horizons**, qui m'a offert un cadre de formation propice à l'acquisition des connaissances et des compétences nécessaires à la réalisation de ce mémoire. Je remercie l'ensemble des autorités académiques, du corps enseignant et du personnel administratif pour leur engagement dans la formation des étudiants.

J'adresse une pensée toute particulière à ma mère, **Thotho Kabey**, dont l'amour, les sacrifices, les prières et le soutien indéfectible ont toujours été une source de motivation. Je lui suis profondément reconnaissant pour avoir toujours cru en moi et m'avoir encouragé à persévérer dans mes études.

Mes sincères remerciements vont également à ma sœur, **Eunice Kawanga**, pour son affection, ses encouragements et son soutien moral tout au long de ce parcours académique.

Je remercie tous les membres de ma famille, mes amis de **Ball is Life**, **Credo Kanumbedi** et toutes les personnes qui, de près ou de loin, ont apporté leur soutien, leurs conseils, leurs encouragements ou leur assistance d'une manière ou d'une autre à la réalisation de ce travail.

Mununga Kayinda Eliezer

## PUBLICATIONS

---

Certaines idées ont déjà été présentées dans la publication suivante :

*Godwill W.K. Ilunga, Selain K. Kasereka, **Eliezer Mununga**, Credo Kanumbedi,  
Onesime M. Mbulayi, Israel M.W. Mwamba, Rebecca Ryakitimbo, Tasho Tashev*

**Speech Dataset Creation in Low-Resource Contexts : A Systematic Review [22]**

The 17th International Conference on Ambient Systems, Networks and  
Technologies Networks (ANT)/ the 9th International Conference on Emerging Data  
and Industry 4.0 (EDI40)

Licence CC BY-NC-ND 4.0

## LISTE DES ABRÉVIATIONS ET ACRONYMES

---

|               |                                                                           |
|---------------|---------------------------------------------------------------------------|
| ACM           | <i>Association for Computing Machinery</i>                                |
| BLEU          | <i>Bilingual Evaluation Understudy</i>                                    |
| BPE           | <i>Byte Pair Encoding</i>                                                 |
| chrF          | <i>Character n-gram F-score</i>                                           |
| DL            | <i>Deep Learning</i>                                                      |
| GPU           | <i>Graphics Processing Units</i>                                          |
| IA            | <i>Intelligence Artificielle</i>                                          |
| IEEE          | <i>Institute of Electrical and Electronics Engineers</i>                  |
| LFR           | <i>Langues à Faibles Ressources</i>                                       |
| MarianMT      | <i>Marian Machine Translation</i>                                         |
| mBART         | <i>Multilingual Bidirectional and Auto-Regressive Transformer</i>         |
| ML            | <i>Machine Learning</i>                                                   |
| MNMT          | <i>Multilingual Neural Machine Translation</i>                            |
| NFC           | <i>Normalization Form Canonical Composition</i>                           |
| NLLB          | <i>No Language Left Behind</i>                                            |
| NLP           | <i>Natural Language Processing</i>                                        |
| NMT           | <i>Neural Machine Translation</i>                                         |
| OCR           | <i>Optical Character Recognition</i>                                      |
| OOV           | <i>Out Of Vocabulary</i>                                                  |
| PBSMT         | <i>Phrase-Based Statistical Machine Translation</i>                       |
| PRISMA        | <i>Preferred Reporting Items for Systematic Reviews and Meta-Analyses</i> |
| RBMT          | <i>Rule-Based Machine Translation</i>                                     |
| RDC           | <i>République Démocratique du Congo</i>                                   |
| RNA           | <i>Réseaux de Neurones Artificiels</i>                                    |
| RNN           | <i>Recurrent Neural Network</i>                                           |
| SentencePiece | <i>SentencePiece Tokenizer</i>                                            |
| SMT           | <i>Statistical Machine Translation</i>                                    |
| TA            | <i>Traduction Automatique</i>                                             |
| TAB           | <i>Traduction Automatique Basée sur des Règles</i>                        |
| TAL           | <i>Traitement Automatique des Langues</i>                                 |
| TAN           | <i>Traduction Automatique Neuronale</i>                                   |
| TAS           | <i>Traduction Automatique Statistique</i>                                 |

## TABLE DES FIGURES

|            |                                                                      |    |
|------------|----------------------------------------------------------------------|----|
| Figure 1.1 | Diagramme PRISMA du processus de sélection des études [39] . . . . . | 6  |
| Figure 1.2 | L'Encodeur-Décodeur . . . . .                                        | 12 |
| Figure 1.3 | Architecture Transformer . . . . .                                   | 14 |
| Figure 1.4 | Répartition des langues selon leurs ressources en NLP . . . . .      | 21 |
| Figure 2.1 | Pipeline de construction du corpus . . . . .                         | 30 |
| Figure 2.2 | Pipeline de numérisation de données . . . . .                        | 32 |
| Figure 2.3 | Pipeline d'alignement de textes . . . . .                            | 34 |
| Figure 2.4 | Statistiques descriptives du corpus OpenRuund . . . . .              | 35 |
| Figure 3.1 | Pipeline global du système de traduction automatique . . . . .       | 37 |
| Figure 3.2 | Pipeline de fine-tuning . . . . .                                    | 45 |
| Figure 3.3 | Architecture générale de l'application . . . . .                     | 46 |
| Figure 4.1 | Performances des modèles selon les scores BLEU et chrF . . . . .     | 49 |
| Figure 4.2 | Courbes d'entraînement NLLB-200-distilled-600M - Français → Ruund    | 50 |
| Figure 4.3 | Courbes d'entraînement NLLB-200-distilled-600M - Ruund → Français    | 50 |
| Figure 4.4 | Courbes d'entraînement mBART-50 - Français → Ruund . . . . .         | 51 |
| Figure 4.5 | Courbes d'entraînement mBART-50 - Ruund → Français . . . . .         | 51 |
| Figure 4.6 | Courbes d'entraînement MarianMT - Français → Ruund . . . . .         | 52 |
| Figure 4.7 | Courbes d'entraînement MarianMT - Ruund → Français . . . . .         | 52 |
| Figure A.1 | Exemple d'une page scannée du Manswik Masu . . . . .                 | 71 |
| Figure A.2 | Page d'accueil de l'application Web . . . . .                        | 72 |
| Figure A.3 | Page de traduction de l'application Web . . . . .                    | 72 |
| Figure A.4 | Page de contribution de l'application Web . . . . .                  | 73 |
| Figure A.5 | Page de collecte d'audios de l'application Web . . . . .             | 73 |
| Figure A.6 | Page d'ajout d'une phrase de l'application Web . . . . .             | 74 |

## LISTE DES TABLEAUX

---

|          |                                                                                                                                                                            |    |
|----------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Table 1  | Critères d’inclusion et d’exclusion des études sélectionnées . . . . .                                                                                                     | 5  |
| Table 2  | Comparaison des approches de traduction automatique . . . . .                                                                                                              | 11 |
| Table 3  | Comparaison des modèles multilingues de traduction automatique . . .                                                                                                       | 16 |
| Table 4  | Synthèse comparative des travaux existants sur la TAN pour les langues<br>à faibles ressources . . . . .                                                                   | 28 |
| Table 5  | Sources et méthodes de collecte des données du corpus . . . . .                                                                                                            | 31 |
| Table 6  | Exemples d’erreurs produites par l’OCR et corrections appliquées . . .                                                                                                     | 33 |
| Table 7  | Exemples de paires de phrases alignées d’OpenRuund . . . . .                                                                                                               | 35 |
| Table 8  | Répartition du corpus tokenisé en ensembles d’entraînement, valida-<br>tion et test . . . . .                                                                              | 40 |
| Table 9  | Stratégies de tokenisation appliquées aux modèles de traduction . . . .                                                                                                    | 41 |
| Table 10 | Grille des hyperparamètres explorée lors de la recherche par grille . . .                                                                                                  | 42 |
| Table 11 | Exemple de traduction de textes variés, principalement hors contexte<br>religieux, tout en incluant quelques extraits du domaine religieux, sur<br>les 3 modèles . . . . . | 53 |
| Table 12 | Exemple de traduction de textes religieux, sur les 3 modèles . . . . .                                                                                                     | 55 |
| Table 13 | Résultats préliminaires de l’évaluation humaine (en cours) . . . . .                                                                                                       | 57 |

## RÉSUMÉ

---

Les progrès récents de la traduction automatique neuronale ont considérablement amélioré la qualité des systèmes de traduction. Cette amélioration profite surtout aux langues disposant d'importantes ressources linguistiques. Les langues à faibles ressources, telles que le ruund, restent en revanche peu prises en compte. Ce manque s'explique par l'absence de corpus parallèles et de ressources numériques. Ce mémoire s'inscrit dans cette problématique. Il vise à étudier les approches de traduction automatique adaptées aux langues à faibles ressources. Pour cela, un système de traduction neuronale a été développé pour le couple ruund–français.

Pour répondre à ce défi, un corpus parallèle a été constitué : **OpenRuund**. Il a été construit à partir de textes du Nouveau Testament et de textes poétiques, pour un total de 8 431 paires de phrases. Les données ont d'abord été numérisées, puis traitées par reconnaissance optique de caractères. Elles ont ensuite été nettoyées, normalisées et alignées. Trois modèles de traduction neuronale ont été adaptés par *fine-tuning* : mBART-50, MarianMT et NLLB-200-distilled-600M. Les performances ont été évaluées à l'aide des métriques BLEU et chrF. Cette évaluation automatique a été complétée par une évaluation humaine, menée par des locuteurs natifs du ruund et un spécialiste en linguistique africaine.

Les résultats montrent que les modèles préentraînés peuvent produire des traductions pertinentes malgré le faible volume de données disponibles. Le modèle NLLB-200-distilled-600M obtient les meilleurs résultats dans les deux sens de traduction. Pour la traduction français→ruund, il atteint un score BLEU de 38.82 et un score chrF de 58.10. Pour la traduction ruund→français, il atteint un score BLEU de 24.11 et un score chrF de 54.80. Ce modèle a été intégré dans une application web. Cette application comprend également un module de collecte collaborative de données textuelles et vocales. L'ensemble des ressources produites, corpus et modèles, a été rendu disponible. Cette diffusion vise à favoriser la réutilisation scientifique et à contribuer au développement du traitement automatique des langues pour le ruund. À notre connaissance, ce travail constitue une première pour le ruund : le premier système de traduction automatique neuronale et le premier corpus parallèle rendus publiquement disponibles pour cette langue.

**Mots-clés :** Traduction Automatique Neuronale, Langues à Faibles Ressources, Ruund, Corpus Parallèle, Transformer, Fine-tuning, mBART-50, MarianMT, NLLB-200-distilled-600M, Traitement Automatique des Langues.



## ABSTRACT

---

Recent advances in neural machine translation have substantially improved translation quality. This improvement mostly benefits high-resource languages. Low-resource languages such as Ruund remain largely underrepresented. This gap is due to the scarcity of parallel corpora and digital language resources. This thesis addresses this gap. It investigates machine translation approaches tailored to low-resource settings. To this end, a neural translation system was developed for the Ruund-French language pair.

To tackle this challenge, a parallel corpus was compiled : **OpenRuund**. It was built from New Testament texts and poetic texts, yielding a total of 8 431 sentence pairs. After digitization and optical character recognition, the data were cleaned, normalized, and aligned. Three neural translation models were adapted to Ruund through *fine-tuning* : mBART-50, MarianMT, and NLLB-200-distilled-600M. Performance was assessed using BLEU and chrF metrics. This automatic assessment was complemented by human evaluation, conducted by native Ruund speakers and a specialist in African linguistics.

The results show that pretrained models can produce meaningful translations despite the limited amount of training data. NLLB-200-distilled-600M achieved the best overall performance in both translation directions. For French→Ruund translation, it obtained a BLEU score of 38.82 and a chrF score of 58.10. For Ruund→French translation, it obtained a BLEU score of 24.11 and a chrF score of 54.80. This model was integrated into a web application. The application also includes a collaborative module for collecting textual and spoken data. All produced resources, including the corpus and trained models, were released. This release supports scientific reuse and contributes to the development of natural language processing tools for Ruund. To our knowledge, this work constitutes a first for Ruund : the first publicly available neural machine translation system and the first publicly available parallel corpus for this language.

**Keywords :** Neural Machine Translation, Low-Resource Languages, Ruund, Parallel Corpus, Transformer, Fine-tuning, mBART-50, MarianMT, NLLB-200-distilled-600M, Natural Language Processing.

## TABLE DES MATIÈRES

|                                                              |           |
|--------------------------------------------------------------|-----------|
| Déclaration sur l'honneur                                    | iii       |
| Épigraphe                                                    | iv        |
| In Memoriam                                                  | v         |
| Remerciements                                                | vi        |
| Publications                                                 | vi        |
| Liste des abréviations et acronymes                          | viii      |
| Résumé                                                       | xi        |
| Abstract                                                     | xiii      |
| <b>0 INTRODUCTION GÉNÉRALE</b>                               | <b>1</b>  |
| 0.1 Contexte de l'étude                                      | 1         |
| 0.2 Problématique                                            | 1         |
| 0.3 Objectifs du mémoire                                     | 2         |
| 0.3.1 Objectif général                                       | 2         |
| 0.3.2 Objectifs spécifiques                                  | 2         |
| 0.4 Hypothèses de recherche                                  | 3         |
| 0.5 Contributions du mémoire                                 | 3         |
| 0.6 Organisation du mémoire                                  | 3         |
| <b>1 REVUE DE LITTÉRATURE</b>                                | <b>4</b>  |
| 1.1 Introduction                                             | 4         |
| 1.2 Méthodologie de la revue de littérature                  | 4         |
| 1.3 Fondements théoriques                                    | 6         |
| 1.3.1 Intelligence artificielle                              | 6         |
| 1.3.2 Machine Learning                                       | 7         |
| 1.3.3 Deep Learning                                          | 8         |
| 1.3.4 Traitement automatique des langues naturelles          | 8         |
| 1.3.5 Traduction automatique                                 | 9         |
| 1.3.6 Traduction automatique neuronale                       | 11        |
| 1.3.7 Architectures Transformer                              | 13        |
| 1.3.8 Modèles multilingues de traduction                     | 15        |
| 1.3.9 Entraînement et adaptation des modèles neuronaux       | 17        |
| 1.3.10 Tokenisation et représentations linguistiques         | 18        |
| 1.3.11 Corpus parallèles                                     | 19        |
| 1.4 Domaine linguistique et langues à faibles ressources     | 20        |
| 1.4.1 Langues à faibles ressources                           | 20        |
| 1.4.2 Défis du TAL pour les langues africaines               | 22        |
| 1.4.3 Présentation linguistique du ruund                     | 22        |
| 1.4.4 Préservation linguistique et intelligence artificielle | 24        |
| 1.5 Analyse des travaux existants                            | 24        |
| 1.5.1 Évolution des approches de traduction automatique      | 24        |
| 1.5.2 Travaux sur les langues à faibles ressources           | 25        |
| 1.5.3 Analyse critique des travaux existants                 | 26        |
| 1.5.4 Gap scientifique et positionnement du mémoire          | 28        |
| <b>2 CONSTRUCTION DU CORPUS PARALLÈLE RUUND-FRANÇAIS</b>     | <b>30</b> |

|       |                                                                     |    |
|-------|---------------------------------------------------------------------|----|
| 2.1   | Introduction . . . . .                                              | 30 |
| 2.2   | Présentation générale du corpus . . . . .                           | 30 |
| 2.2.1 | Objectif de la construction du corpus . . . . .                     | 30 |
| 2.2.2 | Description générale du corpus . . . . .                            | 31 |
| 2.3   | Collecte des données . . . . .                                      | 31 |
| 2.4   | Numérisation et extraction des données . . . . .                    | 31 |
| 2.4.1 | Processus de numérisation . . . . .                                 | 31 |
| 2.4.2 | Reconnaissance optique de caractères . . . . .                      | 32 |
| 2.4.3 | Difficultés rencontrées et corrections . . . . .                    | 32 |
| 2.4.4 | Extraction des données françaises par <i>web scraping</i> . . . . . | 33 |
| 2.5   | Construction du corpus parallèle . . . . .                          | 33 |
| 2.5.1 | Segmentation des textes . . . . .                                   | 33 |
| 2.5.2 | Alignement automatique . . . . .                                    | 34 |
| 2.5.3 | Correction manuelle des alignements . . . . .                       | 34 |
| 2.5.4 | Validation du corpus parallèle . . . . .                            | 34 |
| 2.6   | Analyse descriptive du corpus . . . . .                             | 35 |
| 2.7   | Défis et limites de la construction du corpus . . . . .             | 35 |
| 2.7.1 | Défis liés à la collecte . . . . .                                  | 35 |
| 2.7.2 | Défis liés à l'OCR . . . . .                                        | 36 |
| 2.7.3 | Défis liés à l'alignement . . . . .                                 | 36 |
| 2.7.4 | Limites du corpus obtenu . . . . .                                  | 36 |
| 3     | DÉVELOPPEMENT DU SYSTÈME DE TRADUCTION AUTOMATIQUE . . . . .        | 37 |
| 3.1   | Introduction . . . . .                                              | 37 |
| 3.2   | Préparation des données pour l'entraînement . . . . .               | 38 |
| 3.2.1 | Objectifs du prétraitement . . . . .                                | 38 |
| 3.2.2 | Normalisation des textes . . . . .                                  | 38 |
| 3.2.3 | Filtrage du corpus . . . . .                                        | 39 |
| 3.2.4 | Constitution des ensembles d'apprentissage . . . . .                | 40 |
| 3.3   | Tokenisation et préparation linguistique . . . . .                  | 40 |
| 3.3.1 | Segmentation en sous-mots avec SentencePiece . . . . .              | 40 |
| 3.3.2 | Gestion des mots hors vocabulaire . . . . .                         | 41 |
| 3.3.3 | Préparation des séquences d'entrée et de sortie . . . . .           | 41 |
| 3.3.4 | Configuration des hyperparamètres . . . . .                         | 42 |
| 3.3.5 | Environnement expérimental . . . . .                                | 43 |
| 3.4   | Entraînement des modèles (fine-tuning) . . . . .                    | 43 |
| 3.4.1 | Principe de l'arrêt anticipé . . . . .                              | 43 |
| 3.4.2 | Configuration de l'entraînement final . . . . .                     | 44 |
| 3.5   | Évaluation des modèles . . . . .                                    | 44 |
| 3.5.1 | Méthodologie d'évaluation . . . . .                                 | 44 |
| 3.5.2 | Génération des traductions . . . . .                                | 44 |
| 3.5.3 | Métriques d'évaluation . . . . .                                    | 44 |
| 3.6   | Déploiement du système de traduction . . . . .                      | 46 |
| 3.6.1 | Publication des modèles sur Hugging Face . . . . .                  | 46 |
| 3.6.2 | Architecture générale de l'application . . . . .                    | 46 |
| 3.6.3 | Intégration des modèles dans Django . . . . .                       | 46 |
| 3.6.4 | Fonctionnement du système de traduction . . . . .                   | 47 |
| 4     | RÉSULTATS ET DISCUSSION . . . . .                                   | 48 |
| 4.1   | Introduction . . . . .                                              | 48 |
| 4.2   | Résultats quantitatifs . . . . .                                    | 48 |

|       |                                                                 |    |
|-------|-----------------------------------------------------------------|----|
| 4.2.1 | Présentation des résultats des métriques automatiques . . . . . | 48 |
| 4.2.2 | Analyse comparative des performances des modèles . . . . .      | 49 |
| 4.2.3 | Analyse de la convergence des modèles . . . . .                 | 50 |
| 4.3   | Évaluation qualitative des traductions . . . . .                | 52 |
| 4.3.1 | Analyse d'exemples de traduction . . . . .                      | 52 |
| 4.3.2 | Évaluation humaine . . . . .                                    | 56 |
| 4.4   | Discussion des résultats . . . . .                              | 57 |
| 4.4.1 | Influence du corpus parallèle . . . . .                         | 57 |
| 4.4.2 | Influence des architectures des modèles . . . . .               | 58 |
| 4.4.3 | Analyse des erreurs . . . . .                                   | 58 |
| 4.5   | Validation du système développé . . . . .                       | 59 |
| 4.6   | Conclusion partielle . . . . .                                  | 60 |
| 5     | CONCLUSION GÉNÉRALE                                             | 61 |
| A     | ANNEXES                                                         | 64 |



## INTRODUCTION GÉNÉRALE

---

Ce chapitre présente le contexte général de l'étude. Il expose la problématique, les objectifs du mémoire, les hypothèses de recherche, les contributions du travail ainsi que l'organisation générale du mémoire.

### 0.1 CONTEXTE DE L'ÉTUDE

La traduction automatique constitue aujourd'hui un domaine majeur du *Traitement Automatique des Langues* (TAL). Les progrès récents de l'intelligence artificielle ont transformé ce domaine. Ceux liés à l'apprentissage profond et aux architectures Transformer [48] ont notamment permis le développement de systèmes de traduction automatique neuronale. Ces systèmes produisent des traductions de haute qualité pour plusieurs langues disposant d'importantes ressources numériques [40].

Ces avancées concernent cependant principalement les langues dites à **fortes ressources**, telles que l'anglais, le français ou le chinois. Pour ces langues, de très grands volumes de données parallèles sont disponibles. À l'inverse, un grand nombre de langues africaines demeurent peu présentes dans les technologies linguistiques modernes, faute de ressources numériques exploitables [2, 40]. Ces langues sont généralement qualifiées de *Langues à Faibles Ressources* (LFR).

Parmi ces langues figure le **ruund**, une langue bantoue parlée principalement en *République Démocratique du Congo* (RDC) et en Angola. Cette langue reste très peu exploitée dans le domaine du traitement automatique des langues, malgré son importance culturelle et sociale. Les ressources numériques disponibles pour le ruund sont rares, peu structurées et souvent non numérisées, à l'instar d'autres langues à faibles ressources telles que le mizo [20] ou le pendjabi [23]. Cette situation limite fortement le développement d'outils intelligents tels que les systèmes de traduction automatique.

Dans ce contexte, les approches modernes basées sur les modèles neuronaux multilingues pré-entraînés offrent de nouvelles perspectives. Elles permettent le développement de systèmes de traduction adaptés aux langues à faibles ressources [28, 29]. Ces modèles transfèrent des connaissances acquises sur plusieurs langues. Ce transfert améliore les performances de traduction, même lorsque les données disponibles sont limitées [34, 38].

Le présent mémoire s'inscrit dans cette dynamique. Il porte sur les **approches de traduction automatique pour les langues à faibles ressources**, avec une application particulière au couple **ruund-français**.

### 0.2 PROBLÉMATIQUE

Le développement des systèmes modernes de traduction automatique repose principalement sur la disponibilité de grands volumes de données parallèles. Ces données permettent

l'apprentissage des correspondances linguistiques entre la langue source et la langue cible [40]. Pour les langues à faibles ressources telles que le ruund, ces données sont toutefois extrêmement limitées. Ce manque constitue un obstacle majeur à l'entraînement de modèles neuronaux performants [2, 20].

Plusieurs facteurs rendent difficile le développement d'un système de traduction automatique fiable pour le ruund. Il s'agit notamment de l'absence de jeux de données parallèles structurés, du manque de ressources linguistiques numériques et de la faible disponibilité des travaux de recherche dédiés à cette langue [20, 23]. Les spécificités morphologiques et syntaxiques des langues bantoues augmentent en outre la complexité du problème.

Face à cette situation, plusieurs interrogations scientifiques se posent :

- Comment construire un dataset parallèle ruund–français exploitable pour l'apprentissage automatique ?
- Quelles techniques de prétraitement et d'alignement peuvent être utilisées pour améliorer la qualité des données ?
- Dans quelle mesure les modèles multilingues pré-entraînés peuvent-ils améliorer les performances de traduction dans un contexte à faibles ressources ?
- Quelles performances peuvent être obtenues avec une quantité limitée de données parallèles ?

La problématique principale de ce mémoire consiste donc à étudier comment développer un système de traduction automatique neuronale capable de produire des traductions exploitables entre le ruund et le français, malgré la rareté des ressources linguistiques disponibles.

### 0.3 OBJECTIFS DU MÉMOIRE

#### 0.3.1 *Objectif général*

L'objectif général de ce mémoire est de concevoir et d'évaluer un système de traduction automatique du ruund vers le français adapté au contexte des langues à faibles ressources.

#### 0.3.2 *Objectifs spécifiques*

Plus spécifiquement, il s'agit de :

- Étudier les approches modernes de traduction automatique adaptées aux langues à faibles ressources ;
- Construire un dataset parallèle ruund–français à partir de ressources textuelles disponibles ;
- Effectuer le prétraitement, le nettoyage et l'alignement des données collectées ;
- Expérimenter différents modèles de traduction automatique neuronale, notamment les modèles multilingues pré-entraînés ;
- Évaluer les performances des modèles entraînés à l'aide de métriques adaptées ;
- Développer une application intégrant le modèle de traduction ainsi qu'un système de collecte de données textuelles et vocales.

## 0.4 HYPOTHÈSES DE RECHERCHE

Ce travail repose sur les hypothèses suivantes :

- La construction d'un dataset parallèle ruund-français de qualité peut améliorer significativement les performances de traduction automatique ;
- Les modèles multilingues pré-entraînés permettent de compenser partiellement le manque de ressources linguistiques disponibles ;
- L'utilisation des techniques modernes de traduction automatique neuronale peut produire des résultats exploitables même dans un contexte de faible disponibilité des données .

## 0.5 CONTRIBUTIONS DU MÉMOIRE

Les objectifs précédents décrivent la démarche suivie. Les contributions ci-dessous présentent ce que cette démarche a effectivement produit :

- Un dataset parallèle ruund-français, réutilisable pour de futurs travaux ;
- Des résultats d'expérimentation comparant plusieurs approches modernes de traduction automatique neuronale sur une langue à faibles ressources ;
- Une évaluation comparée de plusieurs modèles de traduction, combinant métriques automatiques et jugement humain ;
- Une application de collecte de données linguistiques intégrant un système de traduction automatique.

## 0.6 ORGANISATION DU MÉMOIRE

Le présent mémoire est organisé en cinq chapitres.

Le premier chapitre est consacré à la revue de littérature. Il présente les fondements théoriques de la traduction automatique neuronale, les spécificités des langues à faibles ressources et les caractéristiques linguistiques du ruund. Il propose aussi une analyse critique des travaux existants en lien avec cette étude.

Le deuxième chapitre décrit le processus de construction du corpus parallèle ruund-français. Il détaille les différentes étapes de collecte, de numérisation, d'alignement, de validation et de préparation des données utilisées pour l'entraînement des modèles.

Le troisième chapitre présente le développement du système de traduction automatique. Il expose les méthodes de prétraitement, le choix des modèles multilingues et leur adaptation par fine-tuning. Il décrit également le processus d'entraînement et d'évaluation.

Le quatrième chapitre est consacré à la présentation et à l'analyse des résultats expérimentaux. Il compare les performances des différents modèles à l'aide de métriques automatiques et d'une évaluation humaine, avant de discuter les principaux résultats obtenus.

Enfin, le cinquième chapitre présente la conclusion générale du mémoire. Il résume les principales contributions de cette étude, met en évidence ses limites et propose des perspectives pour les travaux futurs.



## REVUE DE LITTÉRATURE

---

### 1.1 INTRODUCTION

L'intelligence artificielle connaît une évolution rapide. Elle transforme profondément plusieurs domaines technologiques, notamment le traitement automatique des langues naturelles. Grâce aux avancées du *machine learning* et du *deep learning*, les systèmes informatiques sont désormais capables d'analyser, de comprendre et de générer du langage humain, avec une efficacité croissante.

Le **TAL** constitue aujourd'hui un domaine central de l'intelligence artificielle. Parmi ses principales applications figure la traduction automatique. Celle-ci a évolué des approches basées sur des règles vers des modèles neuronaux utilisant les architectures **Transformer**<sup>1</sup> [48]. Ces modèles offrent des performances élevées, mais nécessitent généralement de grandes quantités de données linguistiques [40].

Les **LFR** demeurent cependant insuffisamment représentées dans les technologies numériques modernes [40]. Cette problématique est particulièrement visible dans le contexte africain. De nombreuses langues locales y disposent de peu de corpus numériques et d'outils linguistiques adaptés [2]. Le **ruund** fait partie de ces langues sous-représentées, ce qui limite son intégration dans les systèmes de traduction automatique [20].

Ce chapitre présente les fondements théoriques liés à l'intelligence artificielle, au **TAL** et à la *Traduction Automatique Neuronale* (**TAN**). Il aborde également les problématiques des **LFR**, le contexte linguistique africain ainsi que les travaux existants, afin de justifier l'intérêt scientifique de cette recherche sur la traduction automatique ruund-français.

### 1.2 MÉTHODOLOGIE DE LA REVUE DE LITTÉRATURE

#### *Protocole de recherche documentaire*

Cette revue de littérature a été réalisée selon une démarche systématique, inspirée des recommandations *Preferred Reporting Items for Systematic Reviews and Meta-Analyses* (**PRISMA**). Les recherches bibliographiques ont été effectuées dans 4 bases de données scientifiques : Scopus, *Association for Computing Machinery* (**ACM**), *Institute of Electrical and Electronics Engineers* (**IEEE**) et Google Scholar.

Les requêtes de recherche ont été construites autour de quatre axes principaux :

- la traduction automatique neuronale ;
- les langues à faibles ressources ;
- la construction et le prétraitement des corpus parallèles ;
- les modèles multilingues et les méthodes d'évaluation.

---

1. Transformer est un outil d'IA qui traduit des textes en analysant tous les mots d'une phrase en même temps. Cela permet de comprendre le sens général et de proposer une traduction très naturelle

Les mots-clés utilisés incluait notamment *machine translation*, *neural machine translation*, *low-resource languages*, *parallel dataset*, *sentence alignment*, *subword segmentation*, *multilingual models*, *transfer learning*, *Transformer* et *BLEU score*.

La requête de recherche de base, élaborée à partir de ces mots-clés, est présentée ci-dessous. Elle a ensuite été adaptée aux spécificités des différentes bases de données consultées :

```
("machine translation" OR "neural machine translation")
AND ("low-resource language" OR "under-resourced language")
AND ("parallel dataset" OR "dataset construction" OR "sentence alignment"
OR "preprocessing")
AND ("Transformer" OR "multilingual" OR "transfer learning" OR "evaluation"
OR "BLEU")
```

#### *Critères d'inclusion et d'exclusion*

Les études ont été sélectionnées selon des critères prédéfinis, afin de garantir leur pertinence par rapport aux objectifs de cette recherche. Le Tableau 1 présente l'ensemble des critères appliqués lors du processus de sélection.

| Critères d'inclusion                                                                                                     | Critères d'exclusion                                                  |
|--------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------|
| Traduction automatique neuronale pour les langues à faibles ressources                                                   | Reconnaissance automatique de la parole ( <i>Speech Recognition</i> ) |
| Construction de corpus parallèles                                                                                        | Classification de textes                                              |
| Alignement de phrases                                                                                                    | Analyse de sentiments                                                 |
| Prétraitement des données                                                                                                | Recherche d'information ( <i>Information Retrieval</i> )              |
| Segmentation en sous-mots ( <i>Byte Pair Encoding (BPE)</i> , <i>SentencePiece Tokenizer (SentencePiece)</i> )           | Enquêtes ( <i>surveys</i> )                                           |
| Modèles multilingues                                                                                                     | Revue de littérature ou études de synthèse                            |
| Apprentissage par transfert ( <i>Transfer Learning</i> )                                                                 |                                                                       |
| Métriques d'évaluation telles que <i>Bilingual Evaluation Understudy (BLEU)</i> , <i>Character n-gram F-score (chrF)</i> |                                                                       |
| Développement de prototypes de traduction automatique                                                                    |                                                                       |

TABLE 1 – Critères d'inclusion et d'exclusion des études sélectionnées

### Processus de sélection des études

La sélection des publications a été réalisée en plusieurs étapes. Les doublons ont d'abord été supprimés, après l'identification initiale des documents dans les différentes bases de données. Les titres et résumés ont ensuite été examinés, afin d'évaluer leur pertinence au regard des critères d'inclusion et d'exclusion. Les articles retenus ont finalement fait l'objet d'une lecture intégrale, avant leur inclusion dans l'analyse finale.

Le processus complet de sélection des études est présenté dans le diagramme PRISMA ci-dessous.




FIGURE 1.1 – Diagramme PRISMA du processus de sélection des études [39]

## 1.3 FONDEMENTS THÉORIQUES

### 1.3.1 Intelligence artificielle

#### Définition et évolution de l'intelligence artificielle

L'**Intelligence Artificielle (IA)** désigne un ensemble de méthodes et de techniques permettant à une machine de reproduire certaines capacités cognitives humaines, telles que l'apprentissage, le raisonnement, la résolution de problèmes ou la prise de décision. Ce domaine de recherche vise principalement à concevoir des systèmes capables d'exécuter automatiquement des tâches nécessitant normalement l'intelligence humaine [17].

L'évolution des capacités de calcul, la disponibilité massive des données numériques ainsi que les progrès des réseaux de neurones ont favorisé l'émergence du *machine learning*, puis

du *deep learning* [17]. Ces approches permettent aux systèmes informatiques d'apprendre automatiquement des représentations complexes à partir des données. Elles améliorent ainsi considérablement les performances dans plusieurs domaines, tels que la vision par ordinateur, la reconnaissance vocale et le traitement automatique des langues [40].

### *IA et traitement automatique des langues*

Le TAL applique les méthodes de l'IA au langage humain : l'analyse, la compréhension et la génération de texte par les machines. Cette branche combine des connaissances issues de l'informatique, de la linguistique et de l'apprentissage automatique [40]. Une définition plus détaillée de ce domaine, ainsi que de ses principales applications, est proposée en section 1.3.4.

Les progrès récents du *deep learning* et des architectures **Transformer** ont considérablement amélioré les performances des systèmes *Natural Language Processing* (NLP), en particulier dans les tâches de TAN (**Neural Machine Translation** (NMT)) [3, 40, 48].

#### 1.3.2 Machine Learning

##### *Définition du Machine Learning*

Le *Machine Learning* (ML) constitue une branche de l'intelligence artificielle. Il permet aux systèmes informatiques d'apprendre automatiquement à partir des données, sans être explicitement programmés pour chaque tâche [17]. Son objectif principal est de construire des modèles capables d'identifier des relations, des régularités ou des représentations à partir des données, afin d'effectuer des prédictions ou des décisions automatiques [17].

##### *Types d'apprentissage*

Le ML regroupe principalement trois grandes catégories d'apprentissage : l'apprentissage supervisé, l'apprentissage non supervisé et l'apprentissage par renforcement [17].

**L'APPRENTISSAGE SUPERVISÉ :** repose sur l'utilisation de données annotées, contenant des exemples d'entrée et de sortie. Le modèle apprend alors à établir une relation entre les données d'entrée et les résultats attendus, afin de prédire correctement de nouvelles données [17]. Cette approche est largement utilisée dans les tâches de classification, de régression et de traduction automatique [40].

##### *Apprentissage supervisé dans la traduction automatique*

La **traduction automatique neuronale** (TAN) repose principalement sur l'apprentissage supervisé. Dans cette approche, le modèle est entraîné à partir de **corpus parallèles**, contenant des phrases dans une langue source et leurs traductions correspondantes dans une langue cible [20, 23, 40].

### 1.3.3 Deep Learning

#### *Réseaux de neurones artificiels*

Les **Réseaux de Neurones Artificiels (RNA)** sont des modèles informatiques inspirés du fonctionnement biologique du cerveau humain [17]. Ils sont composés d'unités appelées **neurones artificiels**, organisées en différentes couches interconnectées. Chaque neurone reçoit des données en entrée, effectue des calculs mathématiques, puis transmet un résultat à la couche suivante [17].

#### *Réseaux neuronaux profonds*

Le **Deep Learning (DL)** correspond à une évolution des réseaux de neurones artificiels, utilisant plusieurs couches cachées. Ces architectures profondes permettent d'apprendre des représentations hiérarchiques et complexes des données. Elles améliorent ainsi considérablement les performances des modèles d'intelligence artificielle [17].

Les réseaux neuronaux profonds ont connu un développement important, grâce à l'augmentation de la puissance de calcul, à la disponibilité des données massives et aux progrès des processeurs graphiques [17]. Ils sont aujourd'hui utilisés dans plusieurs domaines, tels que la vision par ordinateur, la reconnaissance vocale et le traitement automatique des langues [40].

#### *Importance du Deep Learning dans le NLP*

Le DL a profondément transformé le traitement automatique des langues naturelles. Contrairement aux approches traditionnelles, basées sur des règles linguistiques ou des caractéristiques manuellement définies, les modèles profonds apprennent automatiquement les représentations linguistiques à partir des données [17, 40].

Cette évolution a permis l'apparition de modèles neuronaux performants, capables de traiter des tâches complexes telles que la **Traduction Automatique (TA)**, la génération de texte, les agents conversationnels et l'analyse sémantique [3, 40]. Les architectures modernes comme les **Transformers** ont particulièrement amélioré la qualité des systèmes NLP, en facilitant la prise en compte du contexte linguistique [48].

### 1.3.4 Traitement automatique des langues naturelles

#### *Définition du TAL*

Le traitement automatique des langues naturelles (*Natural Language Processing, NLP*) est la branche de l'intelligence artificielle consacrée à l'analyse, à la compréhension et à la génération automatique du langage humain par les machines. Comme indiqué en introduction de ce chapitre, ce domaine associe informatique, linguistique et apprentissage automatique [40].

Le TAL vise principalement à faciliter l'interaction entre l'homme et la machine, à travers le traitement des données textuelles et vocales. Les avancées récentes du DL ont fortement amélioré les capacités des systèmes NLP dans plusieurs tâches linguistiques complexes [48].

### *Principales applications du TAL*

Le TAL possède de nombreuses applications dans les technologies numériques modernes. Outre la traduction automatique, déjà évoquée, ses usages recouvrent la reconnaissance vocale, les assistants conversationnels, l'analyse de sentiments ainsi que les systèmes de recherche d'information [40].

### *TAL et langues africaines*

Malgré les progrès importants du TAL, plusieurs langues africaines demeurent faiblement représentées dans les ressources numériques et les systèmes NLP modernes. Cette situation s'explique notamment par le manque de corpus numériques, l'absence de standardisation linguistique et la rareté des outils de traitement adaptés [2].

Les **langues africaines à faibles ressources** rencontrent ainsi des difficultés importantes dans le développement d'applications telles que la **traduction automatique neuronale**. Le manque de données parallèles limite l'entraînement efficace des modèles de DL, ce qui réduit les performances des systèmes développés pour ces langues [35].

#### 1.3.5 Traduction automatique

##### *Définition de la traduction automatique*

La **traduction automatique (TA)** désigne l'utilisation de systèmes informatiques capables de traduire automatiquement un texte d'une langue source vers une langue cible, sans intervention humaine directe. Elle constitue l'une des principales applications du traitement automatique des langues naturelles [40].

L'objectif de la TA est de produire des traductions grammaticalement correctes et sémantiquement cohérentes, tout en conservant le sens du texte original. Les performances des systèmes de traduction ont considérablement évolué, grâce aux progrès du ML et du DL [48].

##### *Traduction Automatique Basée sur des Règles (TAB)*

Les premiers systèmes de traduction automatique reposaient principalement sur des approches basées sur des règles linguistiques (*Rule-Based Machine Translation (RBMT)*). Ces systèmes utilisaient des dictionnaires bilingues ainsi que des règles grammaticales définies manuellement par des experts linguistes [40].

Cette approche nécessitait une importante expertise linguistique et un travail manuel considérable pour chaque paire de langues. Elle permettait un certain contrôle linguistique, mais présentait des difficultés importantes face aux ambiguïtés lexicales et aux variations contextuelles des langues naturelles [15].

##### *Traduction Automatique Statistique (TAS)*

La **TAS** (*Statistical Machine Translation (SMT)*) a ensuite remplacé progressivement les approches basées sur des règles. Cette méthode repose sur l'apprentissage de relations statis-

tiques, à partir de grands corpus parallèles contenant des phrases alignées dans plusieurs langues.

Les systèmes statistiques analysent les probabilités de correspondance entre les mots et les segments linguistiques, afin de générer des traductions automatiques. Cette approche a permis d'améliorer significativement la qualité des traductions, par rapport aux systèmes basés uniquement sur des règles linguistiques [5].

#### *Limites des approches classiques*

Les approches classiques de traduction automatique présentent plusieurs limites, malgré leurs contributions importantes. Les systèmes à base de règles exigent un travail manuel conséquent et s'adaptent mal à de nouvelles langues, tandis que les approches statistiques restent tributaires de grands corpus parallèles et gèrent difficilement le contexte global des phrases [40].

Ces limitations ont favorisé l'émergence de la **traduction automatique neuronale (TAN)**. Celle-ci est capable d'apprendre automatiquement des représentations linguistiques plus complexes, et de produire des traductions plus naturelles et plus cohérentes [48].

Le Tableau 2 présente une synthèse comparative des trois grandes approches de traduction automatique, selon plusieurs critères pertinents.

| Critère                      | RBMT                                                                 | SMT                                                        | NMT                                                          |
|------------------------------|----------------------------------------------------------------------|------------------------------------------------------------|--------------------------------------------------------------|
| Période                      | Années 1950–1990                                                     | Années 1990–2015                                           | Depuis 2015                                                  |
| Principe                     | Règles linguistiques et dictionnaires bilingues définis manuellement | Modèles probabilistes appris à partir de corpus parallèles | Réseaux de neurones profonds entraînés sur corpus parallèles |
| Données requises             | Règles et lexiques manuels                                           | Grands corpus parallèles                                   | Grands corpus parallèles                                     |
| Apprentissage                | Non automatique                                                      | Automatique (statistique)                                  | Automatique (neural)                                         |
| Gestion du contexte          | Limitée                                                              | Partielle (n-grammes)                                      | Globale (mécanisme d'attention)                              |
| Qualité des traductions      | Contrôlée mais rigide                                                | Meilleure que RBMT                                         | Meilleure qualité globale                                    |
| Langues à faibles ressources | Difficile (expertise manuelle)                                       | Difficile (manque de corpus)                               | Difficile (manque de données)                                |
| Exemples de systèmes         | Systran, Apertium                                                    | Moses, Pharaoh                                             | mBART, NLLB...                                               |

TABLE 2 – Comparaison des approches de traduction automatique

### 1.3.6 Traduction automatique neuronale

#### Principe de la traduction neuronale

La **traduction automatique neuronale** (NMT) constitue une approche moderne de traduction automatique, fondée sur les réseaux de neurones profonds. Contrairement aux approches classiques basées sur des règles ou des probabilités statistiques, la traduction neuronale apprend automatiquement les relations linguistiques entre les langues à partir de corpus parallèles [40].

Le modèle reçoit une phrase dans une langue source et génère directement sa traduction dans une langue cible. Cette approche permet de produire des traductions plus fluides, plus cohérentes et mieux adaptées au contexte linguistique [48].

#### Architectures encodeur-décodeur

Les premiers systèmes de traduction neuronale reposaient principalement sur l'architecture **encodeur-décodeur** (*Encoder-Decoder*). Dans cette architecture, l'encodeur transforme la



phrase source en une représentation numérique, appelée **vecteur de contexte**. Le décodeur utilise ensuite cette représentation pour générer progressivement la phrase traduite [40].

Cette architecture a permis d'améliorer considérablement les performances de la traduction automatique, en facilitant l'apprentissage des relations sémantiques entre les langues [30].

La Figure 1.2 illustre le fonctionnement de l'architecture encodeur-décodeur utilisée dans les premiers systèmes de traduction neuronale.




FIGURE 1.2 – L'Encodeur-Décodeur [27]

### *Mécanisme d'attention*

Le **mécanisme d'attention** (*Attention Mechanism*) a été introduit afin de résoudre certaines limites des architectures encodeur-décodeur classiques, notamment les difficultés liées aux longues phrases [48].

L'attention permet au modèle de se concentrer sur les parties les plus pertinentes de la phrase source, lors de la génération de chaque mot traduit. Cette approche améliore la prise en compte du contexte linguistique. Elle augmente ainsi la qualité des traductions produites [16].

Le mécanisme d'attention constitue également la base des architectures **Transformer** utilisées dans les modèles modernes de traduction automatique neuronale [48].

### *Avantages des approches neuronales*

Les approches neuronales présentent plusieurs avantages par rapport aux méthodes classiques de traduction automatique. Elles permettent de produire des traductions plus naturelles, plus cohérentes et mieux contextualisées. Elles réduisent également la nécessité de définir manuellement des règles linguistiques complexes [40].

Les modèles neuronaux sont capables d'apprendre automatiquement des représentations linguistiques riches. Ils gèrent aussi mieux les relations contextuelles entre les mots. Leurs performances dépendent cependant fortement de la disponibilité des données d'entraînement et des ressources de calcul. Ce constat représente un défi important pour les **langues à faibles ressources** (LFR) telles que le ruund [20].

### 1.3.7 Architectures Transformer

#### *Origine des Transformers*

Les architectures Transformer<sup>2</sup> ont été introduites en 2017, afin d'améliorer les performances des modèles de traitement automatique des langues. Contrairement aux réseaux récurrents traditionnels (*Recurrent Neural Network (RNN)*), les Transformers reposent principalement sur le mécanisme d'attention. Ce choix architectural permet un traitement parallèle des données textuelles [48].

Cette architecture a marqué une évolution majeure dans le domaine du NLP, en améliorant la qualité des tâches linguistiques telles que la traduction automatique, la génération de texte et la compréhension du langage naturel [40].

#### *Fonctionnement du mécanisme d'attention*

Le **mécanisme d'attention** permet au modèle d'identifier les éléments les plus importants d'une phrase, lors du traitement linguistique. Pour chaque mot, le système évalue les relations avec les autres mots de la séquence, afin de mieux comprendre le contexte global [48].

Cette approche améliore la gestion des dépendances linguistiques longues. Elle réduit ainsi certaines limitations des architectures récurrentes classiques. Les Transformers utilisent principalement une variante appelée *Self-Attention*, dans laquelle chaque mot peut interagir directement avec les autres mots de la phrase [48].

La Figure 1.3 illustre l'architecture générale du modèle Transformer, telle que proposée par VASWANI et al.

---

2. <https://poloclub.github.io/transformer-explainer/>




FIGURE 1.3 – Architecture Transformer [48]

### Représentation contextuelle des mots

Les architectures Transformer permettent de générer des **représentations contextuelles** des mots. Contrairement aux représentations statiques traditionnelles, le sens d'un mot est interprété selon son contexte dans la phrase [48].

Cette capacité améliore considérablement la compréhension sémantique. Elle réduit aussi les ambiguïtés linguistiques. Les modèles modernes peuvent ainsi produire des traductions plus cohérentes et mieux adaptées au contexte du texte source [28].

### *Transformers et traduction multilingue*

Les Transformers constituent aujourd'hui la base des principaux modèles de traduction automatique multilingue, tels que **mBART**, **MarianMT** ou **NLLB**. Ces modèles sont capables d'apprendre simultanément plusieurs langues, à partir de grands corpus multilingues [28].

Cette approche facilite le transfert de connaissances entre les langues à fortes ressources et les **langues à faibles ressources**. Elle représente ainsi une solution importante pour le développement de systèmes de traduction automatique adaptés aux langues africaines peu représentées numériquement, notamment le ruund [35].

#### 1.3.8 Modèles multilingues de traduction

##### *Modèles pré-entraînés multilingues*

Les **modèles pré-entraînés multilingues** sont des modèles neuronaux entraînés sur de grandes quantités de données, provenant de plusieurs langues simultanément. Leur objectif est d'apprendre des représentations linguistiques générales, capables d'être réutilisées dans différentes tâches de traitement automatique des langues, notamment la traduction automatique [40].

Ces modèles reposent principalement sur les architectures **Transformer** et exploitent le transfert de connaissances entre langues. Cette approche est particulièrement importante pour les **langues à faibles ressources**, car elle permet d'améliorer les performances, même lorsque les données disponibles sont limitées [38].

##### *Présentation de Multilingual Bidirectional and Auto-Regressive Transformer (mBART)*

**mBART-50** est un modèle multilingue de traduction automatique, fondé sur l'architecture Transformer. Il repose sur une stratégie de pré-entraînement séquence-à-séquence, permettant au modèle d'apprendre des représentations linguistiques à partir de plusieurs langues [28].

Le modèle prend en charge plusieurs dizaines de langues et peut être adapté à des tâches spécifiques grâce au *fine-tuning*. mBART-50 est particulièrement utilisé dans les contextes multilingues et les langues à faibles ressources, grâce à sa capacité de transfert linguistique [28].

##### *Présentation de NLLB-200-distilled-600M*

**NLLB-200-distilled-600M** est un modèle développé dans le cadre du projet *No Language Left Behind* (**NLLB**). Son objectif principal est d'améliorer la traduction automatique pour les langues sous-représentées dans les technologies numériques [40].

Ce modèle prend en charge un très grand nombre de langues, notamment plusieurs langues africaines. Grâce à son entraînement multilingue massif, il offre de bonnes capacités de généralisation et de transfert vers les langues à faibles ressources. La version distillée permet également de réduire les besoins en ressources computationnelles, tout en conservant des performances importantes [3].

### Présentation de Marian Machine Translation (*MarianMT*)

**MarianMT** est un modèle de traduction automatique neuronale, basé sur l’architecture Transformer et développé pour les tâches de traduction multilingue. Il est largement utilisé dans les bibliothèques **NLP** modernes, grâce à sa flexibilité et à sa compatibilité avec plusieurs paires de langues [8].

MarianMT propose des modèles pré-entraînés spécialisés pour différentes combinaisons linguistiques. Il peut également être adapté à des contextes spécifiques à travers le *fine-tuning* [29].

### Comparaison générale des modèles

Les modèles mBART-50, NLLB-200-distilled-600M et MarianMT reposent tous sur les architectures Transformer. Ils utilisent tous des approches multilingues de traduction automatique neuronale. Le Tableau 3 présente une synthèse comparative de ces trois modèles, selon plusieurs critères pertinents pour le contexte des langues à faibles ressources [28, 40].

| Critère                       | mBART-50                     | NLLB-200-distilled-600M       | MarianMT                         |
|-------------------------------|------------------------------|-------------------------------|----------------------------------|
| Architecture                  | Transformer seq2seq          | Transformer seq2seq           | Transformer seq2seq              |
| Nombre de langues             | 50 langues                   | 200+ langues                  | Paires spécifiques               |
| Stratégie de pré-entraînement | Débruitage multi-lingue      | Entraînement supervisé massif | Entraînement supervisé par paire |
| Langues africaines            | Couverture limitée           | Couverture étendue            | Très limitée                     |
| Adaptation (fine-tuning)      | Oui                          | Oui                           | Oui                              |
| Ressources computationnelles  | Modérées                     | Réduites (version distillée)  | Légères                          |
| Langues à faibles ressources  | Performant après fine-tuning | Orienté LFR                   | Dépend de la paire               |
| Disponibilité                 | HuggingFace                  | HuggingFace                   | HuggingFace                      |

TABLE 3 – Comparaison des modèles multilingues de traduction automatique

Le choix du modèle dépend principalement de plusieurs facteurs, tels que la disponibilité des données, les ressources computationnelles et les objectifs de la tâche de traduction [40].

### 1.3.9 Entraînement et adaptation des modèles neuronaux

#### *Pré-entraînement des modèles*

Le **pré-entraînement** consiste à entraîner un modèle neuronal sur de très grandes quantités de données textuelles, avant son utilisation dans une tâche spécifique. Cette étape permet au modèle d'apprendre des représentations linguistiques générales, telles que les relations syntaxiques, sémantiques et contextuelles entre les mots [17, 40].

#### *Fine-tuning des modèles multilingues*

Le *fine-tuning* correspond à l'adaptation d'un modèle pré-entraîné à une tâche particulière, à l'aide d'un corpus spécialisé. Dans le contexte de la traduction automatique, cette étape consiste à réentraîner le modèle sur des données parallèles spécifiques à une paire de langues donnée [28].

Le *fine-tuning* permet d'améliorer les performances du modèle dans un domaine précis, tout en exploitant les connaissances acquises lors du pré-entraînement. Cette méthode est particulièrement utilisée pour les **langues à faibles ressources**, car elle réduit les besoins en grandes quantités de données d'entraînement [34].

#### *Transfer learning dans les langues à faibles ressources*

Le *Transfer Learning*, ou **apprentissage par transfert**, consiste à réutiliser les connaissances acquises par un modèle sur des langues ou des tâches disposant de grandes quantités de données, afin d'améliorer les performances sur des langues moins représentées [29, 38].

#### *Paramètres et poids des modèles*

Les modèles neuronaux sont composés de nombreux paramètres, appelés **poids** (*weights*), appris automatiquement pendant l'entraînement. Ces paramètres représentent les relations mathématiques apprises par le modèle à partir des données [17].

Les grands modèles multilingues possèdent souvent des millions, voire des milliards de paramètres. L'ajustement de ces poids, pendant l'entraînement et le *fine-tuning*, permet au système d'améliorer progressivement ses performances de traduction [28].

L'augmentation du nombre de paramètres entraîne cependant aussi des besoins plus importants en mémoire, en puissance de calcul et en données d'entraînement. Cette contrainte représente un défi majeur dans les contextes de **langues à faibles ressources (LFR)** et d'environnements computationnels limités [3].

#### *Hyperparamètres d'entraînement*

Les performances des modèles neuronaux dépendent fortement du choix des **hyperparamètres d'entraînement**. Contrairement aux paramètres appris automatiquement par le modèle, les hyperparamètres sont définis avant l'entraînement et influencent directement la qua-

lité de l'apprentissage [17]. Les principaux hyperparamètres utilisés dans les systèmes de TAN sont les suivants :

- Le *learning rate* détermine la vitesse de mise à jour des poids du modèle pendant l'apprentissage. Une valeur trop élevée peut entraîner une instabilité de l'entraînement. Une valeur trop faible peut, à l'inverse, ralentir la convergence du modèle.
- Le *batch size* correspond au nombre d'exemples traités simultanément lors d'une étape d'entraînement. Une taille de batch élevée améliore généralement la stabilité des calculs, mais nécessite davantage de mémoire.
- Les *epochs* représentent le nombre de passages complets du modèle sur l'ensemble des données d'entraînement. Un nombre insuffisant d'epochs peut produire un sous-apprentissage (*underfitting*). Un nombre trop élevé peut, à l'inverse, provoquer un surapprentissage (*overfitting*).

Le choix approprié de ces hyperparamètres est déterminant pour la convergence et les performances finales du modèle. Ce choix est particulièrement sensible dans les contextes à faibles ressources, où les données d'entraînement sont limitées [28].

### *Contraintes computationnelles*

L'entraînement des modèles neuronaux de traduction automatique nécessite des ressources computationnelles importantes. Les contraintes computationnelles concernent principalement l'utilisation des *Graphics Processing Units* (GPU), la capacité de stockage des données ainsi que le temps nécessaire pour entraîner et ajuster les modèles. Ces contraintes deviennent encore plus importantes dans les contextes de recherche disposant de ressources matérielles limitées [17].

Dans le cadre des **langues à faibles ressources**, les difficultés computationnelles s'ajoutent souvent aux limitations liées aux données linguistiques. Il devient alors nécessaire d'utiliser des approches adaptées, telles que le *fine-tuning* de modèles pré-entraînés, les modèles distillés ou les architectures optimisées, afin de réduire les coûts computationnels tout en maintenant des performances satisfaisantes [3].

#### 1.3.10 *Tokenisation et représentations linguistiques*

##### *Tokenisation des textes*

La **tokenisation** consiste à découper un texte en unités élémentaires appelées **tokens**. Ces unités peuvent correspondre à des mots, des caractères ou des sous-mots, selon l'approche utilisée. Cette étape constitue une phase essentielle du prétraitement des données dans les systèmes de TAN [40].

La tokenisation permet de transformer les textes bruts en représentations exploitables par les modèles neuronaux [17].

##### *Segmentation en sous-mots*

Les modèles modernes de traduction automatique utilisent généralement une **segmentation en sous-mots**, plutôt qu'une simple segmentation par mots entiers. Cette approche consiste à

découper les mots en unités linguistiques plus petites, afin de mieux gérer les mots rares ou inconnus [45].

Cette stratégie est particulièrement adaptée aux langues morphologiquement riches et agglutinantes. Pour ces langues, une tokenisation par mots entiers produirait un vocabulaire très large et peu généralisable [12].

### *SentencePiece*

**SentencePiece** est une méthode de tokenisation largement utilisée dans les modèles Transformer modernes. Contrairement aux approches traditionnelles, dépendantes des espaces entre les mots, SentencePiece traite directement le texte brut. Il apprend ainsi automatiquement les unités de segmentation les plus pertinentes [36].

### *Embeddings multilingues*

Les **embeddings multilingues** sont des représentations vectorielles, qui projettent les mots de plusieurs langues dans un même espace sémantique. Les mots ayant des significations proches possèdent ainsi des représentations vectorielles similaires [7, 36].

### *Problème des mots hors vocabulaire (OOV)*

Les **mots hors vocabulaire** (*Out Of Vocabulary* (**OOV**)) correspondent aux mots absents du vocabulaire appris par le modèle pendant l'entraînement. Ce problème est fréquent dans les langues à faibles ressources, en raison du manque de données disponibles [40, 45].

#### 1.3.11 *Corpus parallèles*

##### *Définition d'un corpus parallèle*

Un **corpus parallèle** est un ensemble de textes alignés dans au moins deux langues différentes. Chaque phrase de la langue source possède une traduction correspondante dans la langue cible. Les corpus constituent une ressource fondamentale dans les systèmes de traduction automatique neuronale [20, 40].

##### *Importance des corpus dans la traduction automatique*

Les modèles de traduction automatique apprennent les relations linguistiques à partir des corpus parallèles. La qualité, la taille et la diversité des données influencent directement les performances des systèmes neuronaux [2, 40].

##### *Méthodes de collecte des données*

La collecte des données peut être réalisée à partir de plusieurs sources, telles que les documents bilingues, les textes religieux, les contenus éducatifs, les traductions manuelles ou les ressources communautaires [20, 23].



Dans le contexte des **langues africaines à faibles ressources**, la collecte des données nécessite souvent un travail manuel important, en raison du manque de ressources numériques disponibles [2, 35].

#### *Nettoyage et normalisation*

Le **nettoyage** des données consiste à supprimer les erreurs, les doublons et les phrases mal alignées présentes dans le corpus. La **normalisation** permet quant à elle d'uniformiser les textes, afin de faciliter l'apprentissage du modèle [42].

Cette étape peut inclure la conversion en minuscules, la suppression des caractères inutiles ainsi que la correction de certaines incohérences orthographiques [7].

#### *Alignement des phrases*

L'**alignement** consiste à associer correctement chaque phrase de la langue source avec sa traduction dans la langue cible. Cette étape est essentielle pour garantir la qualité des données utilisées pendant l'entraînement des modèles neuronaux [7, 20].

#### *Corpus religieux et poétiques dans les langues à faibles ressources*

Pour de nombreuses **langues à faibles ressources**, les textes religieux et poétiques constituent les piliers fondamentaux pour la construction des premiers corpus parallèles, en raison de leur disponibilité. La **Bible** est une ressource privilégiée, car sa structure rigoureuse en chapitres et en versets offre un cadre d'alignement naturel et fiable. Ce cadre s'est avéré essentiel pour des langues comme le mizo [14, 20], l'araméen [33], le twi [2], ou encore une douzaine de langues autochtones de Colombie et du Mexique telles que le mazatèque, le huichol ou le paez [8].

D'autres ressources structurées, comme le corpus **JW300**, sont également utilisées pour fournir des données bilingues à des langues comme le quechua ou des langues agglutinantes [12, 24]. L'intégration de la **poésie** et de textes littéraires anciens permet, en parallèle, d'enrichir la diversité lexicale et de capturer des nuances culturelles uniques, malgré une complexité stylistique accrue. Cette approche a été appliquée avec succès pour le croate [15], le môn [47] et pour la traduction de l'écriture logographique **Dongba**, à partir de textes sacrés [34]. Ces ressources jouent un rôle crucial dans l'amorçage des systèmes de traduction automatique (NMT et SMT). Elles permettent de réduire la fracture numérique pour les communautés linguistiquement sous-représentées [40].

## 1.4 DOMAINE LINGUISTIQUE ET LANGUES À FAIBLES RESSOURCES

### 1.4.1 *Langues à faibles ressources*

#### *Définition*

Les **langues à faibles ressources** (LFR) sont des langues disposant de peu de données numériques exploitables, pour le développement des systèmes de traitement automatique des

langues. Cette insuffisance concerne notamment les corpus textuels, les dictionnaires numériques, les ressources parallèles ainsi que les outils linguistiques nécessaires à l'entraînement des modèles d'intelligence artificielle [2, 40].

Ces langues sont généralement sous-représentées dans les technologies numériques modernes, ce qui limite leur intégration dans les applications de traduction automatique, de reconnaissance vocale ou de génération de texte [20, 40].

#### *Causes du faible niveau de ressources numériques*

Le faible niveau de ressources numériques s'explique par plusieurs facteurs. Parmi les principales causes figurent le manque de corpus électroniques, l'absence de standardisation orthographique, la faible numérisation des contenus linguistiques ainsi que le manque d'investissements technologiques et scientifiques [2, 23].

Dans plusieurs langues africaines, les ressources disponibles existent souvent sous forme papier ou orale, ce qui complique leur exploitation dans les systèmes de TAL [2, 35].

#### *Inégalités numériques linguistiques*

Les **inégalités numériques linguistiques** désignent la différence de représentation entre les langues, dans les technologies numériques modernes. Certaines langues largement utilisées à l'échelle internationale disposent de grandes quantités de données et de nombreux outils NLP. D'autres restent, à l'inverse, faiblement représentées [3, 40].

Cette situation crée une **exclusion technologique** pour plusieurs communautés linguistiques, notamment africaines, dont les langues ne bénéficient pas pleinement des avancées de l'intelligence artificielle et de la TAN [2, 35].

La Figure 1.4 illustre cette inégalité, en représentant la répartition des langues du monde selon leur nombre de locuteurs et le niveau de ressources disponibles en TAL.



FIGURE 1.4 – Répartition des langues selon leur nombre de locuteurs et leurs ressources en NLP [32]

### 1.4.2 Défis du TAL pour les langues africaines

#### *Manque de données linguistiques*

Le principal défi du **TAL** pour les langues africaines réside dans le **manque de données linguistiques numériques** disponibles. La majorité des langues africaines disposent de très peu de corpus textuels, de ressources parallèles ou de bases lexicales exploitables, pour l'entraînement des modèles neuronaux [2, 40].

#### *Diversité dialectale*

Plusieurs langues africaines présentent une forte **diversité dialectale**. Une même langue peut posséder différentes variantes régionales, phonétiques ou lexicales, selon les communautés locutrices [2, 35].

Cette diversité complique la construction des corpus linguistiques et l'entraînement des modèles de **TAL**, car les variations dialectales peuvent entraîner des incohérences dans les données [20].

#### *Absence de standardisation orthographique*

Certaines langues africaines ne disposent pas d'une orthographe totalement standardisée. Les variations d'écriture, les différences de transcription et les pratiques linguistiques locales peuvent produire plusieurs formes écrites pour un même mot [20, 23].

#### *Difficultés de collecte et d'annotation*

La collecte et l'annotation des données linguistiques nécessitent souvent un travail manuel important. Dans les **langues à faibles ressources**, les textes numériques sont rares et plusieurs contenus existent principalement sous forme orale ou papier [2, 35].

Ces difficultés rendent la constitution de corpus parallèles de qualité particulièrement laborieuse. Elles exigent le recours à des méthodes d'augmentation ou d'automatisation partielle de la collecte, afin de pallier le manque de données annotées [40, 42].

### 1.4.3 Présentation linguistique du ruund

#### *Classification linguistique du ruund*

Le **ruund**, aussi appelé *ruwund*, *uruund* ou *lunda du Nord* dans certaines classifications linguistiques, est une langue bantoue parlée par plus de 250 000 personnes, principalement en République Démocratique du Congo et en Angola. Il appartient à la famille des langues nigéro-congolaises et au groupe des langues bantoues [49].

Cette langue est utilisée par une importante communauté locutrice, notamment dans la région du Katanga. Elle demeure néanmoins faiblement représentée dans les ressources numériques et les technologies linguistiques modernes [49].

### *Caractéristiques morphologiques*

Sur le plan morphologique, le ruund possède une structure fortement **agglutinante**, caractéristique des langues bantoues. L'organisation grammaticale de la langue repose principalement sur un système complexe de **classes nominales**, dans lequel les substantifs sont regroupés sous forme de classes singulier/pluriel ou de classes uniques. Chaque nom est généralement associé à un **préfixe nominal**, qui joue un rôle central dans les mécanismes d'accord grammatical [26].

Le système verbal du ruund présente également une morphologie riche et complexe. Le verbe est construit autour d'une **racine verbale**, combinée à plusieurs affixes flexionnels indiquant notamment l'accord du sujet, le temps, l'aspect, la négation ou encore la pronominalisation de l'objet. À cette structure s'ajoutent des extensions dérivationnelles telles que l'applicatif, le causatif ou le passif, capables de modifier la structure actancielle et la valeur sémantique du verbe [25, 26].

Par ailleurs, la morphotactique du ruund est soumise à des contraintes d'**harmonie vocale**, entre la racine verbale et certains suffixes grammaticaux [25]. Cette richesse morphologique représente un défi important dans les tâches de traitement automatique des langues, notamment pour la tokenisation, la segmentation morphologique et la traduction automatique neuronale.

### *Particularités syntaxiques et lexicales*

Le fonctionnement syntaxique du ruund repose sur un système de **concordance grammaticale** fortement développé. Les différents éléments associés au substantif, notamment les adjectifs, les démonstratifs, les possessifs ainsi que le verbe, s'accordent systématiquement avec le nom selon la classe nominale, le nombre et parfois la personne grammaticale [26].

L'identification des relations grammaticales telles que le sujet, l'objet direct ou l'objet indirect s'effectue à travers une combinaison de mécanismes. Ceux-ci incluent l'ordre des mots, la pronominalisation et certains marquages morphosyntaxiques [26].

Le ruund présente également des évolutions syntaxiques particulières, notamment l'apparition de constructions **passives impersonnelles** venant concurrencer certaines formes passives bantoues traditionnelles, construites à l'aide de suffixes verbaux. La langue se caractérise aussi par une diversité typologique importante des propositions relatives, ainsi que par différents mécanismes de détransitivation [26].

Sur le plan morphosyntaxique, plusieurs études soulignent également l'existence d'un certain **synchrétisme** entre les formes réflexives et réciproques. Elles relèvent aussi une convergence fonctionnelle entre les constructions passives et neutre-passives, malgré leurs différences structurelles [25, 26].

### *Défis du ruund dans le NLP*

Le développement des applications **NLP** pour le ruund fait face à plusieurs défis majeurs. La langue dispose de peu de corpus numériques, de ressources parallèles et d'outils linguistiques spécialisés. Les variations orthographiques et la rareté des données annotées compliquent également l'entraînement des modèles neuronaux.

Ces limitations réduisent les performances des systèmes de traduction automatique. Elles justifient la nécessité de développer des approches adaptées aux langues à faibles ressources, dans le contexte du ruund.

#### 1.4.4 *Préservation linguistique et intelligence artificielle*

##### *Numérisation des langues africaines*

La numérisation des langues africaines constitue une étape essentielle pour leur intégration dans les technologies modernes de traitement automatique des langues. Ce processus consiste à transformer les ressources linguistiques disponibles sous forme orale ou papier, en données numériques exploitables par les systèmes informatiques [2, 35].

##### *IA et sauvegarde du patrimoine linguistique*

L'intelligence artificielle joue un rôle important dans la préservation du patrimoine linguistique. Les technologies de traitement automatique des langues permettent de documenter, d'analyser et de valoriser les langues peu représentées numériquement [3, 40].

##### *Importance des ressources numériques locales*

Le développement de ressources numériques locales représente un enjeu vital pour les langues africaines, afin de surmonter la « **pénurie de données** » (*data scarcity*) qui marginalise la majorité des langues mondiales [40]. Pour le **ruund**, cette démarche s'appuie sur les avancées méthodologiques observées pour d'autres langues à faibles ressources, telles que le **mizo** [20, 30], le **pendjabi** [23] ou le **twi** [2]. Ces langues souffrent également d'un manque initial de présence numérique native. À l'instar du **mon** [47], l'absence de corpus parallèles structurés constitue un frein majeur au développement d'applications performantes. Elle rend indispensable la création d'outils linguistiques et de données annotées, pour renforcer les capacités des modèles neuronaux.

En s'appuyant sur les efforts de documentation menés pour le **quechua** [43] ou l'**araméen** [33], la constitution de ressources pour le ruund s'inscrit dans une quête de **justice numérique**, visant à réduire la fracture technologique [2, 40]. Cette production de données locales dépasse le simple cadre du progrès technique. Elle contribue aussi à préserver et à valoriser un patrimoine linguistique et culturel propre, face aux défis de la mondialisation, et permet à ses locuteurs de participer pleinement à l'écosystème numérique mondial.

## 1.5 ANALYSE DES TRAVAUX EXISTANTS

### 1.5.1 *Évolution des approches de traduction automatique*

#### *Approches symboliques*

Les premières tentatives de traduction automatique, dites **RBMT**, reposaient sur des règles linguistiques et des dictionnaires bilingues élaborés manuellement par des experts. Elles s'avé-

raient précises pour des domaines restreints, mais coûteuses, difficiles à généraliser et incapables de gérer l’ambiguïté naturelle des langues complexes [16, 40].

### *Approches statistiques*

La **traduction automatique statistique (SMT)** a marqué un tournant, en apprenant des probabilités de traduction à partir de grands corpus parallèles. Les modèles de type *Phrase-Based Statistical Machine Translation (PBSMT)* peinent cependant à capturer les dépendances à longue distance et les structures syntaxiques divergentes, en particulier dans les langues morphologiquement riches [14, 30].

### *Approches neuronales modernes*

L’émergence de la **TAN**, et plus particulièrement de l’architecture **Transformer**, a révolutionné le domaine en traitant les phrases de manière globale, via des mécanismes d’auto-attention. Ces modèles surpassent désormais les approches statistiques, en termes de fluidité et de cohérence contextuelle [40, 48].

#### 1.5.2 Travaux sur les langues à faibles ressources

##### *Traduction neuronale multilingue*

La traduction multilingue (*Multilingual Neural Machine Translation (MNMT)*) permet de mutualiser les connaissances entre plusieurs langues au sein d’un modèle unique. Cette approche est cruciale pour les langues peu dotées, car elle facilite le transfert de connaissances depuis des langues à fortes ressources vers des langues cibles [7, 9]. La qualité du transfert dépend également du choix de la stratégie de segmentation en sous-mots et de la nature du transfert cross-lingual entre les langues concernées [36, 45].

##### *Fine-tuning pour les langues sous-représentées*

L’adaptation de modèles pré-entraînés comme **mBART-50** ou **NLLB-200** via le *fine-tuning* est la stratégie la plus efficace pour les petits jeux de données. Un modèle pré-entraîné fournit en effet une excellente initialisation grammaticale, même avec un corpus restreint [21, 28]. Cette approche a également démontré son efficacité dans des contextes de traduction entre langues asiatiques à faibles ressources [46].

##### *Traduction basée sur des corpus bibliques et textes poétiques*

La Bible est souvent l’une des seules ressources parallèles disponibles pour de nombreuses langues à faibles ressources (mizo, twi, quechua). Elle offre un alignement précis par versets. Son domaine reste toutefois restreint, ce qui limite souvent la capacité de généralisation du modèle final [8, 14].

La poésie présente des défis uniques en **TAN**, notamment la préservation des patterns de rimes et de la structure métrique. Les travaux existants indiquent que les modèles neuronaux,

bien que performants, peinent encore à restituer la créativité littéraire sans un ajustement spécifique [15, 33].

#### *Travaux sur les langues africaines et bantoues*

Les langues bantoues, comme le ruund, font face à des défis majeurs en matière de traitement de l'information et de développement informatique. Ces difficultés structurelles, combinées au manque de ressources numériques, soulignent l'importance de construire des ressources locales pour les langues africaines, souvent exclues des technologies numériques [40].

#### 1.5.3 *Analyse critique des travaux existants*

##### *Forces des approches actuelles*

Les modèles basés sur les **Transformers** et l'apprentissage par transfert permettent d'obtenir des résultats exploitables, là où les méthodes traditionnelles échouaient. Cette supériorité empirique a été démontrée pour plusieurs paires de langues à faibles ressources, notamment le mizo-anglais [30] et le môn-anglais [47].

##### *Limites liées aux données*

La TAN est extrêmement gourmande en données. Les performances chutent drastiquement en dessous de 10 000 paires de phrases [40]. Notre corpus de 8 431 paires se situe précisément dans cette zone critique, ce qui rend l'usage du transfert d'apprentissage indispensable [34].

##### *Difficultés liées aux langues bantoues*

Le manque de standardisation orthographique et la richesse des affixes verbaux compliquent la tâche de tokenisation. Les modèles généralistes peinent souvent à capturer l'harmonie vocalique et les spécificités tonales, sans données massives.

##### *Limites des métriques d'évaluation*

Le score BLEU, bien que standard, ne corrèle pas toujours parfaitement avec le jugement humain, pour les langues à faibles ressources [30, 31]. Notre choix d'inclure une évaluation humaine est donc scientifiquement justifié, pour valider l'adéquation sémantique [47].

##### *Synthèse comparative des travaux*

Le Tableau 4 présente une analyse comparative de seize études représentatives, portant sur la traduction automatique pour les langues à faibles ressources. Il synthétise les approches méthodologiques, les performances obtenues, la complexité des systèmes, leur robustesse ainsi que leurs limites principales.



| Auteur(s)                         | Approche                               | Performance                                | Complexité | Robustesse | Limites principales                                                          |
|-----------------------------------|----------------------------------------|--------------------------------------------|------------|------------|------------------------------------------------------------------------------|
| ALI, YADAV et KUMAR [7]           | MNMT non supervisée (XLM-R + ACL)      | +1.2 BLEU (bi-lingue)                      | Élevée     | Haute      | Qualité médiocre sur phrases longues; dépendance aux dictionnaires bilingues |
| LALREMPUII, SONI et PAKRAY [30]   | Comparaison SMT vs NMT (mizo)          | Transformer >> LSTM et SMT                 | Modérée    | Moyenne    | Baisse radicale sur phrases longues; manque de ressources pour le mizo       |
| KOZHIRBAYEV [28]                  | Fine-tuning mBART-50                   | +11.95 BLEU (kazakh-russe)                 | Moyenne    | Haute      | Sensibilité à la qualité des données de fine-tuning et aux hyperparamètres   |
| AHMADNIA, DORR et ARANOVICH [4]   | Filtrage de données pseudo-parallèles  | BLEU > baselines non filtrées              | Modérée    | Améliorée  | Corpus filtré très réduit; généralisation limitée                            |
| DAI et al. [13]                   | Transfert TFT-TL (niveau token)        | 19.88 BLEU (Tr-En)                         | Élevée     | Excellente | Instabilité possible à certaines étapes d'apprentissage                      |
| BRAHMA, MAURYA et DESARKAR [11]   | SELECTNOISE (injection de bruit)       | Surpasse les baselines zero-shot           | Élevée     | Robuste    | Efficacité réduite si les scripts des langues sont trop différents           |
| CHEN et FAZIO [12]                | Segmentation morphologique (PRPE)      | 23.4 BLEU (quechua)                        | Modérée    | Bonne      | Nécessite une liste d'affixes préalable (connaissances linguistiques)        |
| BALA DAS et al. [10]              | MNMT + trans-littération (Indic-Indic) | +6.74 BLEU (malayalam)                     | Modérée    | Bonne      | Interférence négative sur certains groupes linguistiques rares               |
| TUN, SIN et SOE [47]              | Hybride SMT, NMT, BART fine-tuné       | BART + SentencePiece = meilleurs résultats | Élevée     | Bonne      | Complexité morphologique du môn non résolue par le seul transfert            |
| AHMED et al. [6]                  | Rétro-traduction itérative (mizo)      | +3.65 BLEU par itération                   | Modérée    | Moyenne    | Inefficace sur phrases très longues                                          |
| GRÖNROOS, VIRPIOJA et KURIMO [19] | Multi-task learning programmé          | +12.7 BLEU via MNMT + rétro-traduction     | Élevée     | Haute      | Rendements décroissants au-delà de 10 000 phrases                            |



|                                 |                                            |                                    |         |            |                                                                               |
|---------------------------------|--------------------------------------------|------------------------------------|---------|------------|-------------------------------------------------------------------------------|
| ACI, VURAN SARI et İNAN ACI [1] | Analyse de profondeur (anglais-turc)       | 47.85 BLEU (Transformer 3 couches) | Élevée  | Excellente | Chute de performance si la profondeur dépasse le seuil optimal                |
| KANN et al. [24]                | AmericasNLI (langues indigènes)            | +24.53% pour le quechua            | Haute   | Moyenne    | Répétition de sous-mots dans les sorties; sensibilité au domaine              |
| GOYAL, KUMAR et SHARMA [18]     | Translittération unifiée (indo-aryen)      | +5 points BLEU en moyenne          | Modérée | Bonne      | Ambiguïtés à l'inférence entre langues proches                                |
| HONG et al. [21]                | CANTONMT (rétro-traduction + commutation)  | SacreBLEU 16.8                     | Haute   | Moyenne    | Corpus très réduit (60k) par rapport à la population cible (80M locuteurs)    |
| RANI, YADAV et KUMAR SINGH [41] | Filtrage cross-validation (sanskrit-hindi) | +1.85 BLEU (token-level)           | Modérée | Bonne      | Corpus filtré final très réduit (300 paires test); portée statistique limitée |

TABLE 4 – Synthèse comparative des travaux existants sur la TAN pour les langues à faibles ressources

#### 1.5.4 Gap scientifique et positionnement du mémoire

##### *Absence de TAN sur le ruund*

Il n'existe actuellement aucun système de traduction automatique robuste documenté pour le ruund. Ce travail comble un vide numérique pour cette communauté linguistique.

##### *Insuffisance des ressources numériques ruund-français*

Les sources disponibles pour le ruund sont fragmentaires et non structurées pour le ML. L'effort de *Data Engineering* réalisé dans ce travail, à savoir le nettoyage, la normalisation et l'alignement de 8 431 paires, constitue une contribution majeure à la documentation numérique de cette langue [37].

##### *Justification scientifique du mémoire*

Ce mémoire se positionne à la pointe de la recherche actuelle. Il utilise le *fine-tuning* de modèles étatiques (NLLB-200, mBART-50) pour compenser la rareté des données, selon une démarche validée pour d'autres langues à faibles ressources telles que le môn [47].

*Contribution attendue de la recherche*

Outre le système de traduction, ce travail propose une méthodologie pour construire des jeux de données exploitables à partir de sources religieuses et poétiques. Cette méthodologie ouvre la voie à une future généralisation vers des domaines variés.

**CONCLUSION PARTIELLE**

L'analyse de la littérature met en évidence le manque de ressources numériques pour les langues à faibles ressources. Elle souligne aussi l'intérêt des corpus parallèles et des modèles multilingues pré-entraînés pour améliorer la traduction automatique. Ces constats justifient la présente recherche sur le ruund, langue encore peu documentée dans les technologies du langage [20, 28, 40].

Le chapitre suivant présente la construction du corpus parallèle ruund–français, depuis la collecte des données jusqu'à leur alignement et leur validation.

## CONSTRUCTION DU CORPUS PARALLÈLE RUUND-FRANÇAIS

### 2.1 INTRODUCTION

Ce chapitre présente le processus de constitution du corpus utilisé pour l’entraînement et l’évaluation des modèles de traduction automatique étudiés. Il décrit les objectifs poursuivis, les sources de données exploitées ainsi que l’organisation générale du corpus obtenu.

La Figure 2.1 illustre les grandes étapes de ce processus. Ces étapes sont détaillées dans les sections suivantes.




FIGURE 2.1 – Pipeline de construction du corpus parallèle ruund-français

### 2.2 PRÉSENTATION GÉNÉRALE DU CORPUS

#### 2.2.1 Objectif de la construction du corpus

L’objectif principal de la construction du corpus est de disposer d’un ensemble de données parallèles ruund-français. Ces données permettent l’entraînement, l’adaptation et l’évaluation de modèles de **TAN**. Le manque de ressources linguistiques numériques disponibles pour le ruund a rendu nécessaire la constitution d’un corpus spécifique, à partir de données existantes dans les deux langues.

Ce corpus ne sert pas uniquement à ce mémoire. Il alimente aussi un besoin plus large : la mise à disposition de ressources linguistiques pour d’autres travaux de recherche et pour le développement d’applications de **TAL** en ruund.

2.2.2 Description générale du corpus

Le corpus utilisé dans cette étude est un **corpus parallèle texte-à-texte**. Il est composé de phrases en ruund et de leurs équivalents en français. Les données proviennent principalement du **Nouveau Testament** ainsi que d'un ensemble de **poèmes** disponibles dans les deux langues.

La construction du corpus a impliqué plusieurs opérations : collecte, extraction et alignement des données. Ces opérations ont permis d'établir une correspondance entre les segments textuels des deux langues.

Les données sont organisées sous forme de **paires de phrases alignées**. Chaque phrase en ruund est associée à sa traduction correspondante en français. Cette structure est adaptée aux exigences des systèmes de [TAN](#).

2.3 COLLECTE DES DONNÉES

Le [Tableau 5](#) présente une synthèse des sources exploitées ainsi que les méthodes de collecte appliquées pour chacune d'elles.

| Source            | Langue         | Méthode de collecte             | Format de sortie     |
|-------------------|----------------|---------------------------------|----------------------|
| Nouveau Testament | Français       | Web scraping <sup>1</sup>       | Fichier texte (.txt) |
| Nouveau Testament | Ruund          | Numérisation + OCR <sup>2</sup> | Fichier texte (.txt) |
| Poèmes bilingues  | Ruund–Français | Extraction                      | Fichier texte (.txt) |

TABLE 5 – Sources et méthodes de collecte des données du corpus

2.4 NUMÉRISATION ET EXTRACTION DES DONNÉES

2.4.1 Processus de numérisation

Les pages du Nouveau Testament en ruund (*Manswik Masu*, 1996) ont été numérisées à une résolution de **900 dpi**. Cette numérisation a été réalisée à l'aide d'un scanner HP Color LaserJet Pro MFP M283fdw, afin d'obtenir des images nettes. Cette condition est essentielle pour minimiser les erreurs de l'[OCR](#). Cette opération a permis de convertir le document physique en images pouvant être traitées automatiquement.

1. Le *web scraping* est une technique informatique qui consiste à utiliser des programmes ou des scripts pour extraire automatiquement des données de sites internet.  
2. La *Optical Character Recognition* ([OCR](#)) est une technologie qui convertit le texte imprimé ou manuscrit présent sur des images, des photos ou des documents numérisés en un format texte éditables et consultables

La Figure 2.2 présente le pipeline suivi lors du processus de numérisation du Nouveau Testament en ruund.




FIGURE 2.2 – Pipeline de numérisation de données

#### 2.4.2 Reconnaissance optique de caractères

Les images obtenues ont ensuite été traitées par le moteur d'OCR **Tesseract**<sup>3</sup>. Cet outil convertit automatiquement le contenu textuel des images en texte numérique exploitable. Tesseract ne dispose pas de modèle linguistique natif pour le ruund. Le traitement a donc été réalisé par extraction des caractères bruts. Le listing 1, présenté en annexe, illustre cela.

#### 2.4.3 Difficultés rencontrées et corrections

L'extraction automatique a généré certaines erreurs. Elles concernent notamment les **caractères spéciaux**, les **numéros de versets** et la **ponctuation**. Une phase de vérification et de correction manuelle a donc été réalisée. Elle a permis d'améliorer la qualité des textes extraits avant leur utilisation dans le processus d'alignement.

Le Tableau 6 présente quelques types d'erreurs observées après l'OCR, ainsi que des exemples de corrections appliquées automatiquement et manuellement.

3. <https://tesseract-ocr.github.io/tessdoc/>

| Catégorie d'erreur                                                    | Exemple avant correction (OCR)           | Exemple après correction                          |
|-----------------------------------------------------------------------|------------------------------------------|---------------------------------------------------|
| Numéro de verset manquant                                             | Kuvadik kwa Yesu Kristu kwading mwamu.   | 18 Kuvadik kwa Yesu Kristu kwading mwamu.         |
| Caractère spécial mal interprété (symbole vers chiffre)               | § Asa wamuvala Josafat...                | 8 Asa wamuvala Josafat... ou 2, 3, 9 selon le cas |
| Caractère spécial mal interprété (crochet ou apostrophe vers chiffre) | ] 'Minam mawiy majin ma angakiril...     | 1 Minam mawiy majin ma angakiril...               |
| Césure de mot intempestive (tiret en fin de ligne)                    | kumu- kwatish                            | kumukwatish                                       |
| Ponctuation finale manquante                                          | ... mulong wa kuwanyish mazu ma Chinawej | ... mulong wa kuwanyish mazu ma Chinawej.         |
| Numéro de verset collé au texte                                       | 2 1Yesu wavadika...                      | 1 Yesu wavadika...                                |

TABLE 6 – Exemples d'erreurs produites par l'OCR et corrections appliquées

#### 2.4.4 Extraction des données françaises par web scraping

Pour constituer le versant français du corpus, la **Bible en Français Courant** (1997) a été utilisée. Elle est disponible en ligne sur la plateforme [bible.com](https://bible.com). Le processus d'extraction a été automatisé à l'aide d'un script **Python**. Ce script s'appuie sur la bibliothèque **BeautifulSoup**<sup>4</sup>, qui transforme le contenu **HTML** en un flux textuel structuré adapté à l'alignement ultérieur. Le listing 2, présenté en annexe, illustre les étapes clés de ce processus d'extraction.

## 2.5 CONSTRUCTION DU CORPUS PARALLÈLE

Après la collecte et l'extraction des données, les textes ruund et français ont été organisés. Cette organisation visait à constituer un **corpus parallèle** exploitable pour l'entraînement des modèles de [TAN](#).

### 2.5.1 Segmentation des textes

Les textes ont été segmentés en unités correspondant principalement à des **versets bibliques** et à des **phrases issues des poèmes bilingues**. Cette étape a permis d'obtenir des segments comparables dans les deux langues. Elle a aussi permis de préparer les données pour l'alignement.

4. <https://beautiful-soup-4.readthedocs.io/en/latest/>

### 2.5.2 Alignement automatique

L'alignement a consisté à associer chaque segment en ruund à son équivalent en français. Une première correspondance a été réalisée automatiquement, à partir de la structure commune des versets des textes sources. Cette étape a permis de générer une version initiale du corpus parallèle. Le listing 3 illustre le principe de cette procédure d'alignement.




FIGURE 2.3 – Pipeline d'alignement de textes

### 2.5.3 Correction manuelle des alignements

Les alignements produits automatiquement ont ensuite été **vérifiés manuellement**. Les segments mal associés, incomplets ou ambigus ont été corrigés. Cette correction a permis d'améliorer la cohérence entre les phrases sources et cibles.

### 2.5.4 Validation du corpus parallèle

Une vérification finale a été effectuée pour s'assurer de la qualité des alignements et de l'intégrité des données. À l'issue de cette étape, le dataset OpenRuund<sup>5</sup> contient **8 431 paires de phrases ruund-français**. Ces paires sont prêtes à être utilisées pour l'entraînement et l'évaluation des modèles de TAN.

Le Tableau 7 présente quelques exemples de paires de phrases issues du corpus OpenRuund, afin d'illustrer la structure des données alignées obtenues.

5. <https://huggingface.co/datasets/eliezermga/OpenRuund>

| Ruund                                                                                          | Français                                                                                                          |
|------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| Aam nid kwaam nkay chilil mwaan, chik-weeza kumudya mwaan chikudyook mukank mweey              | Je ne suis quant à moi qu’une simple antilope nourricière du petit, ce qui le tuera c’est ta parole malveillante. |
| Yesu wayakula anch : Yangany ukamulejany Yohan yom yiuteshilanya ni yiumenanya                 | Jésus leur répondit : Allez raconter à Jean ce que vous entendez et voyez                                         |
| Akaat kubul mband ni kumubachikin mu chikumbw, anch wamubachikin pool wamupaan kal kudy akween | On corrige une femme discrètement sous le toit conjugal et non en public sinon on l’expose à ce dernier.          |

TABLE 7 – Exemples de paires de phrases alignées d’OpenRuund

## 2.6 ANALYSE DESCRIPTIVE DU CORPUS

La Figure 2.4 présente les principales caractéristiques quantitatives du corpus parallèle construit dans le cadre de cette étude.




FIGURE 2.4 – Statistiques descriptives du corpus OpenRuund

## 2.7 DÉFIS ET LIMITES DE LA CONSTRUCTION DU CORPUS

### 2.7.1 Défis liés à la collecte

La principale difficulté a été l’accès à des ressources bilingues de qualité en ruund. Contrairement au français, les textes numériques disponibles dans cette langue sont rares. Cette rareté a limité les sources exploitables pour la constitution du corpus. Elle reflète plus largement la situation des [LFR](#), pour lesquelles les corpus parallèles structurés demeurent exceptionnels.



### 2.7.2 Défis liés à l'OCR

L'absence de modèles OCR spécifiquement adaptés au ruund a entraîné diverses erreurs lors de l'extraction du texte. Certaines confusions de caractères, omissions et erreurs de segmentation ont nécessité des corrections manuelles avant l'utilisation des données.

### 2.7.3 Défis liés à l'alignement

Les textes bibliques présentent une structure relativement régulière, basée sur les versets. Certaines différences de segmentation entre les versions ruund et française ont néanmoins compliqué l'**alignement automatique**. Une vérification manuelle a donc été nécessaire, en particulier dans les cas où la correspondance entre versets n'était pas univoque, afin de corriger les associations incorrectes.

### 2.7.4 Limites du corpus obtenu

Le corpus construit demeure limité en taille par rapport aux ressources généralement utilisées pour l'entraînement des systèmes de traduction neuronale. Les modèles neuronaux modernes atteignent en effet généralement des performances optimales avec des centaines de milliers de paires de phrases parallèles. Le corpus ruund–français ne contient, quant à lui, que 8 431 paires. Une grande partie des données provient en outre de textes religieux. Cette concentration thématique réduit la diversité du vocabulaire et des tournures rencontrées, ce qui peut à son tour limiter la capacité de généralisation des modèles entraînés sur ces données.

Malgré ces limites, cette ressource constitue une base exploitable pour le développement et l'évaluation de modèles de traduction ruund–français. Elle représente une contribution significative à la numérisation du ruund, une langue jusqu'à présent largement sous-représentée dans les technologies linguistiques modernes.

## CONCLUSION PARTIELLE

Ce chapitre a retracé la construction du corpus OpenRuund, de la collecte des sources jusqu'à la validation finale des paires alignées. Le chapitre suivant s'appuie sur ce corpus pour décrire l'adaptation des modèles de traduction et la mise en place du système applicatif.

## DÉVELOPPEMENT DU SYSTÈME DE TRADUCTION AUTOMATIQUE

### 3.1 INTRODUCTION

Le chapitre précédent a présenté la construction du corpus **OpenRuund**. Cette partie du travail est consacrée au développement du système de traduction automatique. L'objectif est de mettre en œuvre une approche de **TAN** adaptée au contexte des **LFR**, en s'appuyant sur des modèles multilingues préentraînés.

Le développement du système comprend plusieurs volets : la transformation du corpus en données exploitables pour l'apprentissage automatique, l'adaptation des modèles retenus, leur entraînement et l'évaluation de leurs performances. Une fois le modèle le plus performant identifié, celui-ci est intégré dans une application permettant la traduction automatique.

La Figure 3.1 présente le pipeline global adopté pour le développement du système de traduction automatique.




FIGURE 3.1 – Pipeline global du système de traduction automatique

### 3.2 PRÉPARATION DES DONNÉES POUR L'ENTRAÎNEMENT

Avant l'entraînement des modèles de TAN, le corpus OpenRuund a fait l'objet d'une phase de préparation. Cette phase vise à améliorer la qualité des données fournies aux modèles. Le processus mis en œuvre comprend la normalisation des textes ainsi que le filtrage des phrases, afin de réduire les incohérences présentes dans le corpus.

#### 3.2.1 Objectifs du prétraitement

Cette préparation répond à une exigence propre aux systèmes de TAN : les modèles de traduction apprennent à partir des relations observées entre les phrases sources et cibles, si bien que des données bruitées ou incohérentes dégradent directement l'apprentissage et la qualité des traductions générées.

Dans le cadre de cette étude, le prétraitement vise donc principalement à homogénéiser la représentation des textes. Il vise aussi à éliminer les éléments susceptibles d'introduire des erreurs lors de l'entraînement. Cette opération permet d'obtenir un corpus plus cohérent. Elle facilite ainsi l'apprentissage des correspondances linguistiques entre le ruund et le français.

Par ailleurs, la réduction du bruit dans les données améliore la qualité générale du corpus. Les doublons, les phrases vides, les séquences anormalement longues ou encore les paires de phrases présentant un déséquilibre important entre les deux langues peuvent introduire des biais dans le processus d'apprentissage. Leur suppression permet de conserver uniquement les exemples les plus pertinents pour l'entraînement des modèles.

#### 3.2.2 Normalisation des textes

Dans un premier temps, une normalisation Unicode<sup>1</sup> de type *Normalization Form Canonical Composition* (NFC)<sup>2</sup> a été effectuée. Cette opération permet d'uniformiser la représentation interne des caractères Unicode. Elle évite ainsi que des caractères visuellement identiques soient encodés de manière différente.

Ensuite, l'ensemble des textes a été converti en minuscules. Cette transformation réduit la variabilité artificielle du vocabulaire. Elle évite que des mots identiques soient considérés comme différents uniquement en raison de l'utilisation de majuscules.

Une phase de nettoyage des caractères a également été réalisée. Les caractères spéciaux non pertinents ont été supprimés. Les principaux signes de ponctuation utiles à la structure des phrases, notamment les points, les virgules, les points d'interrogation, les points d'exclamation et les apostrophes, ont en revanche été conservés.

Enfin, les espaces superflus ont été éliminés. Les séquences de plusieurs espaces consécutifs ont été remplacées par un espace unique. Les espaces présents en début ou en fin de phrase ont été supprimés. Cette opération permet d'obtenir des textes homogènes et prêts pour les étapes ultérieures d'entraînement.

---

1. La normalisation Unicode est un type spécifique de normalisation de texte qui résout un problème crucial : un même caractère affiché peut avoir plusieurs représentations binaires différentes en Unicode.

2. NFC est une méthode pour organiser le texte sur un ordinateur. Elle permet de s'assurer que les lettres avec des accents sont toujours écrites de la même façon.

Le script implémentant ces opérations de normalisation est présenté en annexe (Listing 4).

### 3.2.3 Filtrage du corpus

Après la normalisation des textes, plusieurs opérations de filtrage ont été appliquées. Elles visaient à conserver uniquement les paires de phrases répondant aux critères de qualité définis pour cette étude.

#### *Suppression des doublons*

Les paires de phrases identiques apparaissant plusieurs fois dans le corpus ont été supprimées. Cette opération évite une surreprésentation de certains exemples durant l'apprentissage. Elle contribue ainsi à améliorer la diversité des données utilisées pour l'entraînement.

#### *Suppression des phrases vides*

Les phrases ne contenant aucun mot après les opérations de prétraitement ont été retirées du corpus. Les paires comportant une phrase vide dans l'une des deux langues ne fournissent en effet aucune information utile au modèle. Elles peuvent aussi perturber le processus d'apprentissage.

#### *Filtrage par longueur des phrases*

Un seuil maximal de 80 mots a été fixé pour chacune des langues. Les paires dont la phrase ruund ou la phrase française dépassait cette limite ont été supprimées. Cette contrainte permet d'écarter les séquences exceptionnellement longues. Elle limite ainsi la complexité de l'entraînement et les déséquilibres susceptibles d'apparaître dans les données.

#### *Filtrage par ratio de longueur*

Un contrôle du rapport de longueur entre les phrases alignées a également été réalisé. Pour chaque paire de phrases, le ratio entre la longueur de la phrase source et celle de la phrase cible a été calculé.

Cette opération permet de détecter les alignements potentiellement incorrects ou les traductions incomplètes. Des différences excessives de longueur entre deux phrases supposées équivalentes peuvent en effet indiquer une mauvaise correspondance entre les segments alignés. Le maintien d'un ratio inférieur ou égal à 2 contribue ainsi à préserver la cohérence linguistique du corpus parallèle utilisé pour l'entraînement des modèles.

L'ensemble des opérations de filtrage décrites ci-dessus est implémenté dans le script présenté en annexe (Listing 5).

### 3.2.4 Constitution des ensembles d'apprentissage

Après la préparation linguistique des données, le corpus a été réparti en plusieurs sous-ensembles. Ces sous-ensembles sont destinés aux différentes phases du processus d'apprentissage et d'évaluation.

#### Découpage du corpus

Le corpus tokenisé a été divisé en trois ensembles distincts : un **ensemble d'entraînement**, un **ensemble de validation** et un **ensemble de test**. La répartition retenue est présentée dans le Tableau 8 ci-dessous.

| Ensemble     | Proportion | Effectif |
|--------------|------------|----------|
| Entraînement | 80%        | 6 492    |
| Validation   | 10%        | 812      |
| Test         | 10%        | 812      |

TABLE 8 – Répartition du corpus tokenisé en ensembles d'entraînement, validation et test

Le découpage a été réalisé de manière aléatoire, en utilisant une graine fixe (*seed* = 42). Cette procédure garantit la reproductibilité des expériences : les mêmes exemples sont affectés aux différents ensembles lors de chaque exécution.

L'ensemble d'entraînement est utilisé pour ajuster les paramètres du modèle. L'ensemble de validation sert à suivre l'évolution des performances pendant l'apprentissage et à comparer différentes configurations. L'ensemble de test, enfin, est exclusivement réservé à l'évaluation finale des modèles après l'entraînement. Le script implémentant ce découpage est présenté en annexe (Listing 12).

## 3.3 TOKENISATION ET PRÉPARATION LINGUISTIQUE

Après prétraitement, le corpus a été préparé pour les architectures de traduction neuronale. Chaque modèle a utilisé son tokenizer pré-entraîné, afin de garantir la compatibilité avec le vocabulaire et la segmentation attendus.

### 3.3.1 Segmentation en sous-mots avec SentencePiece

Les modèles neuronaux ne traitent pas les mots en tant que chaînes brutes. Ils manipulent des unités plus petites, appelées **sous-mots** (*subwords*). Cette segmentation réduit la taille du vocabulaire, tout en permettant de représenter des formes rares ou inconnues.

Les modèles [NLLB](#) et [mBART](#) reposent sur [SentencePiece](#). En décomposant les phrases en sous-unités, cette méthode limite les difficultés liées à la rareté lexicale du ruund. Elle facilite aussi la prise en charge de sa richesse morphologique.

Pour [MarianMT](#), le tokenizer pré-entraîné a été conservé. Il a été enrichi d'un token spécial ruund, qui permet d'indiquer explicitement la langue source.

Le Tableau 9 présente les stratégies de tokenisation utilisées.

| Modèle                   | Mécanisme de tokenisation                  | Adaptation au ruund                                                                          | Scripts en annexe      |
|--------------------------|--------------------------------------------|----------------------------------------------------------------------------------------------|------------------------|
| <a href="#">NLLB-200</a> | AutoTokenizer pré-entraîné (SentencePiece) | Configuration explicite de <code>src_lang=fra_Latn</code> et <code>tgt_lang=run_Latn</code>  | Listing 6, Listing 7   |
| <a href="#">mBART-50</a> | AutoTokenizer pré-entraîné (SentencePiece) | Ajout du token de langue <code>ruu_CM</code> et configuration <code>src_lang/tgt_lang</code> | Listing 8, Listing 9   |
| <a href="#">MarianMT</a> | AutoTokenizer pré-entraîné                 | Ajout d'un token spécial <code>»ruu_CM«</code> et préfixage des entrées Ruund                | Listing 10, Listing 11 |

TABLE 9 – Stratégies de tokenisation appliquées aux modèles de traduction

### 3.3.2 Gestion des mots hors vocabulaire

La segmentation en sous-mots réduit le phénomène des mots hors vocabulaire (OOV). Lorsqu'un mot n'est pas présent dans le vocabulaire, il est décomposé en sous-unités existantes plutôt que remplacé par un symbole générique. Cette approche préserve davantage d'informations linguistiques. Elle améliore ainsi la prise en charge des formes rares du ruund.

L'ajout d'un identifiant de langue ruund pour [MarianMT](#) et [mBART](#) renforce l'intégration explicite de cette langue dans le traitement des données.

### 3.3.3 Préparation des séquences d'entrée et de sortie

Après tokenisation, les phrases ont été converties en séquences d'identifiants numériques reconnues par chaque tokenizer. Ces séquences servent d'entrées et de sorties pour l'entraînement.

Une longueur maximale de 128 tokens a été fixée pour les séquences. Ce choix couvre la majorité des phrases, tout en limitant les besoins en mémoire et en assurant une homogénéité des données.

### 3.3.4 Configuration des hyperparamètres

Plutôt que de fixer manuellement les hyperparamètres d'entraînement, une démarche de **recherche par grille** (*grid search*) a été adoptée. Elle vise à identifier, pour chaque modèle, la combinaison offrant les meilleures performances sur l'ensemble de validation. Cette approche réduit le biais lié à un choix arbitraire des hyperparamètres. Elle objective ainsi la sélection de la configuration finale à partir d'un critère mesurable.

#### Principe de la recherche par grille

La recherche par grille consiste à définir un ensemble fini de valeurs candidates pour chaque hyperparamètre. Toutes les combinaisons possibles issues du produit cartésien de ces valeurs sont ensuite évaluées systématiquement. Pour chaque combinaison, un modèle est entraîné avec un *early stopping*<sup>3</sup> sur un sous-ensemble réduit du corpus d'entraînement. Cette réduction permet d'accélérer le processus d'exploration, tout en conservant une estimation représentative des performances relatives des différentes configurations.

La combinaison retenue est celle qui maximise le score **chrF** calculé sur l'ensemble de validation. Une fois les hyperparamètres optimaux identifiés, l'entraînement final de chaque modèle est réalisé sur l'intégralité du corpus d'entraînement. Cette dernière étape garantit l'exploitation complète des données disponibles.

#### Grille d'hyperparamètres explorée

Le Tableau 10 présente l'ensemble des valeurs candidates explorées lors de la recherche par grille. Le *taux d'apprentissage* (*learning rate*) et le *label smoothing*<sup>4</sup> constituent les deux hyperparamètres variables. Le *weight decay*, la taille de lot (*batch size*) et l'accumulation de gradient (*gradient accumulation*) ont quant à eux été maintenus constants, afin de limiter la combinatoire de la recherche.

| Hyperparamètre               | Valeurs explorées                                            |
|------------------------------|--------------------------------------------------------------|
| <i>Learning rate</i>         | $1 \times 10^{-5}$ ; $2 \times 10^{-5}$ ; $3 \times 10^{-5}$ |
| <i>Weight decay</i>          | 0,01                                                         |
| <i>Label smoothing</i>       | 0,1 ; 0,2                                                    |
| <i>Batch size</i>            | 16                                                           |
| <i>Gradient accumulation</i> | 2                                                            |

TABLE 10 – Grille des hyperparamètres explorée lors de la recherche par grille

3. L'*early stopping* interrompt l'entraînement lorsque la métrique de validation cesse de s'améliorer, afin d'éviter le surapprentissage et de limiter le temps de calcul.

4. Le *label smoothing* est une technique de régularisation qui atténue la confiance excessive du modèle envers les étiquettes cibles, favorisant une meilleure généralisation.

Cette grille produit six combinaisons distinctes. Chacune est évaluée selon la procédure décrite précédemment. Le code source complet relatif à la mise en œuvre de la recherche par grille est présenté en annexe (13).

### 3.3.5 Environnement expérimental

#### Google Colab Pro

L'ensemble des expériences a été réalisé sur la plateforme Google Colab Pro. Cette solution a permis de bénéficier d'un environnement de calcul infonuagique équipé de GPU de type G4, T4, H100... Ce dispositif a facilité l'entraînement et l'évaluation des modèles de TAN dans des délais raisonnables.

#### Bibliothèques utilisées

Plusieurs bibliothèques Python ont été mobilisées pour l'expérimentation :

- **Transformers** pour le chargement, l'adaptation et l'entraînement des modèles de traduction ;
- **Datasets** pour la gestion et le traitement du corpus ;
- **PyTorch** comme cadre d'apprentissage profond ;
- **SentencePiece** pour la tokenisation en sous-mots ;
- **Evaluate** pour l'évaluation des performances ;
- **Pandas** et **NumPy** pour la manipulation et le prétraitement des données.

L'utilisation conjointe de ces bibliothèques a permis de mettre en place un environnement expérimental cohérent pour le *fine-tuning* et l'évaluation des modèles étudiés.

## 3.4 ENTRAÎNEMENT DES MODÈLES (FINE-TUNING)

Le fine-tuning des trois modèles retenus (**mBART**, **NLLB**, **MarianMT**) a été conduit selon une stratégie d'**arrêt anticipé** (*early stopping*). Cette stratégie permet à chaque modèle de converger vers son point optimal, sans imposer un nombre fixe d'*epochs*.

### 3.4.1 Principe de l'arrêt anticipé

Le nombre maximal d'*epochs* défini dans la configuration constitue un plafond, non une valeur imposée. L'entraînement s'interrompt dès que le score **chrF** sur l'ensemble de validation cesse de progresser durant un nombre défini d'évaluations consécutives (*patience*). Ce mécanisme est associé à la conservation du meilleur modèle observé. Le modèle conservé à l'issue de l'entraînement correspond ainsi au meilleur point de convergence, et non à la dernière itération.



### 3.4.2 Configuration de l'entraînement final

Une fois la meilleure combinaison d'hyperparamètres identifiée par la recherche par grille (section 3.3.4), l'entraînement final de chaque modèle est réalisé sur l'intégralité du corpus d'entraînement, avec le plafond d'*epochs* fixé et l'*early stopping* activé.

## 3.5 ÉVALUATION DES MODÈLES

### 3.5.1 Méthodologie d'évaluation

Après l'entraînement, les performances des modèles ont été évaluées sur l'ensemble de test. Cette évaluation mesure leur capacité à produire des traductions correctes sur des données non observées durant l'apprentissage. Elle repose sur une comparaison automatique entre les traductions générées par les modèles et les traductions de référence présentes dans le corpus.

Pour chaque phrase source, le modèle génère une traduction. Cette traduction est ensuite comparée à la traduction de référence correspondante. Les performances sont mesurées à l'aide de **métriques automatiques**, qui permettent d'estimer la qualité des traductions produites.

### 3.5.2 Génération des traductions

La génération des traductions a été réalisée automatiquement à partir des modèles *fine-tunés*, à l'aide du mécanisme de génération intégré à la bibliothèque **Transformers**. Les séquences produites ont ensuite été décodées, afin de reconstruire les phrases textuelles correspondantes.

Avant le calcul des métriques, les identifiants de tokens générés ont été vérifiés, afin de garantir leur validité par rapport au vocabulaire du tokenizer. Les prédictions et les références ont ensuite été décodées en texte naturel, en supprimant les tokens spéciaux utilisés durant l'entraînement.

### 3.5.3 Métriques d'évaluation

Deux métriques automatiques ont été utilisées pour évaluer les performances des modèles de traduction : **BLEU** et **chrF**. Ces métriques permettent de comparer les traductions générées aux traductions de référence du corpus de test.

#### *Principe général*

**BLEU** évalue principalement la correspondance entre les groupes de mots présents dans les deux phrases. **chrF**, pour sa part, repose sur la comparaison de séquences de caractères. L'utilisation conjointe de ces deux métriques permet d'obtenir une évaluation plus complète de la qualité des traductions produites.

### Calcul des scores

Les scores **BLEU** et **chrF** ont été calculés à l'aide des bibliothèques **Evaluate** et **SacreBLEU**. Après génération des traductions sur l'ensemble de test, les prédictions ont été comparées aux références correspondantes.

Le score **BLEU** est obtenu à partir du recouvrement des groupes de mots (*n-grammes*) entre les traductions générées et les références. Le score **chrF** est calculé à partir de la précision et du rappel des séquences de caractères partagées entre les deux textes. Les deux métriques sont calculées sur l'ensemble des phrases du jeu de test, afin d'obtenir une mesure globale des performances de chaque modèle.

### Interprétation

Les scores **BLEU** et **chrF** varient généralement entre 0 et 100. Une valeur élevée indique une plus grande similarité lexicale entre les traductions générées et les références.

Contrairement à **BLEU**, **chrF** opère au niveau des caractères. Cette propriété la rend particulièrement adaptée à l'évaluation des **LFR**, où les variations morphologiques peuvent être importantes. Elle est souvent plus sensible aux similitudes linguistiques partielles et aux différences de segmentation. L'utilisation conjointe de **BLEU** et **chrF** permet ainsi d'obtenir une évaluation plus robuste des performances des modèles étudiés.

La Figure 3.2 illustre les différentes étapes du pipeline de fine-tuning adopté dans cette étude.




FIGURE 3.2 – Pipeline de fine-tuning

### 3.6 DÉPLOIEMENT DU SYSTÈME DE TRADUCTION

#### 3.6.1 Publication des modèles sur Hugging Face

À l'issue du processus de *fine-tuning*, les modèles entraînés ont été publiés sur la plateforme **Hugging Face**. Cette publication facilite leur conservation, leur partage et leur réutilisation dans des applications externes. Les modèles peuvent ainsi être chargés directement depuis leur dépôt lors du déploiement du système de traduction.

#### 3.6.2 Architecture générale de l'application

L'application **LugaYetu** développée repose sur une architecture **client-serveur**. Elle intègre le framework **Django** pour la gestion de l'interface utilisateur et des traitements applicatifs. La Figure 3.3 présente l'architecture générale de l'application et le flux de traitement des requêtes de traduction.




FIGURE 3.3 – Architecture générale de l'application

Cette architecture permet de séparer clairement l'interface utilisateur du moteur de traduction.

#### 3.6.3 Intégration des modèles dans Django

Les modèles publiés ont été intégrés à l'application Django, à l'aide des bibliothèques **Transformers** et **PyTorch**. Lors du démarrage du serveur, le modèle sélectionné est chargé localement, afin d'être disponible pour les requêtes de traduction. Lorsque l'utilisateur soumet un texte, celui-ci est prétraité par le tokenizer associé au modèle, puis transmis au moteur de traduction. La sortie générée est ensuite décodée avant d'être renvoyée à l'interface utilisateur.

#### 3.6.4 *Fonctionnement du système de traduction*

Pour la traduction dans les deux directions, le modèle **NLLB-200** *fine-tuné* sur le corpus parallèle ruund–français est utilisé. Le texte saisi par l'utilisateur est tokenisé, puis transmis au modèle, qui génère automatiquement la traduction.

#### CONCLUSION PARTIELLE

Ce chapitre a décrit la chaîne complète de développement du système : préparation du corpus, adaptation des modèles préentraînés, fine-tuning, évaluation par métriques BLEU et chrF, puis intégration du modèle retenu dans une application Django assurant la traduction bidirectionnelle entre le ruund et le français.

Le chapitre suivant présente les résultats obtenus et leur discussion critique, à partir des évaluations quantitatives et qualitatives réalisées sur les modèles entraînés.

## RÉSULTATS ET DISCUSSION

---

### 4.1 INTRODUCTION

Les chapitres précédents ont présenté la construction du corpus parallèle ruund–français, puis le développement du système de traduction automatique basé sur des modèles neuronaux. Il reste à en mesurer les résultats : identifier les forces et les limites de chaque modèle, et déterminer l’approche la plus adaptée au contexte des LFR.

Ce chapitre présente les résultats obtenus à l’issue du processus de *fine-tuning* des différents modèles de traduction. Les performances sont d’abord analysées à l’aide de métriques d’évaluation automatiques. Ces métriques permettent d’estimer la proximité des traductions générées avec les traductions de référence. Cette évaluation est ensuite complétée par une analyse qualitative reposant sur une évaluation humaine. Cette double approche permet d’apprécier non seulement la qualité lexicale et syntaxique des traductions, mais également leur fidélité sémantique et leur fluidité.

Enfin, une discussion critique des résultats est proposée. Elle interprète les performances observées en tenant compte des caractéristiques du corpus parallèle et des spécificités linguistiques du ruund. Cette analyse met en évidence les principaux facteurs ayant influencé les performances du système développé. Elle identifie aussi les limites de l’étude et dégage des perspectives d’amélioration pour les travaux futurs.

### 4.2 RÉSULTATS QUANTITATIFS

L’évaluation quantitative des modèles de traduction automatique a été réalisée à l’aide de deux métriques largement utilisées dans le domaine de la TAN : le score BLEU et le score chrF. Le score BLEU mesure le degré de correspondance entre la traduction générée et la traduction de référence, à partir des *n-grammes* de mots. Le score chrF repose quant à lui sur les *n-grammes* de caractères, ce qui le rend particulièrement adapté à l’évaluation des langues présentant une forte richesse morphologique ou disposant de ressources limitées. En complément, le temps d’entraînement de chaque modèle a été relevé, afin d’apprécier le coût computationnel associé au processus de *fine-tuning*.

#### 4.2.1 Présentation des résultats des métriques automatiques

Les performances obtenues par les trois modèles étudiés, mBART-50, NLLB-200-distilled-600M et MarianMT, ont été mesurées pour les deux directions de traduction : du ruund vers le français et du français vers le ruund.

Les résultats montrent des différences significatives entre les modèles évalués. Pour les deux directions de traduction, le modèle NLLB-200-distilled-600M obtient systématiquement les meilleurs scores BLEU et chrF. Le modèle mBART-50 se situe en deuxième position, avec des

performances satisfaisantes bien qu’inférieures à celles de [NLLB-200-distilled-600M](#). [MarianMT](#) affiche pour sa part les performances les plus faibles, en particulier pour la direction français→ruund.

Concernant le temps d’entraînement, les trois modèles présentent des durées relativement proches, comprises entre environ neuf et quinze minutes selon la direction de traduction. Le modèle [NLLB-200-distilled-600M](#) présente un temps d’entraînement légèrement inférieur à celui de [mBART-50](#), malgré un nombre de paramètres comparable, tout en offrant des performances nettement supérieures.

La Figure 4.1 présente les résultats détaillés des métriques automatiques pour les trois modèles.




FIGURE 4.1 – Performances des modèles selon les scores BLEU et chrF

#### 4.2.2 Analyse comparative des performances des modèles

L’analyse met en évidence l’intérêt des modèles multilingues de grande capacité pour les [LFR](#). [mBART-50](#) et [NLLB-200-distilled-600M](#) comptent environ 600 millions de paramètres chacun. Leur capacité de représentation dépasse largement celle de [MarianMT](#), qui ne compte qu’environ 60 millions de paramètres. Cette différence de capacité favorise l’apprentissage de représentations linguistiques plus riches. Elle améliore ainsi la généralisation lors du *fine-tuning* sur un corpus de taille limitée.

Les performances plus faibles de [MarianMT](#) s’expliquent aussi par l’origine du modèle. Le modèle de départ, `Helsinki-NLP/opus-mt-ln-fr`, n’a pas été conçu pour prendre en charge le ruund. Son adaptation, par l’ajout du jeton de langue `ruu_CM` et un *fine-tuning* sur le corpus parallèle, a permis d’étendre ses capacités à cette langue. Cette adaptation reste toutefois moins efficace que celle des modèles multilingues préentraînés sur un grand nombre de langues.

Ces résultats quantitatifs constituent une première indication des performances des différents modèles. Les métriques automatiques ne permettent cependant pas, à elles seules, d’apprécier pleinement la qualité des traductions générées. Une analyse qualitative, complétée par une évaluation humaine, est donc nécessaire pour examiner plus finement la fidélité sémantique, la fluidité et l’acceptabilité linguistique des traductions produites.

### 4.2.3 Analyse de la convergence des modèles

L'analyse des courbes d'entraînement complète l'évaluation par les métriques automatiques. Elle permet d'examiner la vitesse d'apprentissage, la stabilité de l'entraînement et la capacité de généralisation des trois modèles étudiés, à partir de l'évolution de la **perte d'entraînement**, de la **perte de validation** et des scores **BLEU**/**chrF** au fil des époques.

Le modèle **NLLB-200-distilled-600M** présente la convergence la plus régulière. Pour les deux directions de traduction, les pertes d'entraînement et de validation diminuent de façon continue sur les quinze époques. Les scores **BLEU** et **chrF** progressent quant à eux jusqu'à atteindre un plateau en fin d'entraînement. L'écart limité entre les deux courbes de perte indique une bonne capacité de généralisation, sans signe marqué de **surapprentissage** (*overfitting*).

Les Figures 4.3 et 4.2 illustrent l'évolution de la perte et des métriques automatiques pour le modèle **NLLB-200-distilled-600M** en fonction des époques.




FIGURE 4.2 – Courbes d'entraînement NLLB-200-distilled-600M - Français → Ruund




FIGURE 4.3 – Courbes d'entraînement NLLB-200-distilled-600M - Ruund → Français

Le modèle **mBART-50** converge plus rapidement sur les premières époques. Les gains les plus importants en **BLEU** et **chrF** sont observés entre la deuxième et la quatrième époque. Au-delà de cette phase, la perte de validation augmente alors que la perte d'entraînement continue

de diminuer, ce qui traduit un début de surapprentissage. Les scores [BLEU](#) et [chrF](#) conservent néanmoins une légère progression jusqu'à la dixième époque, sans être affectés par cette divergence des pertes.

Les Figures 4.4 et 4.5 illustrent l'évolution de la perte et des métriques automatiques pour le modèle [mBART-50](#) en fonction des époques.




FIGURE 4.4 – Courbes d'entraînement mBART-50 - Français → Ruund




FIGURE 4.5 – Courbes d'entraînement mBART-50 - Ruund → Français

Le modèle [MarianMT](#) affiche une diminution régulière et stable des deux pertes, sans augmentation notable de la perte de validation. Les scores [BLEU](#) et [chrF](#) progressent de manière constante, mais avec des gains décroissants au fil des époques. Cette évolution révèle une convergence vers un optimum local, à un niveau de performance inférieur à celui des deux modèles multilingues.

Les Figures 4.6 et 4.7 illustrent l'évolution de la perte et des métriques automatiques pour le modèle [MarianMT](#) en fonction des époques.






FIGURE 4.6 – Courbes d’entraînement MarianMT - Français → Ruund




FIGURE 4.7 – Courbes d’entraînement MarianMT - Ruund → Français

Ces observations corroborent les résultats obtenus par les métriques automatiques (Section 4.2.1). *NLLB-200-distilled-600M* combine les meilleures performances et la convergence la plus stable. *mBART-50* apprend rapidement, mais présente des signes de surapprentissage. *MarianMT* converge de façon stable, sans atteindre un niveau de performance comparable. Ces résultats confirment l’intérêt des modèles multilingues préentraînés de grande capacité pour la TAN appliquée aux LFR telles que le ruund.

### 4.3 ÉVALUATION QUALITATIVE DES TRADUCTIONS

#### 4.3.1 Analyse d’exemples de traduction

##### *Analyse qualitative des traductions hors contexte religieux*

Le Tableau 11 présente quelques exemples de traductions générées par les trois modèles dans les directions Français → Ruund et Ruund → Français. Les exemples retenus couvrent des textes variés, principalement hors contexte religieux, tout en incluant quelques extraits du domaine religieux

| Source                                                                                                                                                                                                                                                                                                                                                          | Référence                                                                                                                                                                                                                                                                                                                                                       | NLLB-200                                                                                                                                                                                                                                                                                                                      | mBART-50                                                                                                                                                                                                                                                                               | MarianMT                                                                                                                                                                                                                                                                                 |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Bonjour, je suis Uriel et je viens de Kolwezi. J'aime les femmes comme le Christ a aimé l'Église. J'ai remarqué que pour avoir de l'argent, il faut travailler, ce qui est difficile à faire, sachant que la majorité des personnes dans le pays sont au chômage. Je vous remercie, que le Seigneur vous bénisse et multiplie le poisson dans votre génération. | Walankan, dijine dam uriel ,nid mu Kolwezi, nikatine emband mud kristu mukatinaye chikumb chend cha nzamb ,nimen kwikal ni nfalang ifandin kusal mudum,ikasken kwihi-sal,mutap enchu avud mwi ngand kadap ni mudum , nikujikitishinan ni nzamb akuyukishan ,avudish enshi mu chipuk Chen                                                                        | mwalany, am nidi uriel wa ku kolwezi. nikatil amband mudi mukatilay kristu in chikumbu cha nzamb. natesha anch, chakwel ukwet nfalang, ufanyidin kusal mudimu, mulong antu avud a mu mangand minam akwet mudimu. nakushmanany, chifanyidin nzamb akuyukishany ni kupan ansh avud mu chisak chen.                              | nakwitiyany, am uriel, nidio-kil ku musumb wa kolwezi. nikat ambwez ambach pa ambweny, nikat kukat ambwez chidi chom chamwamu, mulong kristu watutazuka kand in chikumbu cha nzamb. nova kudi en anch, chifanyidin nsalejetu akwinkishany yiyukish yau ni kupalangan mu yisak yen yau. | am nikat kulembil kudikal ku musumb wa kolwezi, niyam amband amwinend mudi kristu wakad mukach mwi ngand ya in chikumbu cha nzamb. chawiy nading ni kuyilej antu akata kurum-buril rusangu ruwamp ra nfalang ja utad wa nfalang ja utad wa nfalang ja utad wa nfalang ja utad wa nfalang |
| Walankan, dijine dam uriel ,nid mu Kolwezi, nikatine emband mud kristu mukatinaye chikumb chend cha nzamb ,nimen kwikal ni nfalang ifandin kusal mudum,ikasken kwihi-sal,mutap enchu avud mwi ngand kadap ni mudum , nikujikitishinan ni nzamb akuyukishan ,avudish enshi mu chipuk Chen                                                                        | Bonjour, je suis Uriel et je viens de Kolwezi. J'aime les femmes comme le Christ a aimé l'Église. J'ai remarqué que pour avoir de l'argent, il faut travailler, ce qui est difficile à faire, sachant que la majorité des personnes dans le pays sont au chômage. Je vous remercie, que le Seigneur vous bénisse et multiplie le poisson dans votre génération. | d'où me vient l'inquiétude et la détresse que j'éprouve à colosses? je t'adresse ma défense, une fidélité chrétienne qui m'est attachée. je te demande de m'enrichir de plus en plus pour t'aider à progresser dans le monde nouveau. je te demande de m'en remercier, à cause de la grande bénédiction que dieu m'a accordée | il est écrit je suis une femme vierge, qui répond à l'exigence de dieu je suis prête à payer les impôts et les taxes du monde, afin de ne pas avoir à payer les impôts et les taxes du monde. que dieu bénisse ceux qui sont dans le besoin!                                           | en effet, le nom d'un dam urbain, uni à Kolwezi, est une femme qui produit de la viande de jésus, dont l'herbe est cultivée et dont l'argent sert à la fois à la récolte et à la récolte, et qui a beaucoup d'importance dans le monde entier.                                           |

TABLE 11 – Exemple de traduction de textes variés, principalement hors contexte religieux, tout en incluant quelques extraits du domaine religieux, sur les 3 modèles

L'exemple présenté dans le Tableau 11 permet d'observer le comportement des trois modèles sur un texte conversationnel, hors du registre biblique majoritaire du corpus d'entraînement.

Dans la direction **français**→**ruund**, le **NLLB** produit une traduction globalement cohérente. Il conserve les éléments sémantiques centraux de la phrase source (identité du locuteur, provenance géographique, thématique du travail et de l'argent), avec une structure syntaxique proche de la référence. Le **mBART** propose également une sortie cohérente sur le plan grammatical, mais s'écarte davantage de la référence dans le choix lexical, tout en conservant l'idée générale du texte source. Le **MarianMT**, en revanche, présente une dégradation marquée en fin de séquence. La répétition de la séquence « *nfalang ja utad wa nfalang* » illustre un phénomène de **répétition dégénérative** (*repetition loop*). Ce phénomène, fréquent chez les modèles neuronaux insuffisamment régularisés dans les contextes à faibles ressources, traduit une perte de contrôle du décodeur sur la génération.

Dans la direction inverse **ruund**→**français**, les trois modèles échouent à restituer le sens de la phrase source. Le **NLLB** génère un contenu à connotation religieuse (« inquiétude », « Colosses ») totalement étranger au texte source. Le **mBART** produit, pour sa part, une hallucination construite autour des thématiques de la virginité et des impôts. Le **MarianMT** propose un texte incohérent mêlant des éléments disparates (« viande de jésus », « récolte »), sans lien perceptible avec la source. Ce phénomène suggère un **biais de domaine** (*domain bias*) : la forte proportion de textes bibliques dans le corpus d'entraînement semble conduire les modèles à reproduire un registre religieux par défaut, lorsqu'ils sont confrontés à un énoncé hors distribution. Ce biais est particulièrement marqué dans le sens ruund→français, où la charge de génération repose sur le français.

#### *Analyse qualitative des traductions en contexte religieux*

Le Tableau 12 présente quelques exemples de traductions générées par les trois modèles dans les directions Français → Ruund et Ruund → Français, à partir de phrases en contexte religieux. Ces exemples permettent d'évaluer la capacité des modèles à traduire des énoncés relevant du domaine religieux, caractérisés par un vocabulaire spécifique et des formulations propres aux textes sacrés.

| Source                                                                                        | Référence                                                                                     | NLLB-200                                                                                          | mBART-50                                                                                                         | MarianMT                                                                           |
|-----------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
| Qui d'entre vous parvient à prolonger un peu la durée de sa vie par le souci qu'il se fait?   | Ov, nany wa pakach pen anch unenganen ukutwisha kuwejaku ku mwom wend ap kusu kachisu kakemp? | ov, nany wa pakach pen ukutwisha kukarumun chikas chimwing ku mwom wend mulong wa kuzengol kwend? | ov, nany wa pakach pen ukutwisha kukarumuk mivuyivud ya mwom wend mulong wa souci chisotilau?                    | ov, nany ukutwisha kwikal kand anch ov, nany ukutwisha kwikal mwom wa chikupu?     |
| Ov, nany wa pakach pen anch unenganen ukutwisha kuwejaku ku mwom wend ap kusu kachisu kakemp? | Qui d'entre vous parvient à prolonger un peu la durée de sa vie par le souci qu'il se fait?   | qui d'entre vous peut, en s'inquiétant, ajouter une seule coudée à la longueur de sa vie?         | il n'est pas surprenant que quelqu'un, dans votre cas, puisse se relever d'entre les morts pour un peu de temps. | qui d'entre vous peut être capable d'aller jusqu'au bout de sa vie ou d'en sortir? |

TABLE 12 – Exemple de traduction de textes religieux, sur les 3 modèles

Le Tableau 12 présente des exemples en contexte religieux. Il permet d'évaluer les modèles sur le registre dominant de l'entraînement.

Dans la direction français→ruund, le NLLB et le mBART produisent des traductions structurellement proches de la référence. Le mBART laisse toutefois apparaître un phénomène d'**alternance codique** (*code-switching*) involontaire : il conserve le terme français « *souci* » non traduit au sein de la phrase en ruund, ce qui révèle une lacune du vocabulaire cible appris pour ce terme. Le MarianMT échoue de nouveau à produire une traduction exploitable. Il répète partiellement la structure interrogative (« *ov, nany ukutwisha kwikal* »), ce qui vide la phrase de son contenu sémantique original.

Dans la direction ruund→français, le NLLB produit la meilleure traduction observée sur l'ensemble des exemples analysés : la sortie restitue fidèlement le sens de la source. À l'inverse, le mBART produit une hallucination importante, en introduisant une thématique de résurrection totalement absente du texte source. Le MarianMT conserve partiellement le sens interrogatif et la référence à la durée de vie, mais omet la notion causale de « *souci* ». Cette omission constitue une **omission sémantique** significative.

#### *Comparaison générale des trois modèles*

La confrontation des deux contextes met en évidence des tendances cohérentes avec les résultats quantitatifs présentés en section 4.2. Le NLLB apparaît comme le modèle le plus robuste, tant en contexte religieux qu'hors contexte religieux, avec une performance particulièrement notable dans la direction ruund→français sur les données bibliques. Le mBART affiche une qualité intermédiaire, marquée par une tendance récurrente à l'hallucination lorsque le texte source s'éloigne du registre religieux ou lorsque la traduction s'effectue vers le français. Le MarianMT, enfin, présente la performance la plus instable, avec des phénomènes récurrents de répétition dégénérative observés dans les deux directions de traduction, indépendamment du domaine du texte source.

Deux constats transversaux se dégagent de cette analyse. D'une part, la direction français→ruund produit des sorties plus stables que la direction inverse, possiblement en raison d'une distribution lexicale ruund plus contrainte lors de la génération. D'autre part, les trois modèles obtiennent globalement de meilleurs résultats sur le contexte religieux, ce qui s'explique par sa prédominance dans le corpus d'entraînement. Ces observations confirment l'hypothèse d'un déséquilibre de domaine du corpus, susceptible de limiter la capacité de généralisation des modèles vers des registres non religieux.

#### 4.3.2 *Évaluation humaine*

En complément des métriques automatiques, une **évaluation humaine** est actuellement en cours. Elle vise à apprécier la qualité linguistique réelle des traductions produites par les modèles. Cette évaluation porte sur un échantillon de vingt phrases sélectionnées dans le corpus de test et hors corpus. Ces phrases sont examinées indépendamment par 3 locuteurs natifs du ruund, dont un expert titulaire d'un doctorat (PhD) en linguistique et littératures africaines de l'Université de Lubumbashi, le Prof. Michel Kasombo. Trois critères ont été retenus : **la fidélité au texte source**, **la fluidité** et **la correction grammaticale**, chacun noté sur une échelle de 0 à 10.

Les résultats préliminaires disponibles à ce stade sont présentés au Tableau 13, à titre indicatif. Ils seront consolidés à l'issue de la validation complète.

| Modèle                  | Fidélité | Fluidité | Grammaire | Score global (/10) |
|-------------------------|----------|----------|-----------|--------------------|
| NLLB-200-distilled-600M | 6,00     | 5,00     | 3,00      | 4,67               |
| mBART-50                | 3,00     | 2,00     | 2,00      | 2,33               |
| MarianMT                | 1,00     | 0,00     | 1,00      | 0,67               |

TABLE 13 – Résultats préliminaires de l'évaluation humaine (en cours)

Ces résultats préliminaires suggèrent un classement cohérent avec l'évaluation quantitative : NLLB se démarque provisoirement par une meilleure fidélité et fluidité. Ces tendances demeurent toutefois à confirmer, une fois l'évaluation humaine achevée. Elles restent pour l'instant cohérentes avec les orientations de la littérature actuelle, qui favorisent globalement NLLB dans les scénarios de traduction à faibles ressources [3, 40].

#### 4.4 DISCUSSION DES RÉSULTATS

Cette section propose une interprétation critique et transversale des résultats présentés dans les sections précédentes. Elle met ces résultats en regard des caractéristiques du corpus, des architectures des modèles et des erreurs observées, avant d'aborder les limites méthodologiques de l'étude.

##### 4.4.1 Influence du corpus parallèle

Le corpus utilisé dans ce travail comprend 8 431 paires de phrases ruund-français, construites à partir du Nouveau Testament et de poèmes bilingues. La taille de ce corpus constitue un facteur déterminant des performances observées. Selon la littérature portant sur la TAN pour les LFR, les performances des modèles neuronaux chutent drastiquement en deçà de 10 000 paires de phrases [40]. Le corpus mobilisé dans cette étude se situe précisément en dessous de ce seuil critique. Ce constat explique en partie le niveau des scores BLEU obtenus. Il justifie aussi le recours indispensable au *fine-tuning* de modèles multilingues pré-entraînés, plutôt qu'à un entraînement *from scratch*.

Au-delà de la taille, la qualité de l'alignement des paires de phrases joue un rôle déterminant dans l'apprentissage des correspondances linguistiques. La structuration en versets du corpus biblique offre un cadre d'alignement naturellement fiable, ce qui réduit les risques de désalignement source-cible. Cette caractéristique constitue un avantage méthodologique pour la fiabilité des données d'entraînement. Elle s'accompagne toutefois d'une contrepartie importante en matière de **diversité lexicale et stylistique** : le vocabulaire, les tournures syntaxiques et le registre du corpus biblique ne couvrent qu'une partie restreinte de l'usage réel de la langue ruund.

Cette limite liée au domaine biblique se reflète directement dans les résultats de l’analyse qualitative (section 4.3). Les trois modèles y éprouvent des difficultés marquées à traiter des énoncés hors du registre religieux, allant jusqu’à produire des hallucinations à connotation biblique lorsqu’ils sont confrontés à un texte conversationnel. Ce constat suggère que les modèles ont partiellement appris une **distribution de domaine**, plutôt qu’une compétence de traduction généraliste. Cette limite restreint la capacité de généralisation du système à des contextes d’usage variés (administratif, conversationnel, éducatif, etc.).

#### 4.4.2 Influence des architectures des modèles

La Figure 4.1 met en évidence des différences significatives entre les trois modèles.

Le modèle **NLLB-200-distilled-600M** obtient les meilleures performances dans les deux directions de traduction. Cette supériorité s’explique principalement par son pré-entraînement sur 55 langues africaines [44], ce qui favorise un transfert cross-lingual efficace vers le ruund lors du fine-tuning. L’initialisation du nouveau token `rnd_Latn` à partir du proxy `run_Latn`, une langue bantoue proche, a également pu faciliter son adaptation.

Le modèle **mBART-50** présente des performances intermédiaires. Son pré-entraînement sur un ensemble plus restreint de langues limite probablement le transfert de connaissances vers le ruund, malgré l’utilisation du proxy bantou `sw_KE` pour initialiser le token `rnd_XX`.

Le modèle **MarianMT** obtient les scores les plus faibles. Contrairement aux deux autres modèles, il ne dispose ni d’un pré-entraînement multilingue, ni de mécanismes de tokens de langue. Cette absence réduit sa capacité de transfert et rend son adaptation au ruund plus difficile sur un corpus limité.

#### 4.4.3 Analyse des erreurs

L’examen des exemples de traduction présentés en section 4.3.1 permet d’identifier plusieurs catégories d’erreurs récurrentes chez les modèles évalués.

##### *Erreurs lexicales et mots rares.*

Le modèle **mBART** laisse apparaître un phénomène d’**alternance codique** (*code-switching*) involontaire : il conserve le terme français « *souci* » non traduit au sein d’une phrase générée en ruund. Ce comportement traduit une lacune du vocabulaire cible pour un terme peu fréquent dans le corpus d’entraînement. Il illustre la sensibilité des modèles aux mots rares et aux mots hors vocabulaire.

##### *Ambiguïtés et hallucinations liées au domaine.*

Lorsque le texte source s’éloigne du registre religieux, les modèles **NLLB** et **mBART** produisent des traductions sémantiquement incohérentes mais syntaxiquement fluides. Ils reconstituent des contenus à connotation biblique (inquiétude, résurrection, impôts). Ce phénomène d’hallucination constitue une forme d’ambiguïté résolue de manière erronée par le modèle, qui privilégie la distribution de domaine apprise plutôt que le sens réel de la phrase source.

### *Expressions idiomatiques.*

L'exemple biblique portant sur l'expression figurée « *ajouter une coudée à la longueur de sa vie* » révèle une disparité importante entre les modèles. Seul **NLLB** restitue correctement cette formulation idiomatique. **mBART** et **MarianMT** en perdent en revanche le sens figuré, ce qui confirme la difficulté propre à la traduction des expressions idiomatiques dans un contexte de données limitées.

### *Erreurs morphologiques et répétitions.*

Le modèle **MarianMT** présente un phénomène récurrent de répétition dégénérative (*repetition loop*), notamment observable en fin de séquence longue. Une suite de tokens y est reproduite de manière cyclique, sans apport sémantique. Ce comportement est associé à la structure fortement agglutinante du ruund (classes nominales, affixes verbaux multiples). Il suggère une difficulté du modèle à gérer la composition morphologique de la langue cible, plutôt qu'une simple erreur de décodage lexical.

## 4.5 VALIDATION DU SYSTÈME DÉVELOPPÉ

Au terme de l'évaluation quantitative et qualitative, le modèle NLLB-200-distilled-600M s'est révélé être le plus performant pour la traduction automatique entre le français et le ruund. Ce modèle a été retenu pour le déploiement du système, en raison de ses meilleurs résultats en termes de scores BLEU, de score chrF et d'évaluation humaine.

L'intégration du modèle a été réalisée au sein d'une application web développée avec le framework Django. Cette application permet à l'utilisateur de saisir un texte en français ou en ruund et d'en obtenir instantanément la traduction dans la langue cible. Le modèle de traduction, préalablement affiné puis publié sur la plateforme Hugging Face, est chargé par le serveur lors du démarrage de l'application. Lorsqu'une requête est soumise, le texte est prétraité selon la procédure décrite au chapitre précédent. Il est ensuite transmis au modèle NLLB, qui génère la traduction avant son affichage à l'utilisateur.

Au-delà de l'aspect technique, le système développé constitue une première contribution à la valorisation numérique du ruund. En démontrant la faisabilité d'un système de traduction automatique pour cette langue à faibles ressources, ce travail contribue à accroître sa présence dans les technologies du traitement automatique des langues.

L'approche méthodologique adoptée dans cette étude ne se limite d'ailleurs pas au ruund. Ses différentes étapes, la constitution d'un corpus parallèle, l'adaptation d'un modèle multilingue, le fine-tuning et le déploiement dans une application web, peuvent être reproduites pour d'autres langues de la **RDC** disposant de peu de ressources numériques. Cette recherche ouvre ainsi des perspectives intéressantes pour le développement d'outils de traduction destinés à favoriser l'inclusion numérique, la préservation du patrimoine linguistique et l'accessibilité des contenus dans les langues congolaises.



#### 4.6 CONCLUSION PARTIELLE

Les expérimentations menées confirment la supériorité du modèle NLLB-200-distilled-600M sur mBART-50 et MarianMT, tant en scores BLEU/chrF qu'en stabilité d'apprentissage. Ces résultats valident la faisabilité d'une traduction automatique exploitable pour le ruund, malgré la faiblesse des ressources disponibles. L'intégration du modèle retenu dans une application web démontre l'opérationnalité de cette approche pour la valorisation numérique des langues congolaises.

Le chapitre suivant propose une synthèse générale des résultats obtenus. Il revient sur les principales limites de cette étude et ouvre des perspectives d'amélioration, tant sur le plan linguistique que technique, afin d'envisager l'extension de cette démarche à d'autres langues à faibles ressources.

## CONCLUSION GÉNÉRALE

---

L'essor récent de l'[IA](#) et des modèles neuronaux de traduction a considérablement amélioré la qualité des systèmes de traduction automatique. Cette amélioration profite surtout aux langues disposant d'importantes ressources linguistiques. Les [LFR](#) en tirent encore peu profit, notamment celles de la RDC. La faible disponibilité de corpus numériques y constitue un obstacle majeur au développement d'outils de [TAL](#). Le **ruund** fait partie de ces langues : il demeure très peu représenté dans les ressources et les modèles de traduction existants. C'est dans ce contexte que s'inscrit le présent mémoire. Son objectif principal était d'étudier les approches de traduction automatique adaptées aux [LFR](#) et de développer un système de traduction neuronale pour le couple **ruund–français**.

Pour répondre à cette problématique, cette recherche s'est appuyée sur une démarche méthodologique couvrant l'ensemble du cycle de développement d'un système de traduction automatique. Cette démarche va de la constitution des données jusqu'au déploiement d'une application fonctionnelle. Elle s'est d'abord appuyée sur un travail de synthèse : l'étude des fondements théoriques de la [TAN](#) et l'examen critique des recherches consacrées aux [LFR](#). Cette revue de la littérature a mis en évidence un constat récurrent : malgré les progrès réalisés grâce aux architectures Transformer et aux modèles multilingues pré-entraînés, les langues africaines restent largement sous-représentées dans les ressources linguistiques et les systèmes de traduction disponibles. Ce constat a confirmé la pertinence scientifique du choix du ruund comme langue d'étude.

Le travail s'est ensuite traduit par une réalisation concrète : la construction du corpus parallèle **OpenRuund**, constitué de 8 431 paires de phrases en ruund et en français. Ce corpus a été élaboré à partir de textes issus principalement du Nouveau Testament ainsi que de textes poétiques. Sa constitution a nécessité un processus rigoureux. Celui-ci comprend la numérisation des documents, l'extraction des textes par reconnaissance optique de caractères, le nettoyage, la normalisation, l'alignement automatique des phrases, la correction manuelle des erreurs ainsi que la validation finale des données. Cette ressource constitue, à notre connaissance, l'un des premiers corpus parallèles structurés disponibles pour le couple ruund–français. Elle représente une contribution importante au développement futur des technologies de [TAL](#) du ruund.

À partir de ce corpus, trois modèles de [TAN](#) ont été adaptés au contexte du ruund grâce à une phase de *fine-tuning* : [mBART-50](#), [MarianMT](#) et [NLLB-200-distilled-600M](#). Le ruund ne figurait pas parmi les langues initialement prises en charge par certains de ces modèles. Il a donc fallu adapter leur vocabulaire, par l'ajout du jeton linguistique `ruu_CM` et, lorsque cela était nécessaire, par le redimensionnement des couches d'embedding. Les performances des modèles ont ensuite été évaluées à l'aide des métriques automatiques [BLEU](#) et [chrF](#). Cette évaluation a été complétée par une évaluation humaine, réalisée par des locuteurs natifs du ruund et un spécialiste en linguistique et littératures africaines. Les résultats obtenus montrent que les trois modèles produisent des traductions de qualité satisfaisante, malgré le volume limité des données d'entraînement. Parmi eux, [NLLB-200-distilled-600M](#) s'est distingué : c'est le modèle qui

a obtenu les scores les plus élevés dans les deux sens de traduction, ce qui confirme l'intérêt des modèles multilingues massivement pré-entraînés pour les LFR.

Au-delà de l'expérimentation des modèles, cette recherche a abouti au développement d'une application web. Celle-ci intègre le meilleur modèle de traduction ainsi qu'un module de collecte collaborative de données textuelles et vocales. Les modèles entraînés et le corpus construit ont également été publiés sur la plateforme Hugging Face, afin de favoriser leur réutilisation par la communauté scientifique. L'ensemble de ces réalisations constitue une contribution concrète au développement de ressources numériques ouvertes pour le ruund. Il jette les bases de futurs travaux dans le domaine du TAL des langues congolaises.

Ces résultats permettent de valider les hypothèses formulées au début de cette étude. La disponibilité d'un corpus parallèle de qualité constitue un facteur déterminant pour l'apprentissage de modèles de traduction performants. L'adaptation de modèles multilingues pré-entraînés permet de compenser, dans une certaine mesure, le manque de ressources propres au ruund. Il est enfin possible de développer un système de traduction opérationnel pour une LFR à partir d'un corpus de taille relativement modeste, à condition de mettre en œuvre un processus rigoureux de préparation des données et de *fine-tuning*. Les objectifs fixés au début de la recherche ont ainsi été atteints : étude des approches adaptées aux LFR, constitution du corpus, adaptation et comparaison des modèles, évaluation des traductions et déploiement d'un système applicatif.

Malgré ces résultats encourageants, plusieurs difficultés ont marqué la réalisation de ce travail. La principale réside dans l'absence quasi totale de ressources numériques existantes pour le ruund. Cette situation a nécessité la constitution d'un corpus parallèle à partir de documents imprimés. Elle a impliqué un travail conséquent de numérisation et de correction des erreurs générées par la reconnaissance optique de caractères. L'alignement des phrases entre les versions ruund et française a également demandé de nombreuses vérifications manuelles, afin de garantir la qualité des données utilisées pour l'entraînement. L'absence du ruund parmi les langues officiellement supportées par certains modèles pré-entraînés a en outre nécessité l'ajout d'un nouveau jeton linguistique et l'adaptation du vocabulaire des modèles. Enfin, les contraintes liées aux ressources matérielles disponibles, notamment la capacité limitée des GPU, ont imposé certains compromis dans les paramètres d'entraînement.

Cette étude présente également quelques limites. Le corpus parallèle utilisé constitue une ressource précieuse, mais il demeure relativement restreint comparativement aux jeux de données disponibles pour les langues à fortes ressources. Une grande partie des données provient du domaine religieux, ce qui peut limiter la capacité de généralisation des modèles vers d'autres domaines tels que l'administration, l'éducation, la santé ou les médias. Seuls trois modèles de TAN ont par ailleurs été comparés dans cette étude, alors que d'autres architectures récentes auraient pu être évaluées. L'évaluation humaine, enfin, repose sur un nombre limité d'évaluateurs, ce qui ne permet pas d'apprécier de manière exhaustive la qualité des traductions produites.

Ces limites ouvrent plusieurs perspectives de recherche. Une première perspective consiste à enrichir progressivement le corpus OpenRuund, en intégrant des textes provenant de domaines variés, afin d'améliorer la couverture lexicale et la capacité de généralisation des modèles. La poursuite de la collecte collaborative de données textuelles et vocales, à travers la plateforme développée dans ce travail, permettra également d'augmenter le volume des ressources disponibles, tout en impliquant davantage de locuteurs natifs. Sur le plan méthodologique, il serait pertinent d'explorer des techniques récentes d'adaptation efficace des modèles, telles que PEFT, LoRA ou QLoRA, ainsi que l'utilisation de modèles multilingues de nouvelle

génération. Une autre perspective importante consisterait à étendre cette approche à d'autres langues congolaises à faibles ressources, afin de favoriser le développement d'un écosystème national de technologies linguistiques. Enfin, le système développé pourrait évoluer vers une plateforme de traduction multimodale, intégrant la reconnaissance automatique de la parole et la synthèse vocale. Une telle évolution ouvrirait la voie à des applications de traduction parole-à-parole.

En définitive, ce mémoire démontre que le développement d'un système de traduction automatique pour une LFR telle que le ruund est possible. Il se révèle même prometteur, lorsqu'il s'appuie sur une démarche méthodique de constitution des données, d'adaptation de modèles multilingues et d'évaluation rigoureuse des performances. Au-delà des résultats scientifiques obtenus, cette recherche contribue à l'enrichissement des ressources numériques disponibles pour le ruund. Elle contribue aussi à la valorisation du patrimoine linguistique congolais et à la promotion d'une IA plus inclusive. Les ressources produites, les modèles entraînés et la plateforme développée constituent une base solide. De futurs travaux pourront s'appuyer sur cette base pour accélérer l'intégration des langues congolaises dans les technologies modernes de TAL.

## ANNEXES

---

Le code source complet développé dans le cadre de ce mémoire est mis à disposition afin de permettre la vérification, la reproductibilité et l'éventuelle extension des travaux réalisés. Il est accessible publiquement via le dépôt GitHub suivant :

<https://github.com/EliezerMga/Lugayetu>

Ce dépôt contient l'ensemble des modules, scripts et composants nécessaires au fonctionnement du système présenté. Toute réutilisation ou modification du code doit respecter les conditions de la licence associée au dépôt. Aucune donnée sensible ou confidentielle n'est incluse dans ce dépôt.

Les ressources associées au projet sont également disponibles sur Hugging Face :

- Jeu de données OpenRuund : <https://huggingface.co/datasets/eliezerMga/OpenRuund>
- Modèle français → ruund : <https://huggingface.co/eliezerMga/fr-ruund-nllb>
- Modèle ruund → français : <https://huggingface.co/eliezerMga/ruund-fr-nllb>

```
1 def extraire_avec_ocr_neutre(self, pdf_path):
2     """OCR sans interprétation linguistique"""
3     text_parts = []
4
5     try:
6         doc = fitz.open(pdf_path)
7         for page_num in range(len(doc)):
8             page = doc.load_page(page_num)
9             # Vérifier d'abord si la page a du texte vectoriel
10            text_vectoriel = page.get_text()
11            if text_vectoriel and len(text_vectoriel.strip()) > self.
12                min_text_length:
13                continue
14
15            # Sinon, faire OCR
16            try:
17                pix = page.get_pixmap(matrix=fitz.Matrix(300/72, 300/72)
18                )
19                img_data = pix.tobytes("ppm")
20
21                from io import BytesIO
22                img = Image.open(BytesIO(img_data))
23
24                # Convertir en niveaux de gris pour meilleur OCR
```

```

23         if img.mode != 'L':
24             img = img.convert('L')
25
26         # OCR avec configuration neutre
27         text = pytesseract.image_to_string(
28             img,
29             config=self.ocr_config
30         )
31         if text.strip():
32             text_parts.append(f"\n{'='*40} Page {page_num + 1} (
33                 OCR) {'='*40}\n")
34             text_parts.append(text)
35         except Exception as ocr_error:
36             print(f"    OCR page {page_num + 1} échoué: {ocr_error}")
37             continue
38     doc.close()
39     return "\n".join(text_parts)
40 except Exception as e:
41     print(f" Erreur OCR neutre: {e}")
42     return ""

```

Listing 1 – Extraction OCR – conversion d’une page PDF en image puis reconnaissance par Tesseract.

```

1 BASE_URL = "https://www.bible.com/fr/bible/63/{ }.{ }.BFC"
2 HEADERS = {"User-Agent": "Mozilla/5.0"}
3
4 def is_verse(span):
5     return re.search(r"\.\d+$", span.get("data-usfm", "")) is not None
6
7 def is_note(span):
8     classes = span.get("class", [])
9     return any("note" in cls.lower() for cls in classes)
10
11 def extract_clean_text(element):
12     morceaux = []
13     for node in element.descendants:
14         if not isinstance(node, NavigableString):
15             continue
16         skip = False
17         for parent in node.parents:
18             if parent == element:
19                 break
20             if parent.name == "span" and is_note(parent):
21                 skip = True
22                 break
23         if not skip:
24             morceaux.append(str(node))
25     texte = "".join(morceaux)
26     return re.sub(r"\s+", " ", texte).strip()
27
28 def scraper_chapitre(livre, chapitre):
29     url = BASE_URL.format(livre, chapitre)
30     response = requests.get(url, headers=HEADERS, timeout=10)
31     soup = BeautifulSoup(response.text, "html.parser")
32     contenu = []

```

```

33
34 for span in soup.find_all("span"):
35     if is_note(span):
36         continue
37     if "heading" in " ".join(span.get("class", [])).lower():
38         texte = extract_clean_text(span)
39         if texte:
40             contenu.append(f"\n{texte}\n")
41     elif is_verse(span):
42         texte = extract_clean_text(span)
43         if texte:
44             contenu.append(texte)
45 return "\n".join(contenu)

```

Listing 2 – Extrait de récupération des chapitres bibliques depuis [Bible.com](#)

```

1 def read_txt(file_path):
2     data = []
3     with open(file_path, 'r', encoding='utf-8') as f:
4         for i, line in enumerate(f, start=1):
5             line = line.strip()
6             if not line:
7                 continue
8             parts = line.split(' ', 1)
9             if len(parts) != 2:
10                 print(f"[ERREUR FORMAT] Ligne {i} dans {file_path}")
11                 continue
12             verse_id, text = parts
13             data.append((i, verse_id.strip(), text.strip()))
14     return data
15
16 def align_and_export(ruwund_file, francais_file, output_file):
17     ruwund_data = read_txt(ruwund_file)
18     francais_data = read_txt(francais_file)
19     if len(ruwund_data) != len(francais_data):
20         print("Nombre de lignes différent")
21         print(f"Ruwund: {len(ruwund_data)}")
22         print(f"Français: {len(francais_data)}")
23         return
24     print("Nombre de lignes identique")
25     errors = 0
26     with open(output_file, 'w', encoding='utf-8') as out:
27         for i in range(len(ruwund_data)):
28             _, verse_r, text_r = ruwund_data[i]
29             _, verse_f, text_f = francais_data[i]
30             if verse_r != verse_f:
31                 print(f"Incohérence à la ligne {i+1}")
32                 print(f"Ruwund: {verse_r}")
33                 print(f"Français: {verse_f}")
34                 errors += 1
35                 continue
36             out.write(f"{verse_r}\t{text_r}\t{text_f}\n")
37     if errors == 0:
38         print(f"TSV généré : {output_file}")
39     else:

```

```
print(f"{errors} incoh rence(s) d tect e(s)")
```

Listing 3 – Script d’alignement automatique

```
1 def preprocess_text(text):
2     if not isinstance(text, str):
3         return ""
4     # Normalisation Unicode propre
5     text = unicodedata.normalize('NFC', text)
6
7     # Lowercase
8     text = text.lower()
9
10    # Garder ponctuation utile (.,!?)
11    text = re.sub(r"[^\w\s.,!?'"]", "", text)
12
13    # Nettoyage espaces
14    text = re.sub(r'\s+', ' ', text).strip()
15    return text
```

Listing 4 – Pr traitement du Texte pour la Normalisation

```
1 # Sauvegarde taille initiale
2 initial_size = len(df)
3
4 # 1. Suppression doublons
5 df = df.drop_duplicates()
6
7 # 2. Longueurs
8 df['src_len'] = df['Ruund'].apply(lambda x: len(x.split()))
9 df['trg_len'] = df['French'].apply(lambda x: len(x.split()))
10
11 # 3. Suppression phrases vides
12 df = df[(df['src_len'] > 0) & (df['trg_len'] > 0)]
13
14 # 4. Filtrage longueur
15 df = df[(df['src_len'] <= 80) & (df['trg_len'] <= 80)]
16
17 # 5. Filtrage ratio
18 df = df[(df['src_len'] / df['trg_len'] <= 2.0) &
19         (df['trg_len'] / df['src_len'] <= 2.0)]
20
21 # R sultat
22 print(f"Taille initiale : {initial_size}")
23 print(f"Taille apr s filtrage : {len(df)}")
```

Listing 5 – Filtrage du Corpus pour Optimisation des Donn es

```
1 model_checkpoint = "facebook/nllb-200-distilled-600M"
2
3 tokenizer = AutoTokenizer.from_pretrained(model_checkpoint, src_lang="
    fra_Latn", tgt_lang="run_Latn")
```

Listing 6 – Chargement du Mod le et du Tokenizer (NLLB)

```
1 dataset = Dataset.from_pandas(df[['Ruund', 'French']])
2
3 def preprocess(examples):
```



```

4     tokenizer.src_lang = "run_Latn"
5     return tokenizer(
6         examples['Ruund'],
7         text_target=examples['French'],
8         max_length=128,
9         truncation=True,
10        padding=False
11    )
12
13 tokenized_dataset = dataset.map(
14     preprocess,
15     batched=True,
16     remove_columns=['Ruund', 'French']
17 )
18 splits = tokenized_dataset.train_test_split(test_size=0.1, seed=42)
19 train_dataset = splits['train']
20 eval_dataset = splits['test']

```

Listing 7 – Tokenisation du Corpus (NLLB)

```

1 model_name = "facebook/mbart-large-50"
2 tokenizer = AutoTokenizer.from_pretrained(model_name)
3
4 # Ajout du token de langue custom pour le Ruund
5 tokenizer.add_special_tokens({"additional_special_tokens": ["ruu_CM"]})
6 tokenizer.src_lang = "ruu_CM"
7 tokenizer.tgt_lang = "fr_XX"
8
9 # Chargement du modèle + redimensionnement embedding pour le nouveau
  token
10 model = MBartForConditionalGeneration.from_pretrained(model_name)
11 model.config.tie_word_embeddings = False
12 model.resize_token_embeddings(len(tokenizer))
13
14 # Forcer la génération en français (fr_XX car c'est la nouvelle langue
  cible)
15 model.generation_config.forced_bos_token_id = tokenizer.
    convert_tokens_to_ids("fr_XX")
16
17 print(f"Token ruu_CM id : {tokenizer.convert_tokens_to_ids('ruu_CM')}")
18 print(f"Taille du vocabulaire : {len(tokenizer)}")

```

Listing 8 – Chargement du Modèle et du Tokenizer (MBART)

```

1 dataset = Dataset.from_pandas(df[['French', 'Ruund']])
2
3 def preprocess_function(examples):
4     model_inputs = tokenizer(
5         examples["Ruund"],
6         max_length=128,
7         truncation=True,
8         padding=False
9     )
10
11     labels = tokenizer(
12         text_target=examples["French"],
13         max_length=128,

```

```

14         truncation=True,
15         padding=False
16     )
17
18     model_inputs["labels"] = [
19         np.array(l, dtype=np.int64) for l in labels["input_ids"]
20     ]
21
22     return model_inputs
23
24 tokenized_dataset = dataset.map(
25     preprocess_function,
26     batched=True,
27     remove_columns=["French", "Ruund"]
28 )

```

Listing 9 – Tokenisation du Corpus (MBART)

```

1 model_checkpoint = "Helsinki-NLP/opus-mt-ln-fr"
2
3 # Chargement du tokenizer pré-entraîné
4 tokenizer = AutoTokenizer.from_pretrained(model_checkpoint)
5
6 # Définir le token spécial pour le Ruund
7 new_special_tokens = ['>>ruu_CM<<']
8
9 # Ajouter les tokens spéciaux au tokenizer
10 tokenizer.add_special_tokens({'additional_special_tokens':
    new_special_tokens})

```

Listing 10 – Ajout d'un Token de Langue Custom pour le Ruund(MariantMT)

```

1 dataset = Dataset.from_pandas(df[['Ruund', 'French']])
2
3 def preprocess_function(examples):
4     prefixed_ruund_sentences = [f'>>ruu_CM<< {s}' for s in examples['
    Ruund']]
5
6     model_inputs = tokenizer(
7         prefixed_ruund_sentences,
8         max_length=128,
9         truncation=True,
10        padding=False
11    )
12
13    labels = tokenizer(
14        text_target=examples['French'],
15        max_length=128,
16        truncation=True,
17        padding=False
18    )
19
20    model_inputs['labels'] = [
21        np.array(l, dtype=np.int64) for l in labels['input_ids']
22    ]
23
24    return model_inputs
25
26 tokenized_dataset = dataset.map(

```

```

25 preprocess_function,
26 batched=True,
27 remove_columns=['Ruund', 'French']
28 )

```

Listing 11 – Tokenisation du Corpus avec le Token de Langue Custom (MarianMT)

```

1 train_testvalid = tokenized_dataset.train_test_split(test_size=0.2, seed
  =42)
2 test_valid = train_testvalid["test"].train_test_split(test_size=0.5,
  seed=42)
3
4 final_datasets = DatasetDict({
5     "train": train_testvalid["train"],
6     "validation": test_valid["train"],
7     "test": test_valid["test"]
8 })
9
10 train_dataset = final_datasets["train"]
11 eval_dataset = final_datasets["validation"]
12 test_dataset = final_datasets["test"]

```

Listing 12 – Création des Splits d'Entraînement, Validation et Test

```

1 PARAM_GRID = {
2     "learning_rate": [1e-5, 2e-5, 3e-5],
3     "weight_decay": [0.01],
4     "label_smoothing": [0.1, 0.2],
5     "batch_size": [16],
6     "grad_accum": [2],
7 }
8
9 def iter_grid(grid):
10     keys = list(grid.keys())
11     for values in itertools.product(*[grid[k] for k in keys]):
12         yield dict(zip(keys, values))
13
14 def run_grid_search(train_ds, val_ds, search_epochs=12): # cap ; early
15 stopping coupe avant
16 # Sous-échantillon pour accélérer la recherche
17 n = CONFIG["search_subset"]
18 search_train = train_ds.shuffle(seed=CONFIG["seed"]).select(
19     range(min(n, len(train_ds)))) if n else train_ds
20
21 results, best = [], None
22 combos = list(iter_grid(PARAM_GRID))
23 print(f"{len(combos)} combinaisons à tester (train de recherche : {
24     len(search_train)}).\n")
25
26 for i, hp in enumerate(combos, 1):
27     print(f"[{i}/{len(combos)}] {hp}")
28     set_all_seeds(CONFIG["seed"])
29     model = load_model()
30     args = build_training_args(
31         hp, output_dir=f"./search/run_{i}", epochs=search_epochs)
32     trainer = make_trainer(model, args, search_train, val_ds,
33         label_smoothing=hp["label_smoothing"])

```

```

32     trainer.train()
33     metrics = trainer.evaluate()
34     score = metrics[f"eval_{CONFIG['eval_metric']}"]
35     print(f"        -> eval_{CONFIG['eval_metric']} = {score}\n")
36     results.append(**hp, "score": score)
37
38     if best is None or score > best["score"]:
39         best = **hp, "score": score
40
41     del model, trainer; gc.collect()
42     if torch.cuda.is_available(): torch.cuda.empty_cache()
43
44     print("Meilleurs hyperparamètres :", best)
45     return best, pd.DataFrame(results).sort_values("score", ascending=
False)

```

Listing 13 – Recherche par grille des hyperparamètres




FIGURE A.1 – Exemple d’une page scannée du Manswik Masu



FIGURE A.2 – Page d'accueil de l'application Web




FIGURE A.3 – Page de traduction de l'application Web






FIGURE A.4 – Page de contribution de l’application Web




FIGURE A.5 – Page de collecte d’audios de l’application Web

The screenshot shows the 'Contribuer' (Contribute) page of the LugaYetu application. The header includes the LugaYetu logo, navigation links for 'Accueil', 'Traducteur', and 'Contribuer' (which is active), a language selector set to 'FR', a dark mode toggle, and a user profile for 'Eliezer'. The main content area is a white card with the title 'Ajouter une paire de phrases'. Below the title is a subtitle: 'Contribuez en ajoutant des phrases traduites pour enrichir notre base de données.' The form contains three input fields: 'Langue cible' with the value 'Ruund', 'Phrase dans la langue d'origine' with the placeholder 'Entrez la phrase ici...', and 'Traduction en Français' with the placeholder 'Entrez la traduction ici...'. At the bottom of the card is a green button labeled '▶ Enregistrer la paire'.

LugaYetu

Accueil Traducteur Contribuer

FR

Eliezer

Ajouter une paire de phrases

Contribuez en ajoutant des phrases traduites pour enrichir notre base de données.

Langue cible

Ruund

Phrase dans la langue d'origine

Entrez la phrase ici...

Traduction en Français

Entrez la traduction ici...

▶ Enregistrer la paire

FIGURE A.6 – Page d'ajout d'une phrase de l'application Web

## BIBLIOGRAPHIE

---

- [1] Mehmet ACI, Nisa VURAN SARI et Çiğdem İNAN ACI. « Morphological and structural complexity analysis of low-resource English-Turkish language pair using neural machine translation models ». In : *PeerJ Computer Science* 11 (2025), e3072. DOI : [10.7717/peerj-cs.3072](https://doi.org/10.7717/peerj-cs.3072).
- [2] Emmanuel AGYEI, Xiaoling ZHANG, Stephen BANNERMAN, Ama Bonuah QUAYE, Sophyani Banaamwini YUSSI et Victor Kwaku AGBESI. « Low resource Twi-English parallel corpus for machine translation in multiple domains (Twi-2-ENG) ». In : *Discover Computing* 27.1 (2024), p. 17.
- [3] Emmanuel AGYEI, Xiaoling ZHANG, Ama Bonuah QUAYE, Victor Adeyi ODEH et Joseph Roger ARHIN. « Dynamic aggregation and augmentation for low-resource machine translation using federated fine-tuning of pretrained transformer models ». In : *Applied Sciences* 15.8 (2025), p. 4494.
- [4] Benyamin AHMADNIA, Bonnie J. DORR et Raul ARANOVICH. « Impact of Filtering Generated Pseudo Bilingual Texts in Low-Resource Neural Machine Translation Enhancement : The Case of Persian-Spanish ». In : *Procedia Computer Science*. T. 189. Elsevier, 2021, p. 136-141.
- [5] Benyamin AHMADNIA, Parisa KORDJAMSHIDI et Gholamreza HAFFARI. « Neural Machine Translation Advised by Statistical Machine Translation : The Case of Farsi-Spanish Bilingually Low-Resource Scenario ». In : *Proceedings of the 17th IEEE International Conference on Machine Learning and Applications (ICMLA'18)*. IEEE. 2018, p. 1209-1213. DOI : [10.1109/ICMLA.2018.00196](https://doi.org/10.1109/ICMLA.2018.00196).
- [6] Mazida AHMED, Kuwali TALUKDAR, Parvez BORUAH, Shikhar Kumar SARMA et Kishore KASHYAP. « Guit-nlp's submission to shared task : Low resource indic language translation ». In : *Proceedings of the Eighth Conference on Machine Translation*. 2023, p. 935-940.
- [7] Mumtaz ALI, Arun YADAV et Mohit KUMAR. « A Hybrid Word and Sentence Alignment Approach for Unsupervised Multilingual Machine Translation Using Pre-Trained Cross-Lingual Encoder ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* (2026).
- [8] Jason ANGEL, Abdul Gafar Manuel MEQUE, Christian MALDONADO-SIFUENTES, Grigori SIDOROV et Alexander GELBUKH. « Comparing transformer-based machine translation models for low-resource languages of Colombia and Mexico ». In : *Mexican International Conference on Artificial Intelligence*. Springer. 2023, p. 95-105. DOI : [10.1007/978-3-031-47640-2\\_8](https://doi.org/10.1007/978-3-031-47640-2_8).
- [9] Sudhansu BALA DAS, Atharv BIRADAR, Tapas KUMAR MISHRA et Bidyut KR. PATRA. « Improving Multilingual Neural Machine Translation System for Indic Languages ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* 22.6 (2023). DOI : [10.1145/3587932](https://doi.org/10.1145/3587932).
- [10] Sudhansu BALA DAS, Divyajyoti PANDA, Tapas KUMAR MISHRA, Bidyut KR. PATRA et Asif EKBAL. « Multilingual neural machine translation for indic to indic languages ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* 23.5 (2024), p. 1-32.



- [11] Maharaj BRAHMA, Kaushal MAURYA et Maunendra DESARKAR. « SelectNoise : Un-supervised Noise Injection to Enable Zero-Shot Machine Translation for Extremely Low-resource Languages ». In : *Findings of the Association for Computational Linguistics : EMNLP 2023*. Singapore : Association for Computational Linguistics, 2023, p. 1615-1629. URL : <https://aclanthology.org/2023.findings-emnlp.109/>.
- [12] William CHEN et Brett FAZIO. « Morphologically-Guided Segmentation For Translation of Agglutinative Low-Resource Languages ». In : *Proceedings of the 4th Workshop on Technologies for MT of Low Resource Languages (LoResMT2021)*. Virtual : Association for Machine Translation in the Americas, août 2021, p. 20-31. URL : <https://aclanthology.org/2021.mtsummit-loresmt.3/>.
- [13] Wei DAI, Dongfang HAN, Turdi TOHTI, Yi LIANG, Zicheng ZUO, Yuanyuan LIAO et Qingwen YANG. « TFT-TL : Token-Level Filter Training Transfer Learning for Low-Resource Neural Machine Translation ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* 24.6 (2025). DOI : [10.1145/3732779](https://doi.org/10.1145/3732779).
- [14] Chanambam Svata DEVI, Loitongbam Sanayai MEETI et Bipul Syam PURKAYASTHA. « An empirical study on English-Mizo Statistical Machine Translation with Bible Corpus ». In : *International Journal of Electrical and Computer Engineering Systems* 13.9 (nov. 2022), p. 759-765. DOI : [10.32985/ijeces.13.9.4](https://doi.org/10.32985/ijeces.13.9.4).
- [15] Ivan DUNĐER, Sanja SELJAN et Marko PAVLOVSKI. « Automatic machine translation of poetry and a low-resource language pair ». In : *2020 43rd International Convention on Information, Communication and Electronic Technology (MIPRO)*. IEEE. 2020, p. 1034-1039. DOI : [10.23919/MIPRO48935.2020.9245342](https://doi.org/10.23919/MIPRO48935.2020.9245342).
- [16] Kavita GANGAR, Hardik RUPAREL et Shreyas LELE. « Hindi to english : Transformer-based neural machine translation ». In : *International Conference on Communication, Computing and Electronics Systems : Proceedings of ICCCES 2020*. Springer. 2021, p. 337-347.
- [17] Ian GOODFELLOW, Yoshua BENGIO et Aaron COURVILLE. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [18] Vikrant GOYAL, Sourav KUMAR et Dipti Misra SHARMA. « Efficient neural machine translation for low-resource languages via exploiting related languages ». In : *Proceedings of the 58th annual meeting of the association for computational linguistics : student research workshop*. 2020, p. 162-168.
- [19] Stig-Arne GRÖNROOS, Sami VIRPIOJA et Mikko KURIMO. « Transfer learning and sub-word sampling for asymmetric-resource one-to-many neural translation ». In : *Machine Translation* 34 (2020), p. 251-286. DOI : [10.1007/s10590-020-09253-x](https://doi.org/10.1007/s10590-020-09253-x).
- [20] Thangkhanhau HAULAI et Jamal HUSSAIN. « Construction of mizo : English parallel corpus for machine translation ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* 22.8 (2023), p. 1-12.
- [21] Kung Yin HONG et al. « CANTONMT : Investigating Back-Translation and Model-Switch Mechanisms for Cantonese-English Neural Machine Translation ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* (2024). DOI : [10.1145/3698236](https://doi.org/10.1145/3698236).
- [22] Godwill W.K. ILUNGA, Selain K. KASEREKA, Eliezer MUNUNGA, Credo KANUMBEDI, Onesime M. MBULAYI, Israel M.W. MWAMBA, Rebecca RYAKITIMBO et Tasho TASHEV. « Speech Dataset Creation in Low-Resource Contexts : A Systematic Review ». In : *Procedia Computer Science* (2026). ISSN : 1877-0509. DOI : [10.1016/j.procs.2026.04.072](https://doi.org/10.1016/j.procs.2026.04.072).

- [23] Shishpal JINDAL, Vishal GOYAL et Jaskarn Singh BHULLAR. « Building English–Punjabi parallel corpus for machine translation ». In : *International Journal of Computer Applications* 180.8 (2017), p. 26-29.
- [24] Katharina KANN, Abteen EBRAHIMI, Manuel MAGER, Arturo ONCEVAY, John E ORTEGA, Annette RIOS, Angela FAN, Ximena GUTIERREZ-VASQUES, Luis CHIRUZZO, Gustavo A GIMÉNEZ-LUGO et al. « AmericasNLI : Machine translation and natural language inference systems for Indigenous languages of the Americas ». In : *Frontiers in Artificial Intelligence* 5 (2022), p. 995667. DOI : [10.3389/frai.2022.995667](https://doi.org/10.3389/frai.2022.995667).
- [25] Michaël KASOMBO TSHIBANDA. *Structure segmentale du radical verbal et comportement tonal en ruwund L53*. Rapp. tech. Lubumbashi : Université de Lubumbashi, 2016. URL : <https://blogs.helsinki.fi/bantu-6/files/2016/09/Bantu6-Kasombo-Structure-segmentale-du-radical-verbal-et-comportement-tonal-en-ruwund-L53.pdf>.
- [26] Boniface Kaumba KAWASHA. « LUNDA GRAMMAR : A MORPHOSYNTACTIC AND SEMANTIC ANALYSIS ». Book. University of Oregon, juin 2003. URL : <https://theswissbay.ch/pdf/Books/Linguistics/Mega%20linguistics%20pack/African/Niger-Congo/Bantu/Lunda%20Grammar%20-%20A%20Morphosyntactic%20and%20Semantic%20Analysis%20%28Kawasha%29.pdf>.
- [27] Tom KELDENICH. *Encoder Decoder What and Why? – Simple Explanation*. Inside Machine Learning. Consulté le 29 mai 2026. Oct. 2021. URL : <https://inside-machinelearning.com/en/encoder-decoder-what-and-why-simple-explanation/>.
- [28] Zhanibek KOZHIRBAYEV. « Enhancing Neural Machine Translation with Fine-Tuned mBART50 Pre-Trained Model : An Examination with Low-Resource Translation Pairs ». In : *Ingénierie des Systèmes d'Information* 29.3 (2024), p. 1095-1104. DOI : [10.18280/isi.29.0304](https://doi.org/10.18280/isi.29.0304).
- [29] Candy LALREMPUII et Badal SONI. « Investigating unsupervised neural machine translation for low-resource language pair english-mizo via lexically enhanced pre-trained language models ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* 22.8 (2023), p. 1-18.
- [30] Candy LALREMPUII, Badal SONI et Partha PAKRAY. « An improved English-to-Mizo neural machine translation ». In : *Transactions on Asian and Low-Resource Language Information Processing* 20.4 (2021), p. 1-21.
- [31] Séamus LANKFORD, Haithem AFLI et Andy WAX. « Human Evaluation of English–Irish Transformer-Based NMT ». In : *Information* 13.7 (2022), p. 309. DOI : [10.3390/info13070309](https://doi.org/10.3390/info13070309).
- [32] Felix LAUMANN. *Challenges in using NLP for low-resource languages and how NeuralSpace solves them*. Medium. Consulté le 29 mai 2026. Jan. 2022. URL : <https://medium.com/neuralspace/challenges-in-using-nlp-for-low-resource-languages-and-how-neural-space-solves-them-54a01356a71b>.
- [33] Chaya LIEBESKIND, Shmuel LIEBESKIND et Dan BOUHNİK. « Machine translation for historical research : A case study of Aramaic-Ancient Hebrew translations ». In : *ACM Journal on Computing and Cultural Heritage* 17.2 (2024), p. 1-23. DOI : [10.1145/3627168](https://doi.org/10.1145/3627168).
- [34] Xinchun MA, Man LAN, Wenbo HU et Yue LU. « Dongba machine translation with transfer Learning : leveraging pre-trained ancient Chinese models ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* 24.5 (2025), p. 1-17.

- [35] Reagan E. MANDIYA, Selain K. KASEREKA, Christophe B. WIZAMO, Milena SAVOVA-MRATSENKOVA, Ruffin-Benoît M. NGOIE, Tasho TASHEV et Nathanaël M. KASORO. « A Transformer-Based Method for Bidirectional French–Lingala Machine Translation in Speech and Text ». In : *Applied Sciences* 16.7 (2026), p. 3399. DOI : [10.3390/app16073399](https://doi.org/10.3390/app16073399).
- [36] Francois MEYER et Jan BUYS. « A Systematic Analysis of Subwords and Cross-Lingual Transfer in Multilingual Translation ». In : *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. 2024. URL : <https://arxiv.org/abs/2403.20157>.
- [37] Eliezer MUNUNGA, Selain KASEREKA, Godwil ILUNGA, Christopher MWANZA et Eglia MUTALE. *OpenRuund (Revision 9d279ca)*. 2026. DOI : [10.57967/hf/9146](https://doi.org/10.57967/hf/9146). URL : <https://huggingface.co/datasets/eliezermga/OpenRuund>.
- [38] Toan Q. NGUYEN et David CHIANG. « Transfer Learning across Low-Resource, Related Languages for Neural Machine Translation ». In : *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 2 : Short Papers)*. Taipei, Taiwan : Asian Federation of Natural Language Processing, nov. 2017, p. 296-301. URL : <https://aclanthology.org/I17-2050/>.
- [39] Matthew J. PAGE et al. « The PRISMA 2020 statement : an updated guideline for reporting systematic reviews ». In : *BMJ* 372 (mars 2021), n71. DOI : [10.1136/bmj.n71](https://doi.org/10.1136/bmj.n71).
- [40] Surangika RANATHUNGA, En-Shiun Annie LEE, Marjana PRIFTI SKENDULI, Ravi SHEKHAR, Mehreen ALAM et Rishemjit KAUR. « Neural machine translation for low-resource languages : A survey ». In : *ACM Computing Surveys* 55.11 (2023), p. 1-37. DOI : [10.1145/3567592](https://doi.org/10.1145/3567592).
- [41] Pooja RANI, Kamlesh YADAV et Anil KUMAR SINGH. « Filtering and Extended Vocabulary based Translation for Low-resource Language Pair of Sanskrit-Hindi ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* (2023). DOI : [10.1145/3580495](https://doi.org/10.1145/3580495).
- [42] Prawaal SHARMA, Navneet GOYAL, Poonam GOYAL et Vishnupriyan R. « A fully automated and scalable Parallel Data Augmentation for Low Resource Languages using image and text analytics ». In : *Proceedings of the 38th ACM/SIGAPP Symposium on Applied Computing*. 2023, p. 358-361.
- [43] José Alfredo SULLA TORRES, Beatrice CUEVA MEDINA et Gabriel Fabrizio TUCA CASQUINO. « Desarrollo de un modelo de traducción automática neuronal optimizado con BERT para la traducción del idioma quechua al español ». In : *Sustainable Engineering for a Diverse, Equitable, and Inclusive Future at the Service of Education, Research, and Industry for a Society 5.0*. (LACCEI 2024). Costa Rica, 2024. URL : <https://laccei.org/LACCEI2024-CostaRica/meta/FP1636.html>.
- [44] NLLB TEAM et al. *No Language Left Behind : Scaling Human-Centered Machine Translation*. 2022. arXiv : [2207.04672](https://arxiv.org/abs/2207.04672) [cs.CL]. URL : <https://arxiv.org/abs/2207.04672>.
- [45] Cagri TORAMAN, Eyup Halit YILMAZ, Furkan ŞAHINUÇ et Oguzhan OZCELIK. « Impact of Tokenization on Language Models : An Analysis for Turkish ». In : *ACM Transactions on Asian and Low-Resource Language Information Processing* 22.4 (2022), p. 1-21. DOI : [10.1145/3578707](https://doi.org/10.1145/3578707).
- [46] Tho TRAN DUC, Huy NGUYEN TRONG et Huong LE THANH. « Improving Quality of Vietnamese to Khmer Neural Machine Translation Using Multi-stage Fine-Tuning Strategy ». In : *Proceedings of the 11th International Symposium on Information and Communication Technology (SOICT 2024)*. 2024. URL : [https://users.soict.hust.edu.vn/huonglt/Machine\\_Translation\\_Vi\\_Km\\_\\_\\_SOICT\\_2024.pdf](https://users.soict.hust.edu.vn/huonglt/Machine_Translation_Vi_Km___SOICT_2024.pdf).

- [47] Ei Ni Tar TUN, Yi Mon Shwe SIN et Khin Mar SOE. « Exploring Bidirectional Mon-English Machine Translation with SMT, NMT and Fine-Tuned BART ». In : *IAENG International Journal of Computer Science* 52.11 (2025).
- [48] Ashish VASWANI, Noam SHAZEER, Niki PARMAR, Jakob USZKOREIT, Llion JONES, Aidan N GOMEZ, Łukasz KAISER et Illia POLOSUKHIN. « Attention is all you need ». In : *Advances in neural information processing systems* 30 (2017).
- [49] WIKIPÉDIA. *Ruund* — Wikipédia, l'encyclopédie libre. [En ligne ; Page disponible le 29 Mai 2026]. 2022. URL : <http://fr.wikipedia.org/w/index.php?title=Ruund&oldid=199251041>.

Mununga Kayinda Eliezer : *Approches de traduction automatique pour les langues à faibles ressources : application au ruund-français*, TFC, © juillet 2026

ENCADRANTS :

Prof. Dr Selain Kasereka Kabunga  
C.T Godwill Ilunga Wa Kumwita

LIEUX :

République démocratique du Congo, Haut-Katanga, Lubumbashi

CADRE TEMPOREL :

juillet 2026